

Développement d'une application d'auto-évaluation de l'épuisement professionnel

Méthodologie statistique et enjeux de prévention

Responsable de mémoire : Monsieur Sylvain Chareyron,
Maître de conférences en sciences économiques à l'Université Paris-Est Créteil

Jade LAURENT
Master 1 Parcours MASERATI DS
UFR de Sciences Économiques et de Gestion
Année universitaire 2024–2025

Remerciements

Je tiens à adresser mes plus sincères remerciements à **Monsieur Sylvain Chareyron**, maître de conférences en sciences économiques pour avoir accepté de diriger ce mémoire. Tout au long de cette recherche, il m'a guidée avec rigueur, bienveillance et clarté, en m'apportant des précieux conseils à chaque étape de l'élaboration de ce travail. Je lui suis également reconnaissante pour la qualité des enseignements qu'il m'a dispensés, notamment en programmation Python, qui ont constitué une base solide pour l'ensemble de l'analyse empirique menée dans ce mémoire.

Je remercie également l'ensemble de l'équipe pédagogique du *Master MASERATI* pour la qualité des enseignements dispensés cette année. Je suis particulièrement reconnaissante pour la confiance qui m'a été accordée en m'accueillant dans cette formation, et pour l'opportunité qui m'a été donnée de développer mes compétences dans un environnement intellectuellement exigeant et stimulant.

Je souhaite remercier tout particulièrement **Monsieur Kevin Fourrey**, maître de conférences en économie pour avoir accepté de faire partie du jury de ce mémoire. Je tiens également à le remercier pour la qualité des enseignements qu'il m'a dispensés, tant en économétrie durant ma licence qu'en économie publique au niveau Master. Ses cours ont fortement contribué à forger mon intérêt pour l'analyse empirique et les politiques publiques.

Je remercie les amis et personnes de confiance qui m'ont accompagnée au fil de cette année intense. Vos encouragements, votre écoute et vos mots bienveillants m'ont permis d'avancer avec plus de sérénité.

Enfin, je tiens à exprimer toute ma reconnaissance à ma famille, dont le soutien indéfectible m'a portée dans chaque étape de ce parcours. Merci pour votre patience, votre confiance et votre présence constante, qui ont été des appuis essentiels jusqu'à l'aboutissement de ce mémoire.

Table des matières

Remerciements	1
1 Introduction	4
2 Revue de littérature	5
2.1 Définition complexe du burn-out	5
2.1.1 Les origines de la notion d'épuisement	5
2.1.2 Une définition médicale et multidimensionnelle	6
2.1.3 Une vision plus large et systémique	6
2.2 Les modèles explicatifs du burn-out	7
2.2.1 Diverses approches théoriques	7
2.2.2 Une lecture psychosociale du burn-out	8
2.3 Les principaux facteurs de risque du burn-out	9
2.3.1 Les déterminants structurels : la pression du travail et ses effets	10
2.3.2 Les facteurs individuels	10
2.4 Limites et zones d'ombre des approches actuelles	11
2.4.1 Une notion floue	11
2.4.2 Des modèles utiles mais incomplets	11
2.4.3 Une problématique liée à la société actuelle	12
3 Étude empirique	12
3.1 Source des données, méthode de collecte et échantillon	12
3.1.1 Origine et caractéristiques de l'enquête mobilisée	12
3.1.2 Constitution de l'échantillon final	13
3.2 Justification du choix méthodologique et construction de la variable d'épuise- ment professionnel	13
3.2.1 Construction des trois dimensions du <i>Maslach Burnout Inventory</i>	14
3.2.2 Construction du score global d'épuisement professionnel	18
3.2.3 Transformation du score en variable binaire	19
3.3 Choix du modèle économétrique : régression logistique binaire	19
3.3.1 Spécification du modèle	19
3.3.2 Sélection des variables explicatives	20
4 Résultats empiriques et discussions	21
4.1 Modélisation du risque d'épuisement professionnel	21
4.1.1 Estimation du modèle logit	21
4.1.2 Qualité d'ajustement et performance prédictive	25
4.1.3 Application interactive de prédiction du risque d'épuisement profes- sionnel	27
4.2 Discussion : implications en matière de prévention et de politiques publiques .	29
5 Conclusion	30
Annexe A Illustrations graphiques	34
Annexe B Résultats du modèle OLS	39
Annexe B Résultats du modèle OLS	39

Annexe C Résultats du modèle OLS enrichi	40
Annexe D Résultats du modèle Logit enrichi	41
Annexe E Résultats du modèle Logit final	42
Annexe G Code Python	42

1 Introduction

Le travail occupe une place centrale dans la vie des individus. Il façonne l'identité, structure le quotidien et peut être une source de satisfaction, de reconnaissance et de lien social. Mais il peut aussi devenir un facteur de déséquilibre, notamment lorsque les exigences dépassent les ressources dont dispose la personne pour y faire face. Ce déséquilibre peut avoir des effets durables sur la santé mentale et physique. Il ne dépend pas seulement des caractéristiques individuelles, mais aussi des conditions d'exercice du travail, de l'environnement organisationnel et de la façon dont les efforts fournis sont reconnus ou soutenus.

Le stress, reconnu comme un risque psychosocial par l'Agence européenne pour la sécurité et la santé au travail (AESST), apparaît précisément lorsque les attentes professionnelles sont ressenties comme supérieures aux capacités à y répondre. Lorsqu'il devient chronique, il peut fragiliser l'équilibre mental de manière significative. Ce phénomène dépasse largement les conséquences individuelles : il s'agit d'un véritable enjeu de santé publique, dont les répercussions concernent également les entreprises et la société dans son ensemble. En France, le coût social du stress au travail est estimé entre 1,9 et 3 milliards d'euros par an selon l'Institut national de recherche et de sécurité (INRS). À l'échelle européenne, la Fondation de Dublin l'évalue à environ 20 milliards d'euros pour les quinze pays membres. Ces chiffres révèlent l'ampleur d'un phénomène qui reste parfois sous-estimé.

Le burn-out s'inscrit dans cette dynamique. Décrit pour la première fois dans les années 1970, il a depuis gagné en visibilité, au point d'être récemment intégré par l'Organisation mondiale de la santé (OMS) dans la Classification internationale des maladies (CIM-11), comme un phénomène lié au travail. Si sa reconnaissance comme maladie professionnelle n'est pas encore acquise en France, il n'en demeure pas moins une réalité préoccupante. Derrière ce terme se cachent des vécus marqués par l'épuisement profond, la perte de sens, le repli, ou encore un sentiment d'échec qui envahit peu à peu la sphère personnelle. Les entreprises, quant à elles, en perçoivent les effets à travers les arrêts répétés, le désengagement, les tensions internes ou la difficulté à fidéliser les équipes. Au-delà des coûts financiers, ce sont des trajectoires humaines qui se délitent.

Le burn-out, défini comme un état d'épuisement physique, mental et émotionnel résultant d'une implication prolongée dans un travail perçu comme exigeant et peu soutenant, est donc à la croisée de plusieurs champs : la santé publique, l'organisation du travail et les politiques sociales. Il renvoie à des choix collectifs en matière de gestion des ressources humaines, de reconnaissance professionnelle, mais aussi de protection sociale. Depuis plusieurs années, les pouvoirs publics tentent d'intégrer cette problématique dans des démarches plus larges de prévention des risques psychosociaux. Cependant, l'absence de consensus institutionnel autour de sa définition et de son inscription légale limite encore les actions concrètes et coordonnées.

Cette recherche s'inscrit dans un contexte où les enjeux économiques et sociaux de l'épuisement professionnel sont de plus en plus visibles, tant pour les individus que pour les structures. Elle s'appuie sur les outils de l'économiste, en mobilisant une base de données de grande ampleur, l'enquête Conditions de travail et Risques Psychosociaux (CT-RPS) 2016, et un modèle économétrique permettant de modéliser un phénomène de santé au travail. L'approche adoptée croise les dimensions individuelles, professionnelles et contextuelles afin d'identifier les profils les plus exposés à ce risque. Il s'agit ici de produire une lecture quantitative du phénomène, dans l'idée de contribuer à une meilleure compréhension de ses déterminants.

La problématique centrale de ce mémoire peut ainsi se formuler ainsi : quels sont les facteurs qui augmentent la probabilité de burn-out chez les actifs occupés, et comment les modéliser de manière rigoureuse pour construire un outil d'évaluation du risque individuel ? L'objectif est double : mieux comprendre les ressorts du burn-out, et proposer une base pour la mise en place d'outils de prévention plus ciblés, sous la forme d'une application d'auto-évaluation du risque.

Pour répondre à cette question, ce mémoire s'organise en quatre parties. La première revient sur les apports des travaux existants concernant les risques psychosociaux et le burn-out, en mobilisant les principaux modèles explicatifs. La seconde présente la base de données utilisée et les variables mobilisées. La troisième est consacrée à la méthodologie économétrique retenue. Enfin, la dernière partie expose les résultats de l'analyse et propose des pistes concrètes pour la prévention.

2 Revue de littérature

Bien que l'épuisement professionnel fasse l'objet de recherches depuis plusieurs décennies, la notion demeure difficile à cerner avec précision. Initialement étudiée dans des contextes spécifiques notamment les professions médicales, sociales ou éducatives elle s'observe aujourd'hui dans des environnements de travail très diversifiés. Cela soulève plusieurs interrogations : comment une même notion peut-elle s'appliquer à des situations aussi variées ? Quels facteurs communs permettent d'expliquer son apparition ? Et dans quelle mesure est-il possible d'agir pour prévenir cet épuisement professionnel ?

Cette revue de littérature se propose d'explorer ces questions en s'appuyant sur les principaux apports théoriques et empiriques disponibles. Elle vise à identifier les facteurs de risque les plus fréquemment associés au burn-out, dans la perspective de contribuer à l'élaboration d'un outil d'autoévaluation simple et rigoureux. Pour ce faire, elle s'organise en quatre temps : un retour sur la définition du burn-out ; une présentation des modèles explicatifs ; une synthèse des déterminants identifiés dans la littérature ; et enfin, une discussion des limites soulevées par les approches actuelles.

2.1 Définition complexe du burn-out

2.1.1 Les origines de la notion d'épuisement

Si le burn-out est aujourd'hui reconnu comme une problématique majeure de santé au travail, la notion d'épuisement moral ou existentiel auquel il renvoie s'enracine dans des représentations bien antérieures. Le terme anglais *burn out*, qui signifie littéralement se consumer ou brûler jusqu'à extinction, apparaît dès le XVII^e siècle. Il figure notamment dans *The Passionate Pilgrim* (1599), un recueil poétique attribué à William Shakespeare, où il est employé pour suggérer la perte d'intensité émotionnelle, l'usure intérieure, ou encore la fin d'une passion.

Cette image du feu qui s'éteint résonne plus concrètement au XX^e siècle dans le roman *A Burnt-Out Case* (1960) de Graham Greene. L'ouvrage met en scène un architecte célèbre, Querry, qui, après avoir connu le succès, se retire dans une léproserie au Congo, éprouvant un profond désintérêt pour sa profession et un désengagement affectif général. Le personnage, déconnecté de ses émotions et de son environnement, illustre plusieurs symptômes aujourd'hui associés au burn-out : l'effondrement de la motivation, la perte de sens, la lassitude extrême et le retrait

social. Si ce roman demeure une uvre de fiction, il traduit néanmoins une compréhension fine de l'épuisement psychique, bien avant son inscription dans les classifications médicales.

Ces références littéraires, bien qu'éloignées des cadres scientifiques actuels, mettent en lumière une réalité persistante : la souffrance liée à un engagement intense dans une activité exigeante n'est pas nouvelle. Ce qui a évolué, en revanche, c'est le cadre d'analyse et de reconnaissance de cette souffrance, désormais inscrit dans les transformations du travail salarié, les dynamiques organisationnelles contemporaines et la montée des risques psychosociaux.

2.1.2 Une définition médicale et multidimensionnelle

Sur le plan scientifique, l'épuisement professionnel est généralement défini comme un syndrome psychologique d'épuisement survenant dans un contexte de stress professionnel chronique, en particulier lorsque les ressources individuelles disponibles ne permettent plus de répondre aux exigences du poste. Il concerne souvent des personnes particulièrement investies dans leur travail, dont l'engagement initial se transforme progressivement en source de tension et de souffrance.

La définition la plus largement reprise est celle proposée par Christina Maslach et Susan Jackson (1981). Elles décrivent le burn-out comme un syndrome multidimensionnel composé de trois composantes étroitement liées. L'épuisement émotionnel désigne une fatigue intense, une sensation de saturation mentale, et une perte d'énergie qui affecte la capacité à s'engager dans le travail. La dépersonnalisation, quant à elle, se traduit par un retrait affectif et une forme de distance, voire d'indifférence, vis-à-vis des collègues, des usagers ou du contenu même de l'activité professionnelle. Enfin, la réduction de l'accomplissement personnel reflète une impression de ne plus être à la hauteur, une perte de confiance en ses compétences, et un sentiment croissant d'inefficacité.

Ce modèle a profondément influencé les travaux sur l'épuisement professionnel en proposant une lecture intégrée de ses manifestations. Il met en lumière un processus progressif qui peut s'installer sans que l'individu en prenne pleinement conscience.

2.1.3 Une vision plus large et systémique

D'autres auteurs ont enrichi cette approche en mettant en avant le rôle du contexte organisationnel dans l'émergence du burn-out. Wilmar Schaufeli et Dirk Enzmann (1998), notamment, insistent sur la dimension situationnelle du phénomène : le burn-out ne résulte pas d'une vulnérabilité individuelle mais d'une inadéquation prolongée entre les attentes professionnelles et les ressources disponibles pour y faire face. Il est alors perçu comme un processus d'usure, dans lequel les stratégies d'adaptation, initialement mises en place pour faire face à la pression, deviennent progressivement inefficaces, voire contre-productives.

Plusieurs auteurs proposent aujourd'hui une lecture plurielle du burn-out, en insistant sur la diversité de ses formes et de ses causes. D'un point de vue clinique, il s'agit d'un syndrome émotionnel et comportemental, qui se manifeste par une fatigue persistante, une irritabilité accrue, des troubles du sommeil ou encore une démotivation progressive.

D'autres travaux le décrivent comme un processus évolutif, qui s'installe progressivement : on passe souvent d'un investissement intense à une forme de désillusion, puis à un retrait affectif, voire à un effondrement psychique. Ce parcours n'est pas linéaire, mais il suit des étapes

caractéristiques. Sur le plan explicatif, l'épuisement professionnel résulte d'une combinaison de facteurs multiples, à la fois individuels (comme le perfectionnisme ou la faible estime de soi), relationnels (tensions, isolement, manque de reconnaissance), et structurels (surcharge de travail, faible autonomie, pression temporelle).

Enfin, certains chercheurs insistent sur le fait qu'il s'agit d'un phénomène systémique, qui reflète plus largement les logiques de performance, les modes de gestion et les valeurs dominantes de certaines organisations.

En définitive, le burn-out ne peut être enfermé dans une définition unique. Il émerge à l'intersection de l'engagement personnel et des contraintes imposées par le cadre professionnel, et exige une approche globale qui tienne compte à la fois des dimensions psychologiques, sociales et organisationnelles du travail.

2.2 Les modèles explicatifs du burn-out

La définition du burn-out en tant que syndrome d'épuisement professionnel ne suffit pas à en saisir toute la complexité. Pour mieux en comprendre les causes, les chercheurs ont proposé différents modèles explicatifs. Ces modèles aident à mieux comprendre ce qui provoque le burn-out, en prenant en compte différents facteurs : personnels, professionnels et sociaux. Cette section propose d'abord un panorama des principales théories du burn-out, avant de s'arrêter plus en détail sur les deux modèles qui serviront de cadre de référence pour la suite de ce travail.

2.2.1 Diverses approches théoriques

Les premières conceptualisations du burn-out remontent aux années 1970, dans des secteurs où l'engagement humain est fort, comme le soin, l'éducation ou le travail social. Ce sont des contextes où la relation à l'autre occupe une place centrale, où l'investissement affectif et moral est valorisé, mais aussi où les conditions de travail peuvent être précaires, les reconnaissances rares, et les marges de manœuvre faibles. En 1974, le psychologue Herbert Freudenberger publie un article dans le *Journal of Social Issues* dans lequel il décrit les symptômes d'épuisement observés chez les bénévoles d'un centre d'accueil pour toxicomanes à New York. Il parle de burn-out pour désigner cet état de fatigue physique et émotionnelle extrême, accompagné d'un sentiment de perte d'idéal et de réalité professionnelle. Il insiste sur un paradoxe qui restera central dans les approches ultérieures : ce sont souvent les individus les plus motivés, animés par une forte vocation, qui s'effondrent les premiers, à force de dévouement non reconnu.

Cette idée est développée par Cherniss en 1980, qui conçoit le burn-out comme un processus en trois temps : une période de stress professionnel intense, une phase de tension émotionnelle, puis un repli défensif. Ce dernier se manifeste par un retrait affectif, une forme de distance ou d'indifférence, visant à se protéger du décalage entre attentes et réalités du terrain. Il s'agit là d'un mécanisme de protection psychique face à un environnement perçu comme de moins en moins soutenant. Son modèle est basé sur l'observation de jeunes travailleurs sociaux fraîchement recrutés et rapidement confrontés à une charge émotionnelle intense sans réel accompagnement.

D'autres auteurs intègrent une dimension plus large, en reliant le burn-out aux transformations sociales contemporaines. Lauderdale (1982) s'inscrit dans une réflexion plus sociologique : selon lui, les mutations des sociétés modernes – perte des repères collectifs, affaiblissement des solidarités, intensification des rythmes de travail – ont modifié le rapport que les individus entre-

tiennent avec leur travail. Il identifie trois stades : la confusion, la frustration, puis le désarroi, traduisant une rupture progressive entre l'identité professionnelle et le sens de l'engagement. Il s'appuie notamment sur des observations en milieu hospitalier et administratif.

Dans les années 1980-1990, des modèles plus structurels émergent. En 1996, le modèle effort-récompense de Siegrist s'appuie sur les situations professionnelles marquées par une charge de travail importante, une responsabilité forte, et une reconnaissance faible voire inexistante. Ce déséquilibre est d'autant plus préjudiciable qu'il s'inscrit souvent dans des environnements compétitifs, hiérarchisés, où les salariés sont en quête de validation symbolique ou matérielle. Quand l'effort est perçu comme excessif au regard de ce qui est reçu en retour, le risque d'épuisement professionnel augmente. Ce modèle est aujourd'hui utilisé pour analyser les risques psychosociaux dans les grandes entreprises ou les métiers à forte exposition publique (enseignement, hôpital, etc.).

Dans une perspective psychologique, la théorie de la conservation des ressources, proposée par Hobfoll (1989), postule que le stress survient quand une personne sent que ses ressources matérielles, sociales ou émotionnelles sont menacées ou ne peuvent être renouvelées. Ce modèle trouve une résonance particulière dans les contextes où les salariés doivent constamment puiser dans leurs capacités d'adaptation sans pour autant bénéficier de temps de récupération ni de reconnaissance. L'épuisement professionnel est alors compris comme un processus d'usure provoqué par la perte progressive de ces ressources.

Enfin, Farber (1990) propose une typologie intéressante, qui distingue trois profils : les individus frénétiques, qui s'épuisent en poursuivant des objectifs trop exigeants ; les sous-stimulés, qui souffrent d'ennui ou d'un manque de sens ; et les épuisés, qui se décrochent après une longue période d'usure. Cette classification permet de rappeler que l'épuisement professionnel ne touche pas un seul type de salarié, mais peut concerner aussi bien les hyperactifs que ceux confrontés à une perte de motivation dans un environnement routinier.

Dans l'ensemble, ces modèles ont permis d'élargir la compréhension du burn-out, en introduisant des dimensions individuelles, structurelles et symboliques. Ils montrent que ce syndrome n'est pas réductible à une fragilité personnelle, mais qu'il est aussi le produit d'interactions complexes entre le sujet et son environnement de travail.

2.2.2 Une lecture psychosociale du burn-out

À partir de la fin des années 1970, l'approche du burn-out change de perspective : on ne se limite plus aux caractéristiques personnelles de l'individu, mais on s'intéresse aussi à l'environnement professionnel dans lequel il évolue. Cette évolution marque l'émergence des modèles interactionnistes, qui considèrent que le stress, puis l'épuisement professionnel, découlent d'un déséquilibre entre les exigences du travail et les ressources disponibles pour y faire face.

Parmi les modèles les plus influents, celui de Karasek (1979) constitue une avancée majeure. Il repose sur une articulation entre trois dimensions fondamentales :

La demande psychologique, qui désigne la charge de travail perçue, les exigences de performance, les pressions temporelles ou encore les interruptions fréquentes ;

La latitude décisionnelle, c'est-à-dire l'autonomie dont dispose le salarié pour organiser son travail, faire appel à ses compétences ou prendre des décisions ;

Le soutien social, ajouté par Theorell en 1990, qui reflète la qualité des relations avec les collègues et la hiérarchie.

Lorsque les exigences sont élevées et la latitude faible c'est le fameux *job strain* les effets délétères sur la santé mentale sont particulièrement marqués. Ce modèle a donné lieu à de nombreuses applications empiriques, notamment en épidémiologie du travail, et reste aujourd'hui un outil de référence pour évaluer les facteurs de risque psychosociaux.

Dans une autre approche, Christina Maslach et Michael Leiter (1997) proposent un modèle du burn-out, aujourd'hui largement reconnu dans la littérature. Leur travail repose sur l'observation de professionnels de la santé et de l'éducation, exposés à des tensions relationnelles et à un fort investissement affectif. Le burn-out s'y manifeste à travers trois composantes clés :

L'épuisement émotionnel, considéré comme le cur du syndrome, correspond à une sensation de fatigue constante, une perte d'énergie, et une saturation mentale face aux exigences du travail ;

La dépersonnalisation, ou retrait émotionnel, qui se traduit par une forme de distance ou de cynisme vis-à-vis des bénéficiaires de son activité (patients, élèves, clients) ;

La diminution de l'accomplissement personnel, qui renvoie à un sentiment d'inefficacité, de frustration, et de perte de motivation dans son rôle professionnel.

Ce modèle a donné naissance au *Maslach Burnout Inventory* (MBI), un questionnaire auto-administré qui reste la référence pour évaluer le niveau de burn-out. Il existe en plusieurs versions : le MBI-HSS (Human Services Survey) destiné aux professions de l'aide, le MBI-ES (Educators Survey) pour les enseignants, et le MBI-GS (General Survey) pour la population active en général. Chaque version mesure les trois dimensions via des items formulés sur une échelle de fréquence allant de jamais à tous les jours. Un score élevé d'épuisement ou de dépersonnalisation et un score faible d'accomplissement personnel indiquent un niveau de burn-out important.

Malgré ses nombreuses qualités, le MBI est parfois critiqué pour son manque d'adaptation interculturelle ou pour sa focalisation sur les dimensions individuelles, sans prise en compte directe de l'environnement organisationnel. Néanmoins, son influence reste centrale dans les recherches actuelles.

Ces deux modèles Karasek et Maslach constituent aujourd'hui les piliers théoriques de l'étude du burn-out. Ils offrent deux lectures complémentaires : l'une centrée sur les conditions de travail objectives et le déséquilibre structurel, l'autre sur le vécu subjectif de l'individu face à un investissement émotionnel insoutenable. Ensemble, ils permettent d'éclairer les mécanismes complexes de l'épuisement professionnel et d'ouvrir la voie à des pistes concrètes en matière de prévention.

2.3 Les principaux facteurs de risque du burn-out

Au-delà des définitions et des modèles explicatifs, la littérature scientifique s'accorde sur un point : l'épuisement professionnel ne survient jamais au hasard. Il résulte d'un enchaînement de facteurs qui, combinés, finissent par fragiliser l'individu. Ces facteurs peuvent être organisationnels, relationnels ou individuels, et leur poids respectif varie selon les contextes professionnels.

2.3.1 Les déterminants structurels : la pression du travail et ses effets

Le développement du burn-out s'ancre d'abord dans un contexte professionnel où les exigences du travail dépassent, progressivement ou brutalement, les ressources disponibles de l'individu. C'est précisément ce déséquilibre, au cur des facteurs psychosociaux, qui constitue le terreau principal de l'épuisement professionnel.

Parmi les premiers éléments en cause figure la surcharge de travail, devenue presque banale dans de nombreux métiers. Qu'il s'agisse d'un rythme soutenu, d'objectifs irréalistes ou d'une accumulation de responsabilités, la fatigue s'installe lorsque le salarié n'a plus le temps de récupérer. Mais, à l'inverse, une sous-charge chronique aussi appelée *bore-out* peut elle aussi générer de la souffrance, en entretenant un sentiment d'inutilité et de perte de sens.

Un autre facteur souvent sous-estimé est la charge émotionnelle. Certains métiers, notamment dans les secteurs du soin, de l'éducation ou du social, impliquent une exposition répétée à la détresse d'autrui. Cette exposition, combinée à l'obligation de maîtriser ses propres émotions, épuise les ressources internes à petit feu.

Les conditions matérielles et organisationnelles de travail influencent également le risque de burn-out. Horaires atypiques, travail de nuit, bureaux ouverts bruyants, télétravail mal encadré. Autant d'éléments qui peuvent altérer la concentration, perturber le sommeil ou isoler socialement. À cela s'ajoutent les effets délétères des réorganisations à répétition, du management par objectifs ou du manque de visibilité sur l'avenir professionnel.

Le manque de reconnaissance constitue également un facteur de risque majeur. Lorsque les efforts déployés ne sont ni remarqués ni valorisés, le sentiment d'injustice s'installe. Cela est d'autant plus vrai dans des structures marquées par des formes d'injustice organisationnelle : favoritisme, absence de participation aux décisions, pratiques managériales autoritaires.

Un dernier pilier, fondamental, est celui du soutien social. Le sentiment d'être entouré, compris, écouté, peut agir comme une véritable protection face au stress. À l'inverse, l'isolement au travail ou les tensions interpersonnelles amplifient les effets négatifs du stress chronique. Le climat collectif, la solidarité entre collègues, mais aussi la posture de la hiérarchie, jouent un rôle déterminant.

2.3.2 Les facteurs individuels

Si les conditions de travail jouent un rôle central dans l'apparition de l'épuisement professionnel, tous les individus n'y sont pas exposés de la même manière. Certaines caractéristiques personnelles peuvent renforcer la vulnérabilité face aux risques psychosociaux, en influençant la manière dont on perçoit, vit et affronte les contraintes professionnelles.

Les études montrent que le sexe constitue une variable importante. Les femmes déclarent plus souvent un état de souffrance lié au travail. Elles sont aussi majoritaires dans les secteurs les plus exposés au stress émotionnel (santé, éducation, social). Leur épuisement prend souvent une forme émotionnelle plus marquée, là où les hommes tendent à développer une forme de retrait ou de cynisme. Cela n'implique pas une fragilité intrinsèque, mais traduit des contextes professionnels et des attentes genrées bien distinctes.

De même, l'âge et l'expérience peuvent moduler le risque. Les jeunes travailleurs, souvent très investis mais encore peu armés face aux tensions, sont particulièrement vulnérables dans

les premières années de leur carrière. À l'inverse, l'expérience acquise avec le temps semble offrir une forme de protection, bien que certains contextes (changement de poste, manque de reconnaissance, instabilité) puissent fragiliser les salariés plus âgés.

Au-delà du travail, la situation familiale peut aussi faire tampon ou au contraire accentuer la pression. Une vie familiale équilibrée peut offrir un soutien émotionnel et une forme de rééquilibrage entre sphères personnelle et professionnelle. À l'inverse, l'isolement ou les conflits dans la sphère privée peuvent aggraver l'épuisement.

Enfin, certaines dimensions psychologiques et comportementales pèsent dans le processus de burn-out. Le perfectionnisme, par exemple, pousse à des exigences irréalistes et génère une insatisfaction permanente. De même, la tendance à attribuer ce qui nous arrive à des facteurs extérieurs est liée à un sentiment d'impuissance face aux difficultés professionnelles.

Les traits de personnalité évalués par le modèle des *Big Five* confirment ce lien : un score élevé en névrosisme (instabilité émotionnelle) est fortement associé au burn-out. À l'inverse, des niveaux élevés de conscience professionnelle, d'amabilité ou d'extraversion peuvent jouer un rôle protecteur, même si certaines formes d'exigence ou de surengagement peuvent aussi se retourner contre la personne.

2.4 Limites et zones d'ombre des approches actuelles

2.4.1 Une notion floue

Le premier point de difficulté réside dans la définition même du burn-out. Si le consensus existe autour de certaines dimensions épuisement, désengagement, perte de sens les frontières du syndrome restent poreuses. L'épuisement professionnel est parfois confondu avec la dépression, le stress chronique, l'anxiété, ou même le simple mal-être professionnel. Cette absence de critères diagnostiques clairs explique en partie pourquoi il n'est toujours pas reconnu comme une entité pathologique dans les classifications internationales comme le DSM-5 (*Diagnostic and Statistical Manual of Mental Disorders, 5th Edition*).

Par ailleurs, la variété des questionnaires et des outils d'évaluation ajoute à la confusion. Les seuils sont souvent arbitraires, les résultats variables selon les contextes culturels, et la distinction entre souffrance passagère et épuisement clinique reste difficile à établir.

2.4.2 Des modèles utiles mais incomplets

Les modèles théoriques, bien qu'éclairants, présentent eux aussi certaines limites. Beaucoup s'appuient sur des situations professionnelles particulières (notamment les métiers du soin), ce qui peut limiter leur portée générale. De plus, nombre de ces modèles se concentrent sur une seule dimension (charge de travail, reconnaissance, autonomie), alors que l'épuisement professionnel se développe souvent dans des contextes où plusieurs facteurs se conjuguent.

Le modèle de Karasek, par exemple, bien qu'incontournable, reste centré sur deux ou trois dimensions clés, sans intégrer suffisamment la dynamique émotionnelle ou la subjectivité de l'individu. Le modèle de Maslach, quant à lui, se heurte à certaines critiques méthodologiques, notamment concernant la validité psychométrique de certaines échelles.

2.4.3 Une problématique liée à la société actuelle

Enfin, on ne peut ignorer la dimension plus large du phénomène. Le burn-out ne peut être réduit à une problématique purement individuelle ou professionnelle. Il s'inscrit dans un contexte sociétal marqué par l'accélération des rythmes, l'éclatement des collectifs de travail, l'injonction à la performance et la mise en concurrence des individus. Ces mutations, analysées par des auteurs comme Hartmut Rosa ou Christophe Dejours, dépassent largement le cadre du bureau ou de l'entreprise.

À force de chercher des solutions dans l'individu mieux gérer son stress, apprendre se détendre on risque de faire l'impasse sur les transformations structurelles nécessaires. La prévention ne peut être seulement individuelle : elle doit aussi être organisationnelle, collective et politique.

En définitive, le burn-out apparaît comme une réalité complexe, à la fois individuelle, professionnelle et sociétale. Derrière les modèles théoriques, aussi éclairants soient-ils, se cachent des vécus singuliers, des contextes de travail variés et des trajectoires personnelles parfois invisibles dans les statistiques. C'est justement cette tension entre théorie et expérience vécue que nous allons désormais explorer à travers les données issues de l'enquête *Conditions de travail et Risques Psychosociaux* (CT-RPS) 2016. L'objectif est de mieux cerner les profils les plus exposés, les environnements professionnels les plus à risque, et d'objectiver, autant que possible, les déterminants du burn-out à travers une approche quantitative rigoureuse.

3 Étude empirique

3.1 Source des données, méthode de collecte et échantillon

3.1.1 Origine et caractéristiques de l'enquête mobilisée

Ce travail repose sur l'exploitation des données issues de l'enquête *Conditions de travail et Risques Psychosociaux* (CT-RPS), mise en place par la Direction de l'Animation de la Recherche, des Études et des Statistiques (Dares), en collaboration avec la Direction de la Recherche, des Études, de l'Évaluation et des Statistiques (Drees) et l'Institut national de la statistique et des études économiques (Insee). Ce dispositif s'inscrit dans le cadre du suivi statistique des risques psychosociaux initié par le Collège d'expertise entre 2009 et 2010. Il a pour objectif d'analyser de manière approfondie les conditions d'exercice du travail, les formes d'exposition aux risques psychosociaux et leurs effets sur la santé des travailleurs.

L'enquête CT-RPS succède à l'enquête *Conditions de travail*, tout en élargissant son périmètre à des dimensions plus subjectives telles que le ressenti au travail, les parcours professionnels, et la santé perçue. L'édition 2016 s'inscrit dans un dispositif longitudinal, amorcé en 2013, visant à suivre un même ensemble d'individus sur plusieurs années afin d'étudier l'évolution de leurs conditions de travail et de leur état de santé.

L'enquête se divise en trois volets : un volet Employeurs, un volet Individus, et un volet Actifs occupés, qui constitue la source principale de cette étude. Ce dernier cible les personnes en emploi lors des deux éditions (2013 et 2016), et permet une analyse dynamique des trajectoires professionnelles. Le panel initial comprend 22 852 individus, dont 2 970 sont devenus inactifs au moment de la seconde vague. L'étude se concentre uniquement sur les actifs occupés en 2016, c'est-à-dire les personnes déclarant exercer une activité professionnelle rémunérée au

moment de l'enquête. Ce ciblage permet d'analyser une population directement concernée par les expositions professionnelles susceptibles de favoriser l'apparition d'un burn-out.

L'échantillon est représentatif des actifs occupés âgés de 15 ans ou plus vivant en France métropolitaine. Il a été construit selon un tirage aléatoire stratifié, prenant en compte des critères tels que l'âge, le sexe, le secteur d'activité, la catégorie socioprofessionnelle ou encore le niveau de diplôme. Il se compose de deux sous-populations :

- les individus déjà interrogés en 2013, constituant le panel,
- et des entrants sélectionnés en 2014 afin de garantir la représentativité de la population active en 2016.

Cette double composition permet à la fois d'assurer la représentativité nationale et de suivre l'évolution des parcours dans le temps. Le recours à ce type de données longitudinales est particulièrement utile pour étudier un phénomène comme l'épuisement professionnel, car il permet de relier les conditions de travail passées à l'état de santé perçu plus tard. En suivant les mêmes personnes dans la durée, on peut ainsi mieux comprendre les effets différés ou cumulatifs de certaines expositions professionnelles.

La collecte des données a été réalisée par des enquêteurs de l'Insee en face à face au domicile des enquêtés, à l'aide d'un questionnaire informatisé. Pour les thématiques jugées sensibles, telles que la santé mentale, les violences ou les conflits au travail, un auto-questionnaire papier a été proposé. Ce mode de passation mixte permet de préserver la confidentialité des réponses et de limiter les biais de désirabilité sociale, qui peuvent apparaître lorsque les individus sont interrogés sur des sujets personnels en présence d'un enquêteur.

3.1.2 Constitution de l'échantillon final

À partir de la base brute issue du volet Actifs occupés de l'enquête CT-RPS 2016, plusieurs étapes de filtrage ont été appliquées afin de constituer un échantillon exploitable pour l'analyse statistique.

Une première version du jeu de données comptait 19 882 individus et 552 variables. Un premier filtrage a consisté à supprimer les variables non pertinentes (administratives, hors sujet, ou fortement manquantes), ce qui a permis de ramener la base à 133 variables pour 19 591 individus.

Un second traitement a concerné la variable revenu mensuel net, jugée essentielle pour l'analyse. Les individus présentant des valeurs manquantes ou aberrantes sur cette variable ont été exclus, ce qui a réduit l'échantillon à 15 611 individus. Le revenu a ensuite été discrétisé en tranches, ajoutant une variable catégorielle au jeu de données (134 variables au total).

Concernant l'âge, les observations extrêmes ont été supprimées afin de recentrer l'analyse sur la population active dite centrale. Seules les personnes âgées de 24 à 64 ans ont été conservées, ramenant l'échantillon à 15 407 individus et 135 variables. Cette restriction vise à éliminer les cas atypiques tout en conservant une large représentativité.

3.2 Justification du choix méthodologique et construction de la variable d'épuisement professionnel

Ce mémoire vise à modéliser le niveau d'épuisement professionnel à partir des données de l'enquête CT-RPS 2016, dans la perspective de concevoir un outil d'auto-évaluation du risque

psychosocial. Cela suppose de définir une variable dépendante fidèle à la réalité du burn-out, fondée sur un cadre théorique reconnu.

Deux approches sont mobilisées dans la littérature : le modèle de Karasek, centré sur les caractéristiques de l'environnement de travail, et le *Maslach Burnout Inventory* (MBI), orienté vers les manifestations psychologiques du syndrome. Le premier permet d'identifier des situations à risque à travers la charge mentale, l'autonomie et le soutien social, mais il ne permet pas de mesurer directement l'état d'épuisement. Le second, conçu pour évaluer le burn-out, repose sur trois dimensions cliniques : l'épuisement émotionnel, la déshumanisation, et la perte d'accomplissement personnel.

Le choix de retenir le MBI comme base de construction repose à la fois sur sa capacité à décrire le vécu subjectif de l'individu, et sur sa compatibilité avec la finalité pratique du projet : produire une évaluation personnalisée du risque à destination des actifs. Dans cette optique, les indicateurs centrés sur l'expérience vécue apparaissent plus adaptés qu'un modèle purement organisationnel.

3.2.1 Construction des trois dimensions du *Maslach Burnout Inventory*

Le MBI comprend 22 items répartis en trois dimensions : 9 pour l'épuisement émotionnel, 5 pour la déshumanisation et 8 pour l'accomplissement personnel. À partir des données de l'enquête CT-RPS 2016, des variables ont été sélectionnées pour leur proximité conceptuelle avec ces items. Chaque variable a été recodée en binaire (1 = exposition, 0 = non exposition), en excluant les non-réponses ou les modalités non exploitables.

Les trois scores ont été calculés par somme stricte des indicateurs associés, sans tolérance aux valeurs manquantes, afin d'assurer la cohérence des profils retenus pour l'analyse.

Construction du score d'épuisement émotionnel :

Le score d'épuisement émotionnel regroupe neuf dimensions inspirées du Maslach Burnout Inventory (MBI), chacune traduisant une forme de fatigue physique, mentale ou émotionnelle liée au travail. Pour chaque item, un indicateur binaire (0 = non exposition, 1 = exposition) a été construit à partir des données de l'enquête CT-RPS 2016.

1. *Je me sens émotionnellement vidé(e)* : Cet item est approché par une variable mesurant si l'individu se sent fatigué presque tous les jours. L'indicateur vaut 1 en cas de fatigue fréquente.
2. *Je suis à bout à la fin de la journée* : L'épuisement en fin de journée est évalué par une question sur la sensation d'être faible ou facilement épuisé. Codage direct en 0/1.
3. *Je me sens fatigué(e) le matin* : Cet item est approché à partir de la fréquence à laquelle la personne se sent en forme au réveil. Un état de fatigue matinale est codé 1.
4. *Travailler avec des gens me demande beaucoup d'effort* : L'indicateur est construit à partir de trois situations : devoir calmer des personnes, gérer des conflits, ou faire face à la détresse d'autrui. L'indicateur vaut 1 si au moins deux situations sont présentes.
5. *Je sens que je vais craquer* : Ce ressenti est approché par l'exposition à une forte pression mentale (travail sous tension, surcharge cognitive, ruminations, imprévus). L'indicateur vaut 1 si trois de ces facteurs sont cumulés.
6. *Je me sens frustré(e)* : Représenté par un indicateur combinant des situations de conflit moral : tâches désapprouvées, dissonance émotionnelle, ou actes contraires à ses valeurs.

Codé à 1 si deux situations sont rapportées.

7. *Je travaille trop dur* : Approché à partir de contraintes temporelles et psychologiques : pression constante, heures supplémentaires, et envahissement de la sphère privée. L'indicateur vaut 1 si deux éléments sont présents.
8. *Le contact direct me stresse* : Cet item est représenté par la combinaison d'un contact régulier avec le public et d'une exposition à des tensions émotionnelles fréquentes. L'indicateur est activé si les deux conditions sont réunies.
9. *Je suis au bout du rouleau* : Représenté par un indicateur croisant surcharge physique (tension corporelle) et surcharge mentale. L'indicateur vaut 1 en cas de cumul des deux dimensions.

L'ensemble de ces indicateurs binaires est agrégé par une somme stricte, sans tolérance de valeurs manquantes. Le score obtenu varie entre 0 et 9.

Construction du score de déshumanisation :

Le score de déshumanisation repose sur cinq dimensions issues du *Maslach Burnout Inventory*. Il reflète un détachement émotionnel, une perte d'empathie ou une rupture dans la relation à autrui dans le cadre professionnel. Les indicateurs retenus captent des formes d'usure morale, de désengagement ou de distance affective vis-à-vis des bénéficiaires, collègues ou usagers.

1. *Je traite les autres comme des objets* : Cette dimension est approchée à partir de situations où la personne déclare avoir dû accomplir des tâches dégradantes, traiter injustement des individus, ou imposer une contrainte à autrui. L'indicateur est activé si au moins deux de ces situations sont rapportées.
2. *Je suis devenu(e) insensible aux autres* : L'insensibilité émotionnelle est captée par la déclaration d'une perte d'intérêt ou de plaisir dans les activités récentes. Cette absence d'élan affectif est interprétée ici comme un désengagement relationnel. L'indicateur est codé à 1 dans ce cas.
3. *Ce travail m'endurcit émotionnellement* : Cette dimension correspond à des situations de tension morale, telles que mentir à des usagers ou collègues, effectuer des tâches désapprouvées ou contraires à ses valeurs, ou encore traiter injustement. L'indicateur est codé à 1 si au moins deux de ces tensions sont rapportées.
4. *Je me fiche des bénéficiaires ou des clients* : Cette attitude de détachement est approchée à partir de comportements comme le fait de mentir, de prendre des risques pour autrui ou d'exprimer une forme d'indifférence dans la relation de travail. L'indicateur est activé si deux de ces situations sont présentes.
5. *Je suis tenu(e) responsable des problèmes des autres* : Cet item reflète une mise en cause injustifiée. Il est approché par un indicateur regroupant des expériences de reproches fréquents, de critiques publiques ou d'empêchement de s'exprimer dans le cadre professionnel. L'indicateur est activé si au moins deux de ces situations sont déclarées.

La somme stricte des cinq indicateurs binaires permet de calculer le score total de déshumanisation, compris entre 0 et 5.

Construction du score d'accomplissement personnel :

Le score d'accomplissement personnel regroupe sept dimensions issues du *Maslach Burnout Inventory*. Il reflète le sentiment de compétence, d'utilité sociale, de reconnaissance au travail et de stabilité émotionnelle. Les indicateurs construits visent à identifier les individus qui perçoivent leur activité professionnelle comme valorisante, stimulante et cohérente avec leurs valeurs.

1. *Je comprends facilement les autres* : Cette dimension est approchée par la combinaison de deux indicateurs : le sentiment d'appartenance à une équipe et la capacité à apaiser les tensions dans les interactions. L'indicateur est activé lorsque ces deux conditions sont réunies.
2. *J'aide efficacement les personnes dont j'ai la charge* : Ce sentiment est représenté par la fierté du travail accompli, la perception d'apporter une aide utile et la coopération avec les collègues. L'indicateur est codé à 1 si deux de ces trois éléments sont présents.
3. *J'ai l'impression de faire quelque chose d'utile* : Cette dimension est captée par une question directe sur le sentiment d'utilité dans le travail quotidien. L'indicateur prend la valeur 1 si l'utilité est perçue de manière fréquente.
4. *Je me sens plein(e) d'énergie* : La vitalité professionnelle est approchée par la fréquence à laquelle l'individu se sent énergique et vigoureux. L'indicateur est activé en cas de ressenti fréquent de cette énergie.
5. *Le contact avec les autres me dynamise* : Cette dimension est évaluée par la combinaison entre un contact direct avec les usagers ou le public et la sensation d'être de bonne humeur. L'indicateur est activé lorsque ces deux conditions sont réunies.
6. *J'ai le sentiment d'avoir accompli quelque chose de valeur* : L'indicateur est construit à partir de trois éléments : le sentiment de travail bien fait, l'aide perçue comme utile et l'appartenance à une équipe. Il est activé si au moins deux de ces éléments sont déclarés.
7. *Je gère calmement les situations difficiles* : Cette stabilité émotionnelle est approchée par la capacité à désamorcer des tensions, à faire face aux conflits, et à se sentir détendu. L'indicateur est activé si deux de ces comportements sont rapportés.

La somme stricte des sept indicateurs binaires permet de calculer le score total d'accomplissement personnel, compris entre 0 et 7.

À partir des variables explicatives retenues et préalablement recodées, nous avons calculé des statistiques descriptives simples (moyenne et écart-type) afin de mieux caractériser la population incluse dans le modèle. Le tableau ci-dessous présente les principales dimensions individuelles, professionnelles et psychosociales mobilisées dans l'analyse. Il permet de situer les répondants en termes d'âge, de situation socioprofessionnelle, de conditions de travail et de ressenti, avant toute modélisation du risque d'épuisement professionnel.

TABLE 1 – Statistiques descriptives des variables explicatives retenues

Variable	Moyenne	Écart-type
Âge (en années)	45,06	9,35
Sexe (1 = femme)	0,57	0,50
Niveau de diplôme (0 à 3)	1,64	1,02
Type d'emploi (1 à 7)	5,93	0,38
Revenu mensuel net (€)	1975,20	875,17
Équilibre vie pro / perso (1 = bon)	0,83	0,37
Prévisibilité des horaires (1 = élevée)	1,21	0,61
Prise d'initiatives requise	0,81	0,39
Peut mettre en uvre ses idées (1 = oui)	0,64	0,48
Peut intervenir sur la charge de travail	0,28	0,45
Soutien social (1 = oui)	0,94	0,25
Événement marquant (1 = oui)	0,42	0,49
Tâches inutiles ou dégradantes (1 = oui)	0,06	0,23
Moqueries ou blagues blessantes (1 = oui)	0,06	0,23
Ennui dans le travail (1 = fréquent)	0,08	0,26
Aide des collègues (1 = oui)	0,89	0,31
Contact pro hors horaires (1 = oui)	0,20	0,40
Confiance dans les informations (03)	2,21	0,85
Désaccord avec la hiérarchie (03)	0,93	0,72
Bien-être général (1 = bien)	0,62	0,49
Tensions hiérarchiques (1 = oui)	0,31	0,46

L'âge moyen des individus est de 45 ans, avec un écart-type de 9,35 ans. La variable *sexe* indique une légère surreprésentation des femmes (moyenne de 0,57). Le niveau de diplôme est relativement élevé (moyenne de 1,64 sur une échelle de 0 à 3), et la majorité de l'échantillon est en emploi permanent (type d'emploi moyen de 5,93 sur 7).

Le revenu mensuel net moyen s'élève à environ 1 975 €, avec une dispersion importante (écart-type de 875 €). L'équilibre entre vie professionnelle et vie personnelle est globalement jugé satisfaisant (moyenne de 0,83), tout comme le bien-être général (0,62).

Les dimensions relatives à l'autonomie au travail, comme la prévisibilité des horaires (1,21), la nécessité de prendre des initiatives (0,81), ou la capacité à mettre en uvre ses idées (0,64), révèlent des conditions moyennement favorables. Toutefois, la possibilité d'intervenir sur la charge de travail est plus restreinte (0,28).

Les indicateurs de soutien social sont majoritairement positifs, avec des moyennes élevées pour le soutien perçu (0,94) et l'aide des collègues (0,89). En revanche, certaines situations de tensions sont rapportées : près de 31 % des répondants déclarent vivre des tensions hiérarchiques fréquentes, et la confiance dans les informations transmises par la hiérarchie atteint en moyenne 2,21 sur 3.

Enfin, certaines variables signalent la présence de facteurs de vulnérabilité : 42 % des répondants déclarent avoir vécu un événement marquant, et environ 6 % ont subi des moqueries ou des tâches perçues comme dégradantes.

Ces statistiques descriptives permettent de mieux cerner les profils à risque et les conditions associées à un niveau élevé d'épuisement professionnel. Elles justifient économétriquement leur inclusion dans le modèle explicatif.


3.2.2 Construction du score global d'épuisement professionnel

Un score global de burn-out a été calculé en additionnant les trois scores construits précédemment : épuisement émotionnel, déshumanisation et accomplissement personnel. Étant donné que ce dernier évolue en sens inverse des deux autres (un score élevé reflétant une bonne santé psychologique), il a été inversé afin de garantir la cohérence du score final.

$$\text{score_burnout} = \text{score_epuisement} + \text{score_deshumanisation} + (8 - \text{score_accomplissement})$$

Le score global de l'épuisement professionnel n'ayant pu être calculé qu'en présence d'informations complètes sur les trois dimensions, seules les observations sans données manquantes ont été conservées (N = 11 059), un échantillon encore suffisamment large pour garantir la robustesse des analyses sans recourir à une imputation potentiellement biaisée.

Figure 1 : Répartition des niveaux d'épuisement professionnel dans l'échantillon (0 à 22)



Ce score théorique, compris entre 0 et 22, permet d'évaluer de manière synthétique le niveau d'épuisement professionnel d'un individu, dans une logique cumulative cohérente avec le modèle du *Maslach Burnout Inventory*.

Le score global de burn-out, obtenu par addition des trois scores dimensionnels (épuisement, déshumanisation, accomplissement inversé), présente une distribution asymétrique à droite. La majorité des individus se situe entre 3 et 7, avec une moyenne de 5,8 sur 22. Cette forme confirme que les niveaux élevés d'épuisement professionnel sont rares, mais bien présents dans la population. La courbe permet également de valider le bon étalement de l'indice, garantissant sa capacité discriminante.

3.2.3 Transformation du score en variable binaire

Afin d'étudier économétriquement les déterminants de l'épuisement professionnel, nous avons transformé le score global de burn-out en une variable binaire, permettant d'identifier les individus présentant un niveau élevé de symptômes. Plusieurs seuils ont été testés, notamment la médiane (score supérieur à 5) ou le 1er quartile, mais c'est le seuil du troisième quartile, soit un score strictement supérieur à 8, qui a été retenu.

Ce choix repose sur plusieurs arguments :

- Il permet de cibler les formes sévères d'épuisement professionnel, en cohérence avec la littérature épidémiologique qui estime la prévalence entre 10,
- Il renforce la robustesse du modèle en limitant les faux positifs.
- Il maximise la capacité discriminante de la variable, en se concentrant sur les cas les plus préoccupants.

La variable binaire épuisement professionnel prend donc la valeur 1 si l'individu présente un score global strictement supérieur à 8, et 0 sinon. Cette transformation conserve 15 407 individus ayant des données complètes sur les trois dimensions du *Maslach Burnout Inventory*. Parmi eux, 2 180 (soit 14,1,%) sont classés en situation de burn-out élevé. Cette répartition, marquée par une faible proportion de cas positifs, reflète la rareté relative des formes sévères de burn-out dans la population active. Elle justifie le choix d'un seuil élevé pour identifier les individus les plus à risque, tout en appelant à la prudence dans l'estimation du modèle en raison du déséquilibre entre les classes.

3.3 Choix du modèle économétrique : régression logistique binaire

3.3.1 Spécification du modèle

L'objectif est de modéliser la probabilité qu'un individu présente un niveau élevé d'épuisement professionnel. La variable dépendante, notée y_i , prend la valeur 1 si le score global dépasse un seuil critique (défini empiriquement), et 0 dans le cas contraire. Cette structure binaire justifie l'usage d'un modèle logit.

Ce modèle est particulièrement adapté pour plusieurs raisons :

- La variable à expliquer est dichotomique, ce qui rend inopérant le recours aux modèles linéaires classiques.
- Il garantit des probabilités comprises entre 0 et 1, interprétables directement comme des risques individuels.
- Il permet une lecture intuitive des effets via les *odds ratios*, ce qui le rend adapté à la fois à l'analyse scientifique et à une restitution vulgarisée dans une interface utilisateur.

Dans le cadre d'une formulation à variable latente, on suppose l'existence d'un score continu non observé y_i^* représentant le niveau latent d'épuisement professionnel :

$$y_i^* = X_i\beta + \varepsilon_i$$

où :

- X_i est le vecteur des variables explicatives,
- β est le vecteur des coefficients à estimer,
- ε_i est le terme d'erreur, supposé suivre une loi logistique standard.

La variable observée y_i est alors définie par :

$$y_i = \begin{cases} 1 & \text{si } y_i^* > 0 \\ 0 & \text{sinon} \end{cases}$$

Ce modèle implique que la probabilité conditionnelle de survenue d'un burn-out sévère s'écrit comme suit :

$$P(y_i = 1 | X_i) = \frac{1}{1 + \exp(-X_i\beta)}$$

L'interprétation des coefficients estimés repose sur les *odds ratios*, obtenus par exponentiation des β . Un *odds ratio* supérieur à 1 indique que la variable augmente la probabilité d'épuisement professionnel, tandis qu'un ratio inférieur à 1 suggère un effet protecteur.

Le modèle a été estimé sur un échantillon de 12 173 individus pour lesquels des données complètes étaient disponibles sur les variables sélectionnées. Un travail préparatoire conséquent a été réalisé en amont : élimination des non-réponses, recodage des modalités incohérentes, harmonisation des échelles de réponse, et création de variables indicatrices lorsque cela était nécessaire. Toutes les variables explicatives ont été structurées de manière rigoureuse afin d'assurer la cohérence de l'estimation et l'interprétation des coefficients.

Ce choix méthodologique poursuit une double finalité. Sur le plan explicatif, il vise à identifier les déterminants les plus fortement associés à un niveau élevé d'épuisement psychologique, en mobilisant un cadre économétrique rigoureux. Sur le plan préventif, le modèle est intégré à une application interactive, permettant à chaque utilisateur d'obtenir une estimation personnalisée de son niveau de risque. Ce dispositif, fondé sur une démarche statistique transparente et reproductible, a vocation à contribuer à la sensibilisation aux risques psychosociaux dans le monde professionnel.

3.3.2 Sélection des variables explicatives

Dans le but de modéliser économétriquement la probabilité d'un niveau élevé d'épuisement professionnel, une sélection rigoureuse des variables explicatives a été opérée. Ce choix repose sur trois critères complémentaires : leur ancrage théorique dans la littérature sur les risques psychosociaux, leur pertinence empirique au regard des premières analyses descriptives, et leur qualité statistique (faible taux de non-réponse, modalités bien définies, distribution équilibrée).

Les variables retenues couvrent cinq grands axes :

- Caractéristiques sociodémographiques : genre (femme/homme), âge (en années), niveau de diplôme (quatre niveaux), niveau de revenu (tranches mensuelles nettes).
- Conditions d'emploi et de travail : équilibre entre vie professionnelle et personnelle, degré de prévisibilité des horaires, capacité à prendre des initiatives, possibilité de mettre ses idées en pratique, intervention sur la charge de travail.
- Relations professionnelles : tensions avec la hiérarchie, confiance dans les informations transmises par les supérieurs, désaccords sur la manière de faire son travail, aide reçue des collègues.

- Soutien social et événements marquants : présence d'un soutien moral, exposition récente à un événement familial difficile, perception du bien-être au travail.
- Ressenti professionnel : exposition à des comportements hostiles (tâches inutiles, moqueries, dévalorisation), ennui professionnel.

Certaines variables catégorielles ont été transformées en variables indicatrices, comme le type de contrat ou les tranches de revenu, en excluant la modalité de référence. L'ensemble des variables a été nettoyé, recodé et harmonisé pour garantir une interprétation cohérente dans le modèle. Les fréquences et modalités détaillées sont consultables en annexe.

4 Résultats empiriques et discussions

4.1 Modélisation du risque d'épuisement professionnel

4.1.1 Estimation du modèle logit

Dans le but de modéliser économétriquement la probabilité d'un niveau élevé d'épuisement professionnel, une sélection rigoureuse des variables explicatives a été opérée à partir de la base CT-RPS 2016. Cette sélection s'est fondée sur trois critères complémentaires et interdépendants.

Tout d'abord, chaque variable a été choisie pour son ancrage théorique solide dans la littérature sur les risques psychosociaux et le burn-out. Ensuite, les premières analyses descriptives menées sur la base ont permis de vérifier la pertinence empirique des variables pressenties. Les variables les plus différenciantes entre les niveaux de score global, celles dont la distribution est suffisamment discriminante, ont été privilégiées. Celles présentant un fort taux de non-réponse, une absence de variabilité ou une ambiguïté de codage ont été écartées ou regroupées. Enfin, des critères statistiques ont guidé le traitement final des variables. Les modalités ont été recodées de manière à éviter toute colinéarité forte ou domination d'une modalité sur les autres. Les variables catégorielles à plus de deux modalités ont été transformées en variables indicatrices en excluant systématiquement une modalité de référence pour permettre l'identification du modèle.

Au final, les variables retenues s'organisent autour de cinq axes thématiques principaux :

- **Caractéristiques sociodémographiques** : le sexe (binaire femme/homme), l'âge (variable continue), le niveau de diplôme (quatre niveaux ordinalisés), et le revenu mensuel net (regroupé en cinq tranches, traitées par dummies).
- **Conditions d'emploi et de travail** : un indicateur subjectif de l'équilibre vie professionnelle/vie personnelle, la prévisibilité des horaires (échelle de 1 à 4), la possibilité de prendre des initiatives, la mise en uvre des idées, et la marge de manuvre sur la charge de travail (trois dernières variables recodées de façon binaire).
- **Relations professionnelles** : l'existence de tensions avec la hiérarchie (binaire), le degré de confiance dans les informations reçues (échelle de 0 à 3), la fréquence des désaccords sur le travail (échelle ordinale de 0 à 3), et l'aide reçue des collègues (variable binaire).
- **Soutien social et vécu personnel** : le soutien social perçu (binaire), l'exposition à un événement familial marquant récent (binaire), et la perception subjective du bien-être global (binaire).
- **Ressenti au travail** : trois variables renseignant l'exposition à des comportements hostiles (tâches inutiles, moqueries, empêchement de s'exprimer), ainsi qu'un indicateur d'ennui professionnel. Ces variables ont été recodées en indicateurs binaires.

TABLE 2 – Effets des variables explicatives sur la probabilité d'épuisement professionnel (modèle logit binaire)

	Variable	OR	p-valeur
<i>Genre</i>			
	Femme (réf.)		
	Homme	2.16***	< 0.001
<i>Âge et diplôme</i>			
	Âge (années)	1.002	0.689
	Diplôme (niveau)	1.16***	< 0.001
<i>Conditions de travail</i>			
	Horaires prévisibles	1.13*	0.018
	Équilibre vie pro/perso	0.48***	< 0.001
	Initiative au travail	1.83***	< 0.001
	Mise en uvre d'idées	0.76***	< 0.001
	Quantité de travail maîtrisée	0.77***	< 0.001
	Tensions hiérarchiques	1.89***	< 0.001
	Contact hors horaires	1.91***	< 0.001
<i>Relations professionnelles</i>			
	Aide des collègues	0.75**	0.003
	Confiance infos supérieurs	0.89**	0.004
	Désaccord hiérarchique	1.32***	< 0.001
	Soutien moral	0.51***	< 0.001
	Bien-être perçu	0.66***	< 0.001
<i>Événement marquant</i>			
	Deuil / santé proche	1.46***	< 0.001
<i>Violences / atteintes</i>			
	Tâches dégradantes	2.30***	< 0.001
	Moqueries ou blagues	2.08***	< 0.001
	Ennui au travail	2.10***	< 0.001
<i>Ressources économiques</i>			
	Revenu ≤ 1350 (réf.)		
	13511700	0.91	0.321
	17012250	0.94	0.526
	22513000	0.87	0.245
	> 3000	0.71**	0.027
<i>Type d'emploi</i>			
	CDI / Fonction publique (réf.)		
	Emploi non stable	1.26	0.061

Note : OR = Odds Ratio. Significativité : * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$.

Les résultats du modèle logit confirment plusieurs hypothèses théoriques sur les déterminants de l'épuisement professionnel, tout en nuancant certaines autres.

L'effet du genre est particulièrement marqué : les hommes présentent une probabilité d'épuisement nettement plus élevée que les femmes, avec des chances multipliées par plus de deux. Ce résultat, significatif au seuil de 1 %, invite à nuancer l'idée reçue selon laquelle les femmes seraient plus vulnérables, et peut s'expliquer par une verbalisation plus tardive du mal-être chez les hommes ou par une exposition accrue à certaines formes de tension.

Le niveau de diplôme est également associé à un risque accru : chaque niveau supplémentaire de diplôme augmente les chances d'épuisement d'environ 16 %, ce qui est statistiquement significatif. Cela semble refléter une intensification des responsabilités et des exigences, confirmant des résultats déjà observés dans la littérature sur les cadres et professions intellectuelles. À l'inverse, l'âge n'apparaît pas comme un facteur significatif dans le modèle.

Du côté des conditions de travail, plusieurs éléments confirment les grands modèles explicatifs de type Karasek. Les individus déclarant devoir régulièrement prendre des initiatives voient leur probabilité d'épuisement augmenter sensiblement, tandis que ceux qui peuvent mettre en œuvre leurs idées ou estiment maîtriser leur charge de travail bénéficient d'un effet protecteur clair. Le fait de disposer d'un bon équilibre entre vie professionnelle et vie privée se révèle particulièrement déterminant : les personnes concernées présentent une probabilité divisée par deux de se retrouver en situation d'épuisement professionnel. À l'inverse, être régulièrement sollicité en dehors des horaires de travail augmente significativement le risque, ce qui confirme le rôle nocif de la porosité des temps de vie.

Les relations professionnelles jouent un rôle ambivalent mais déterminant. Le soutien des collègues, la confiance dans les informations de la hiérarchie, et le fait de pouvoir se confier réduisent significativement la probabilité d'épuisement. À titre d'exemple, les individus disposant d'un soutien moral voient leur risque quasiment divisé par deux. En revanche, les tensions avec la hiérarchie ou les désaccords sur la manière d'effectuer son travail accroissent sensiblement les risques, confirmant que la qualité des relations managériales est un levier central de prévention.

Certaines dimensions personnelles sont également en cause. Avoir connu récemment un événement marquant (deuil ou maladie grave d'un proche) augmente nettement les chances d'épuisement, validant l'hypothèse d'une vulnérabilité psychologique accrue en période de fragilité. Ce résultat rappelle que l'épuisement professionnel est souvent le fruit d'une interaction entre sphère personnelle et professionnelle.

L'exposition à des formes de dévalorisation ou de violence symbolique constitue l'un des facteurs les plus puissants du modèle. Être affecté à des tâches jugées dégradantes ou subir des moqueries multiplie par deux ou plus la probabilité d'épuisement. L'ennui chronique, souvent moins visible, agit de manière équivalente. Ces résultats confirment que l'épuisement peut découler tout autant d'une surcharge que d'un manque de sens ou de stimulation dans le travail.

Enfin, les effets des variables économiques sont plus nuancés. Seule la tranche de revenu la plus élevée (au-delà de 3 000 euros mensuels) est associée à une diminution significative du risque. Cela suggère que les ressources financières permettent une meilleure mise à distance du stress ou une adaptation plus aisée. L'effet de la précarité de l'emploi, bien que non significatif au seuil strict de 5 %, reste proche de la significativité à 10 %, et va dans le sens attendu d'un risque accru.

TABLE 3 – Effets des variables explicatives sur la probabilité d'épuisement professionnel (régressions logistiques univariées et multivariées)

Variable	Proportion	OR univarié	Signif.	OR ajusté	Signif.
<i>Genre</i>					
Homme (réf. = Femme)	56.9%	2.00	***	2.20	***
<i>Âge et diplôme</i>					
Âge (années)		0.99	*	1.00	
Diplôme (niveau)		1.18	***	1.18	***
<i>Conditions de travail</i>					
Horaires prévisibles		1.30	***	1.14	**
Équilibre vie pro/perso	83.2%	0.33	***	0.48	***
Initiative au travail	80.9%	1.47	***	1.74	***
Mise en uvre d'idées	64.1%	0.72	***	0.77	***
Quantité de travail maîtrisée	28.0%	0.65	***	0.79	***
Tensions hiérarchiques	31.0%	3.73	***	1.88	***
Contact hors horaires	19.4%	1.74	***	1.89	***
<i>Relations professionnelles</i>					
Aide des collègues	89.1%	0.57	***	0.70	***
Confiance infos supérieurs		0.58	***	0.86	***
Désaccord avec la hiérarchie		2.01	***	1.29	***
Soutien moral	93.6%	0.43	***	0.50	***
Bien-être perçu	62.1%	0.32	***	0.64	***
<i>Événement marquant</i>					
Deuil ou santé proche	41.6%	1.82	***	1.53	***
<i>Violences / atteintes</i>					
Tâches dégradantes	5.8%	5.13	***	2.16	***
Moqueries ou blagues	5.8%	4.24	***	2.12	***
Ennui au travail	7.5%	3.46	***	2.14	***
<i>Ressources économiques</i>					
13511700	27.0%	1.01		0.99	
17012250	26.8%	1.04		1.00	
22513000	17.2%	1.00		0.88	
> 3000	9.2%	0.75	**	0.70	*
(réf. = ≤ 1350)					
<i>Type d'emploi</i>					
Emploi non stable		1.39	***	1.26	*

Note : OR = Odds Ratio. La colonne "OR univarié" présente les résultats issus des régressions logistiques bivariées (une variable à la fois).

La colonne "OR ajusté" présente les résultats de la régression logistique multivariée avec contrôle pour l'ensemble des variables listées.

Significativité : * $p < 0,05$; ** $p < 0,01$; *** $p < 0,001$.

Ce tableau croisé, permet de visualiser, en un seul coup d'il, les résultats des régressions logistiques univariées et multivariées, tout en indiquant la proportion de répondants concernés par chaque modalité. Il met en évidence les variables ayant un effet statistiquement significatif, tant lorsqu'elles sont prises isolément (colonnes OR univarié) que lorsqu'elles sont contrôlées par l'ensemble des autres facteurs (colonnes OR ajusté). L'écart entre ces deux types d'analyse permet de détecter des effets indirects ou médiateurs éventuels.


Par exemple, être un homme, subir des tâches dégradantes ou avoir un désaccord hiérarchique conserve un effet significatif après ajustement, ce qui témoigne de la robustesse de ces déterminants. En revanche, certaines variables comme l'âge ou les tranches de revenus intermédiaires perdent leur significativité une fois les autres facteurs contrôlés, suggérant que leur effet est absorbé par d'autres variables explicatives.

La structuration thématique du tableau améliore la clarté de l'interprétation en distinguant les domaines d'exposition (genre, conditions de travail, relations professionnelles, violences, ressources, etc.). Cela facilite l'identification des leviers potentiels de prévention. Ainsi, cette double lecture statistique permet d'affiner la compréhension des mécanismes associés au risque d'épuisement professionnel.

4.1.2 Qualité d'ajustement et performance prédictive

Le modèle logit enrichi présenté ici résulte d'un processus itératif combinant sélection théorique des variables, ajustements empiriques et arbitrages entre robustesse statistique et performance prédictive.

Performances globales du modèle Le critère d'information d'Akaike (AIC) atteint 6 227,4, ce qui traduit un bon compromis entre qualité d'ajustement et parcimonie. Par ailleurs, l'aire sous la courbe ROC (AUC = 0,813) indique une bonne capacité de discrimination : dans plus de 81 % des cas, le modèle attribue une probabilité plus élevée d'épuisement à un individu réellement concerné qu'à un individu non concerné. La courbe ROC complète est présentée en annexe.



Le seuil de classification a été fixé à 0,20, de manière à maximiser le rappel tout en maintenant une précision acceptable. Ce choix reflète une stratégie conservatrice, orientée vers la détection des cas positifs même au prix d'un certain nombre de fausses alertes. À ce seuil :

- La précision sur la classe positive est de 42,3 % : parmi les individus identifiés comme à risque, seuls 42 % le sont réellement, ce qui reflète un taux important de faux positifs.
- Le rappel (ou sensibilité) est de 63,5 % : cela signifie que près de deux tiers des individus effectivement en situation d'épuisement sont correctement identifiés.
- Le F1-score atteint 0,508 : cet indicateur combine précision et rappel. Sa valeur intermédiaire reflète un compromis acceptable dans un contexte de déséquilibre entre les classes.
- La précision sur la classe négative s'élève à 92,7 % : le modèle identifie très correctement les individus ne présentant pas de risque élevé, avec peu de faux négatifs dans cette catégorie.
- L'accuracy globale est de 81 % : 4 prédictions sur 5 sont correctes, ce qui donne une impression globale de bonne performance, bien qu'elle soit en partie influencée par la forte proportion de cas négatifs.

Ces résultats soulignent un bon pouvoir prédictif global du modèle, notamment sur la classe majoritaire. L'usage combiné de l'AUC, du F1-score et du rappel permet de dépasser les limites de l'accuracy, souvent biaisée dans les cas de déséquilibre de classes.

Validation de la spécification : test de log-vraisemblance et pseudo- R^2 Pour confirmer que le modèle enrichi apporte une amélioration substantielle par rapport à un modèle nul (constante seule), un test de log-vraisemblance a été réalisé. La statistique obtenue ($\chi^2 = 1429,28$, $p < 0,001$) valide très significativement l'apport des variables explicatives. Le pseudo- R^2 de McFadden, égal à 0,1883, est considéré comme satisfaisant dans les analyses logit appliquées à des données sociales.

Vérification de la calibration : test de Hosmer–Lemeshow Pour évaluer la cohérence entre probabilités estimées et événements réellement observés, le test de Hosmer–Lemeshow a été mobilisé. Ce test, qui regroupe les observations en déciles selon leur probabilité prédite, aboutit à une statistique de 9,11 et une p-valeur de 0,3335. L'hypothèse de bon ajustement n'est donc pas rejetée, ce qui confirme une bonne calibration du modèle.

Visualisation de la calibration : courbe de calibration En complément du test statistique précédent, la courbe de calibration (voir annexe) permet de visualiser la fidélité des prédictions. La courbe suit globalement la diagonale idéale, malgré quelques écarts pour les classes extrêmes, indiquant un modèle bien calibré dans l'ensemble.

Analyse des résidus : résidus de Pearson Afin d'identifier d'éventuelles anomalies d'ajustement, les résidus de Pearson ont été examinés. Leur distribution est centrée sur 0, sans excès de dispersion ni asymétrie notable. Seules quelques valeurs extrêmes isolées apparaissent, ce qui est habituel dans les enquêtes en population générale. L'absence de structure anormale dans ces résidus conforte la qualité de l'ajustement.

Stabilité du modèle : distances de Cook Enfin, la robustesse du modèle a été vérifiée à travers l'analyse des distances de Cook, qui mesurent l'influence potentielle de chaque observation sur les coefficients estimés. En retenant le seuil classique de $4/n \approx 0,00045$, 903 observations (soit environ 10 % de l'échantillon d'apprentissage) dépassent ce seuil. Ces cas mériteraient un

examen approfondi dans une perspective de modélisation plus poussée. Toutefois, la majorité des observations présentent une influence négligeable, et l’histogramme des distances (annexe) ne révèle pas de concentration problématique. Cela confirme la stabilité globale de l’estimation.

En résumé, la qualité d’ajustement du modèle est validée par une combinaison cohérente de diagnostics : bon pouvoir explicatif, calibration satisfaisante, absence d’anomalies structurelles et robustesse face aux valeurs atypiques. Le modèle peut ainsi être mobilisé en toute rigueur pour l’analyse du risque d’épuisement professionnel.

L’ensemble de ces éléments confirme la qualité et la stabilité du modèle logit enrichi, ce qui autorise son utilisation pour une application interactive de prédiction individuelle du risque d’épuisement professionnel.

4.1.3 Application interactive de prédiction du risque d’épuisement professionnel

Dans une démarche de valorisation empirique et de sensibilisation, nous avons développé une application interactive de type formulaire prédictif, conçue avec la bibliothèque *Streamlit* en Python. Cette interface permet à tout utilisateur de simuler son risque individuel d’épuisement professionnel, sur la base d’un modèle logit binaire estimé à partir des données de l’enquête nationale *Conditions de travail et Risques psychosociaux (CT-RPS)* de 2016.

Objectifs de l’interface L’objectif est double :

- proposer un outil pédagogique et préventif, ancré dans des fondements économétriques rigoureux ;
- sensibiliser les actifs aux facteurs de risque concrets identifiés dans la littérature et l’analyse empirique.

Conception et choix techniques L’application repose sur un modèle logit enrichi, intégrant une vingtaine de variables explicatives jugées économétriquement significatives ou conceptuellement importantes. Pour garantir la transparence du processus, les coefficients estimés sont directement intégrés dans le code, sans recours à la sérialisation du modèle, ce qui permet de mieux expliciter les mécanismes de prédiction.

L’utilisateur est guidé à travers un questionnaire structuré en quatre blocs thématiques :

- **Données sociodémographiques** : âge, sexe, diplôme, type d’emploi, revenu ;
- **Conditions de travail** : horaires, autonomie, initiatives, équilibre vie privée / vie professionnelle ;
- **Relations professionnelles** : soutien, tensions hiérarchiques, conflits, confiance dans l’encadrement ;
- **Ressenti au travail** : ennui, moqueries, tâches inutiles.

Il est important de souligner que ces questions ne reprennent pas directement les 22 items du *Maslach Burnout Inventory* (MBI), utilisés en amont pour construire la variable dépendante. L’objectif ici est de prédire la probabilité d’un épuisement professionnel sévère à partir de variables explicatives externes, évitant ainsi tout biais de redondance.

Traitement des réponses Les modalités de réponse ont été recodées selon les mêmes logiques que celles utilisées lors de l’estimation du modèle logit. Les réponses ambiguës ou non

exploitables (Sans objet, NSP, Refus) sont systématiquement exclues du calcul, afin d'assurer une cohérence stricte avec les hypothèses du modèle.

Limites techniques et arbitrages Plusieurs arbitrages méthodologiques ont été nécessaires. Si l'utilisateur ne complète pas l'ensemble du questionnaire, l'application suspend l'affichage du score et invite à compléter les champs manquants. De plus, les personnes sélectionnant Autre pour le genre ne reçoivent pas de prédiction automatique, en raison de l'absence d'individus similaires dans l'échantillon d'estimation. Dans ce cas, l'application propose des conseils préventifs généraux, dans une optique inclusive mais rigoureuse.

Le seuil de classification retenu est de 0,2, correspondant au quartile supérieur de la distribution du score global d'épuisement. Ce choix permet de maximiser la détection des cas à risque, dans une logique de prévention, quitte à accepter un léger surdiagnostic.

Portée et intérêt de l'outil Ce prototype répond à un enjeu de santé publique : démocratiser l'accès à des outils d'auto-évaluation, dans un contexte où les formes de souffrance au travail sont souvent banalisées ou invisibilisées. Il offre plusieurs apports :

- une diffusion vulgarisée des résultats du modèle économétrique ;
- une meilleure prise de conscience individuelle des risques professionnels ;
- des recommandations conditionnelles, adaptées au profil renseigné ;
- une base exploitable pour des actions collectives de prévention, en entreprise ou en santé au travail.

En somme, cette application constitue une preuve de concept d'un outil interactif, non médical mais scientifiquement fondé, qui montre comment les données empiriques peuvent être mobilisées de manière concrète pour prévenir l'épuisement professionnel.

FIGURE 1 – Exemple d'interface Informations sociodémographiques

FIGURE 2 – Exemple d'interface Ressenti au travail et résultat

4.2 Discussion : implications en matière de prévention et de politiques publiques

Les résultats issus du modèle confirment que certaines conditions de travail jouent un rôle central dans l'apparition de l'épuisement professionnel. Les tensions hiérarchiques, le manque d'autonomie dans l'organisation du travail, la faible prévisibilité des horaires ou encore l'absence de soutien apparaissent comme les principaux déterminants. Ces éléments dépassent largement les caractéristiques individuelles, ce qui souligne l'importance de recentrer la prévention sur les structures de travail elles-mêmes : climat managérial, organisation, communication interne, reconnaissance, marges de manœuvre.

Ces constats renforcent un consensus croissant dans la littérature : l'épuisement professionnel est d'abord un phénomène organisationnel. Pourtant, en pratique, les approches restent souvent centrées sur les individus, via des dispositifs de résilience, de gestion du stress ou de développement personnel. Si ces outils peuvent être utiles à court terme, ils ne suffisent pas à traiter les causes structurelles.

Un autre point de blocage important tient à la reconnaissance institutionnelle du phénomène. En France, le burn-out n'est toujours pas inscrit dans les tableaux des maladies professionnelles de la Caisse nationale de l'assurance maladie (CNAM). Sa reconnaissance est possible hors tableau, mais ces démarches sont complexes, peu connues, et rarement abouties. Cette absence de reconnaissance freine la visibilité du problème, complique la prise en charge des salariés concernés, et dilue les responsabilités. Le traitement reste ainsi inégal selon les situations, les employeurs ou les acteurs impliqués.

Sur le plan juridique, le cadre impose pourtant déjà à l'employeur de garantir la santé physique et mentale des travailleurs (article L.4121-1 du Code du travail). En théorie, cela inclut les risques psychosociaux, dont l'épuisement professionnel. Mais dans les faits, les mesures mises en œuvre varient fortement selon les structures. Certaines entreprises disposent de politiques actives de prévention, tandis que d'autres se contentent d'actions ponctuelles, souvent en réaction à des situations déjà critiques. La médecine du travail, qui devrait jouer un rôle central dans l'identification et la prévention des situations à risque, est quant à elle confrontée à des contraintes croissantes : manque de médecins, limitations d'accès aux salariés, faibles moyens de suivi.

D'un point de vue plus global, il semble nécessaire de renforcer les politiques publiques autour des risques psychosociaux. Cela suppose d'abord une meilleure formation des professionnels de santé, des médecins du travail mais aussi des généralistes, souvent en première ligne. Des outils d'évaluation plus clairs, partagés et validés cliniquement pourraient faciliter les diagnostics et harmoniser les pratiques. Une réflexion sur les critères de reconnaissance administrative s'impose également, pour éviter que la reconnaissance en maladie professionnelle repose uniquement sur des démarches longues et aléatoires.

Il convient toutefois de souligner certaines limites inhérentes aux modèles utilisés. Premièrement, la démarche repose sur un modèle logistique binaire qui, bien qu'efficace pour identifier des facteurs associés, ne permet pas d'établir de lien de causalité formel. Les relations observées restent donc corrélationnelles, et peuvent être influencées par des biais non observés ou des variables omises. Deuxièmement, malgré un important travail de nettoyage et de recodage, certaines variables restent approximatives ou déclaratives, ce qui peut introduire un biais de mesure. Enfin, le choix de seuil pour définir un niveau élevé d'épuisement professionnel repose sur

une décision empirique (dernier quartile du score global), qui, bien que justifiée, reste arbitraire. Ces éléments appellent à la prudence dans l'interprétation, tout en montrant l'intérêt de croiser les approches qualitatives, cliniques et statistiques pour mieux comprendre ce phénomène complexe.

Enfin, les résultats de cette étude mettent en lumière l'apport des données statistiques pour orienter la prévention. Le recours à des modèles empiriques, capables d'identifier les profils les plus à risque, permettrait de mieux cibler les actions et d'adapter les dispositifs aux réalités des différents secteurs. La prévention des risques psychosociaux pourrait ainsi évoluer vers des approches plus proactives, mieux informées, et plus équitables. Cela suppose toutefois une collaboration étroite entre chercheurs, entreprises, institutions et partenaires sociaux.

5 Conclusion

L'objectif de ce travail était de mieux comprendre les mécanismes à l'œuvre dans l'apparition de l'épuisement professionnel, à partir d'un matériau empirique riche, celui de l'enquête CT-RPS 2016. En construisant un score global d'épuisement à partir des trois dimensions du *Maslach Burnout Inventory* épuisement émotionnel, déshumanisation, et sentiment d'accomplissement puis en le modélisant à l'aide d'une régression logistique binaire, cette étude a permis de dégager des profils de risque de manière statistiquement fondée.

L'approche adoptée repose sur un échantillon robuste de plus de 12 000 actifs occupés, disposant de données complètes sur les dimensions du burn-out et un ensemble de variables contextuelles. La variable dépendante, définie comme un niveau élevé d'épuisement correspondant au dernier quartile de l'indice construit, permet de cibler les situations les plus critiques sans tomber dans l'arbitraire d'un seuil médical.

Les résultats montrent clairement que l'épuisement professionnel n'est pas aléatoire. Il est fortement lié à des conditions objectives de travail : les tensions avec la hiérarchie, le manque d'autonomie, la faible prévisibilité des horaires, l'absence de soutien, ou encore l'exposition à des tâches jugées dévalorisantes sont autant de facteurs qui augmentent significativement le risque. Ces déterminants ne relèvent pas de la seule sphère individuelle, mais pointent plutôt des déséquilibres organisationnels durables.

Ainsi, cette recherche rejoint un consensus scientifique croissant : le burn-out ne peut être compris uniquement à travers les caractéristiques personnelles (résilience, perfectionnisme, etc.), mais doit être replacé dans une analyse systémique du travail. C'est l'environnement professionnel, dans ce qu'il a de soutenant ou d'hostile, qui façonne la probabilité d'épuisement. En ce sens, la prévention doit porter avant tout sur l'organisation du travail, la charge, la reconnaissance, le management et les marges de manœuvre laissées aux salariées.

Pourtant, dans les faits, la reconnaissance de l'épuisement professionnel reste incertaine. Il ne figure toujours pas dans les tableaux de maladies professionnelles de la Caisse nationale de l'assurance maladie (CNAM), ce qui rend son indemnisation complexe et marginale. Le traitement des cas repose sur une expertise médicale parfois subjective, et sur des démarches longues et dissuasives. Ce flou institutionnel accentue le sentiment d'invisibilité chez les personnes concernées, et empêche une réponse cohérente et équitable du système de santé au travail.

Du côté de la prévention, les obligations légales existent : l'employeur est tenu de protéger

la santé mentale de ses salariés. Mais l'application de cette règle varie énormément selon les contextes, les secteurs et les ressources disponibles. Dans bien des cas, la prévention reste déclarative ou symbolique. La médecine du travail, qui pourrait jouer un rôle clé dans le repérage précoce et le dialogue avec les employeurs, souffre d'un manque criant de moyens humains et de reconnaissance.

D'un point de vue plus global, cette étude souligne l'intérêt de mobiliser les outils de la data science pour objectiver les facteurs de risque psychosociaux. L'application interactive développée à partir du modèle logit enrichi permet à chacun d'estimer son niveau de risque, mais surtout de visualiser les leviers sur lesquels agir. En identifiant clairement les éléments à risque dans l'environnement de travail, elle offre un support à la prévention personnalisée et à la décision managériale.

Il est désormais nécessaire d'élargir ce type d'initiatives. La prévention de l'épuisement professionnel ne pourra être pleinement efficace que si elle s'inscrit dans un cadre collectif : meilleure formation des encadrants, campagnes d'information publiques, critères cliniques partagés, reconnaissance juridique renforcée, et implication des partenaires sociaux. Le rôle des pouvoirs publics est central : en tant que garants de la santé au travail, employeurs eux-mêmes à travers les fonctions publiques, et financeurs d'un système de santé solidaire, ils ont une triple responsabilité dans la lutte contre l'épuisement professionnel.

Enfin, cette recherche ouvre la voie à d'autres travaux. Une évaluation longitudinale permettrait d'objectiver les trajectoires de détérioration de la santé mentale au travail. L'ajout de données qualitatives offrirait un éclairage complémentaire sur les expériences vécues derrière les chiffres. Et surtout, le dialogue entre chercheurs, professionnels de santé, institutions et salariées doit se poursuivre pour bâtir des environnements de travail plus soutenables, plus humains et plus justes.

6. Bibliographie

Chapelle F. (2018), *Risques psychosociaux et Qualité de Vie au Travail en 36 notions*. Paris : Dunod.

Faivre C., Taright, N., et Boileau, P. (2018), "Burn-out chez les chirurgiens orthopédiques et traumatologues français : une étude nationale." *Revue de Chirurgie Orthopédique et Traumatologique*, 104(2), 123-130.

Karasek R. A. (1979), "Job demands, job decision latitude, and mental strain : Implications for job redesign." *Administrative Science Quarterly*, 24(2), 285-308.

Khireddine I., Lemaire C., and Homère J. (2015), "Surveillance des troubles psychiques liés au travail en France : résultats du programme MCP (2007-2012)". *Bulletin Epidémiologique Hebdomadaire*, 15-16, 264-271.

Nagasaki K., Emiko, R., Maeno T., and Kobayashi H. (2022), Diagnostic accuracy of the Single-item Measure of Burnout (Japanese version) for identifying medical resident burnout." *Journal of General and Family Medicine*, 23(5), 345-350. <https://doi.org/10.1002/jgf2.535>

Nasse P., Légeron, P. (2008), "La détermination, la mesure et le suivi des risques psychosociaux au travail." *Références en santé au travail*, n°131. INRS.

Niedhammer I., Chastang, J.-F., David, S. (2006), "Exposition aux facteurs psychosociaux au travail en France : résultats de l'enquête Sumer 2003." *Archives des Maladies Professionnelles et de l'Environnement*, 67(4), 585-594.

Olié J.-P., Légeron, P. (2016), "Le burn-out : un état de stress intense". Rapport de l'Académie nationale de médecine. Paris : Académie nationale de médecine.

Trontin C., Lassagne, M., et Boini, S. (2007), "Le coût du stress professionnel en France en 2007." *INRS Documents pour le Médecin du Travail*, 110, 1-12.

Technologia. (2014), "Le syndrome d'épuisement, une maladie professionnelle." Paris.

Truchot D. (2015), *Épuisement professionnel et burn out. Concepts, méthodes, interventions*. Paris, Dunod.

Maslach, C. (1982), "Understanding burn out : Definition issues in analyzing a complex phenomenon." In W.S. Paine (éd.), *Job Stress and Burn out*. Sage Publications, Beverly Hills (California).

Marchand A., Demers A and Durand P (2005), "Does work really cause distress ? The contribution of occupational structure and work organization to the experience of psychological distress." *Social Science and Medicine*, 61(1), 1-14.

Légeron P. (2015), *Le stress au travail : un enjeu de santé*. Éditions Odile Jacob, Paris.

Gollac M. (2011), "Mesurer les facteurs psychosociaux de risque au travail pour les maîtriser." Rapport du collège d'expertise sur le suivi des RPS au travail réuni à la demande du ministre du Travail et des Affaires sociales, Paris.

Haute Autorité de Santé (HAS). (2017), "Burn out - Repérage et prise en charge." https://www.has-sante.fr/jcms/pprd_2974265/fr/burnout-reperage-et-prise-en-charge

Perraudin C., Thevenot N.,et Dessein S. (2022), "Conditions de travail et prévention des risques professionnels dans le travail en sous-traitance : une étude quantitative.", Dares. 2022. hal-03239644 <https://hal.science/hal-03239644v1>

Camphuis M. (2022), "Le diagnostic du burnout en médecine générale : au-delà des débats, quelle pratique ?" *Médecine humaine et pathologie*. 2022. dumas-03659496

World Health Organization (WHO). (2019), "Burn-out an occupational phenomenon : International Classification of Diseases." [cité 10 févr 2022].

Zawieja, P. (2022), *Le burn-out*, Que sais-je ?

7. Annexes Numérotées

Annexe A Illustrations graphiques

FIGURE 3 – *

Figure A1 Distribution des revenus mensuels dans l'échantillon




FIGURE 4 – *

Figure A2 Répartition des tranches de revenus mensuels




FIGURE 5 – *
Figure A3 Distribution de l'âge dans l'échantillon




FIGURE 6 – *
Figure A4 Distribution du score d'épuisement émotionnel




FIGURE 7 – *

Figure A5 Distribution du score de déshumanisation




FIGURE 8 – *

Figure A6 Distribution du score d'accomplissement personnel




FIGURE 9 – *

Figure A7 Courbe de calibration du modèle logit




FIGURE 10 – *

Figure A8 Histogramme des résidus de Pearson




FIGURE 11 – *

Figure A9 Histogramme des distances de Cook





FIGURE 12 – *

Figure A10 Distances de Cook par observation



Annexe B Résultats du modèle OLS

TABLE 4 – *
Tableau B Résultats de la régression linéaire (méthode OLS)

Variable	Coef.	Erreur Std	t	p-valeur
Constante	4.609	0.474	9.716	0.000
Sexe	0.605	0.052	11.631	0.000
Prévisibilité horaires (PREVIS)	0.128	0.039	3.305	0.001
Équilibre vie pro/perso (CVFVP_reg)	-0.886	0.063	-14.039	0.000
Diplôme (niv_diplome_reg)	0.206	0.028	7.323	0.000
Type de ménage (typmen15_reg)	-0.035	0.023	-1.540	0.124
Soutien moral (RP1_reg)	-0.959	0.097	-9.916	0.000
Événement marquant (RP4B_reg)	0.435	0.048	9.093	0.000
Confiance hiérarchique (CONFSAL_reg)	-0.497	0.075	-6.658	0.000
Bien-être perçu (BIENETR1_reg)	-0.559	0.053	-10.596	0.000
Comportement hostile (CWMVT_reg)	0.292	0.052	5.668	0.000
<i>Statistiques du modèle</i>				
Nombre d'observations	9 168			
R ² / R ² ajusté	0.317 / 0.314			
Statistique F	151.2 (p = 0.000)			
AIC / BIC	40 790 / 41 000			

Annexe C Résultats du modèle OLS enrichi

TABLE 5 – Régression OLS enrichie sur le score d'épuisement professionnel

Variable	Coefficient	Erreur Std	t	p-valeur
const	4.6432	0.481	9.660	0.000
sexe	0.5804	0.054	10.726	0.000
PREVIS	0.1370	0.039	3.514	0.000
CVFVP_reg	-0.8812	0.063	-13.881	0.000
niv_diplome_reg	0.1947	0.029	6.742	0.000
typmen15_reg	-0.0450	0.026	-1.745	0.081
RP1_reg	-0.9632	0.097	-9.945	0.000
RP4B_reg	0.4312	0.048	9.017	0.000
CONFSAAL_reg	-0.4975	0.075	-6.668	0.000
BIENETR1_reg	-0.5525	0.053	-10.450	0.000
CWMVT_reg	0.2897	0.052	5.619	0.000
ENCADR_reg	0.2092	0.052	4.058	0.000
RPB1E_b	1.5992	0.107	14.958	0.000
RPB1H_b	0.6650	0.159	4.186	0.000
RPB1J_b	1.2476	0.109	11.450	0.000
RPB5E_b	1.6260	0.097	16.753	0.000
INITIAT_reg	0.3641	0.073	5.015	0.000
IDEE_reg	-0.2424	0.057	-4.237	0.000
QUANTI_reg	-0.2557	0.054	-4.768	0.000
ATTENTE_reg	0.3923	0.040	9.812	0.000
TENSION2_reg	0.8939	0.056	16.080	0.000
NBENFM3	0.0532	0.077	0.693	0.488
NBENF3A17	0.0244	0.031	0.790	0.430
TYPEEMPLOI	0.1284	0.075	1.716	0.086
FONCTION	0.0073	0.008	0.897	0.370
STATUT	-0.0256	0.012	-2.136	0.033
ETAMATRI	0.0290	0.030	0.967	0.333
AGE_tranche_30-44	0.0791	0.109	0.728	0.467
AGE_tranche_45-54	0.0708	0.113	0.627	0.531
AGE_tranche_55+	0.0689	0.122	0.566	0.572
rev_13511700	-0.0376	0.069	-0.545	0.586
rev_17012250	0.0483	0.074	0.649	0.516
rev_22513000	0.0579	0.089	0.652	0.514
rev_>3000	0.1260	0.116	1.085	0.278
Nombre d'observations		9 168		
R ² / R ² ajusté		0.317 / 0.315		
F-statistic (p)		128.6 (0.000)		
AIC / BIC		40 790 / 41 040		

Annexe D Résultats du modèle Logit enrichi

TABLE 6 – Coefficients, odds ratios et significativité du modèle logit enrichi

Variable	Coefficient	Odds Ratio	p-valeur
const	-3.3687	0.034	0.0000
TENSION2_reg	0.6319	1.881	0.0000
INITIAT_reg	0.5121	1.669	0.0000
JOINEXT_reg	0.6286	1.875	0.0000
RPB5E_b	0.7328	2.081	0.0000
RPB1J_b	0.7206	2.056	0.0000
ACCHEF_reg	0.2619	1.299	0.0000
RP4B_reg	0.3798	1.462	0.0000
sexe	0.7848	2.192	0.0000
RPB1E_b	0.8432	2.324	0.0000
CVFVP_reg	-0.7198	0.487	0.0000
RP1_reg	-0.6660	0.514	0.0000
BIENETR1_reg	-0.4299	0.651	0.0000
INT_OBJECTIF_INITIAT	0.3146	1.370	0.0000
niv_diplome_reg	0.1484	1.160	0.0002
IDEE_reg	-0.2672	0.766	0.0004
QUANTI_reg	-0.2745	0.760	0.0006
AIDCOLL_reg	-0.2803	0.756	0.0040
INFOCONF_reg	-0.1177	0.889	0.0045
rev_>3000	-0.4194	0.657	0.0081
PREVIS	0.1115	1.118	0.0265
TYPEEMPLOI	0.2261	1.254	0.0702
rev_22513000	-0.1733	0.841	0.1559
rev_13511700	-0.0993	0.905	0.3161
rev_17012250	-0.0826	0.921	0.4270
AGE	0.0022	1.002	0.5669

Annexe E Résultats du modèle Logit final

TABLE 7 – Coefficients, odds ratios et significativité du modèle logit final

Variable	Coefficient	Odds Ratio	p-valeur
const	-4.1810	0.015	0.0000
sexe	0.7442	2.105	0.0000
CVFVP_reg	-0.6789	0.507	0.0000
TENSION2_reg	0.6935	2.001	0.0000
INITIAT_reg	0.6207	1.860	0.0000
niv_diplome_reg	0.2025	1.224	0.0000
BIENETR1_reg	-0.5148	0.598	0.0000
RP1_reg	-0.6685	0.512	0.0000
RP4B_reg	0.5947	1.813	0.0000
RPB1E_b	0.8088	2.245	0.0000
RPB5E_b	0.7969	2.219	0.0000
RPB1J_b	0.7448	2.106	0.0000
PREVIS	0.1857	1.204	0.0002
ATTENTE_reg	0.1633	1.177	0.0007
QUANTI_reg	-0.2444	0.783	0.0021
CONFSAL_reg	-0.2271	0.797	0.0095
ENCADR_reg	0.2180	1.244	0.0187
TYPEEMPLOI	0.2661	1.305	0.0242
IDEE_reg	-0.1701	0.844	0.0245
CWMVT_reg	0.1440	1.155	0.0466
RPB1H_b	0.3281	1.388	0.0557
rev_>3000	-0.2453	0.782	0.1294
sexe_x_rp4b	-0.1358	0.873	0.3305
AGE_tranche_55+	0.1051	1.111	0.5129
rev_17012250	0.0582	1.060	0.5784
AGE_tranche_45-54	-0.0738	0.929	0.6216
bienetre_x_encadr	-0.0505	0.951	0.7001
rev_22513000	-0.0340	0.967	0.7823
rev_13511700	0.0247	1.025	0.8023
typmen15_reg	-0.0030	0.997	0.9240
AGE_tranche_30-44	0.0012	1.001	0.9933

Annexe G Code HTML de l'application

Mémoire

Importation des données

```
In [1]: import pandas as pd
import numpy as np
import os

import os
print(os.getcwd())
# Change le répertoire de travail
path = '/Users/jadelaurent/Documents/M1/Mémoire/Data/Csv'
print(os.getcwd())

# Charge le fichier CSV en précisant le séparateur
data = pd.read_csv('ao_panel_2016.csv', sep=';', low_memory=False)

/Users/jadelaurent/Documents/M1/Mémoire/Data.csv/Csv
/Users/jadelaurent/Documents/M1/Mémoire/Data.csv/Csv
```

```
In [2]: # On fait apparaître les 5 premières lignes de la base
data.head()
```

```
Out[2]:
```

	IDENT_IND	LIEN_01	LIEN_02	LIEN_03	LIEN_04	LIEN_05	LIEN_06	LIEN_07	LIEN_08	LIEN_09	...	numfa	iden
0	010000060100002	1	0.0	3.0	NaN	NaN	NaN	NaN	NaN	NaN	...	6	01000006
1	010000170100002	1	0.0	3.0	3.0	22.0	22.0	NaN	NaN	NaN	...	17	01000017
2	010000180100001	0	1.0	3.0	3.0	3.0	NaN	NaN	NaN	NaN	...	18	01000018
3	010000180100002	1	0.0	3.0	3.0	3.0	NaN	NaN	NaN	NaN	...	18	01000018
4	010000200100002	2	0.0	NaN	NaN	NaN	NaN	NaN	NaN	NaN	...	20	01000020

5 rows × 552 columns

```
In [3]: # On fait apparaître les types des variables
data.dtypes
```

```
Out[3]:
```

IDENT_IND	object
LIEN_01	int64
LIEN_02	float64
LIEN_03	float64
LIEN_04	float64
...	...
ident_panel	object
poids_panel_RPS_cal	float64
poids_panel_RPS_calqaa	float64
typrepqaa	int64
CHAMP_CT2005	int64

Length: 552, dtype: object

```
In [4]: print(data.shape) # Nombre de lignes et colonnes
```

(19882, 552)

```
In [5]: print(data.columns) # Liste des colonnes
```

```
Index(['IDENT_IND', 'LIEN_01', 'LIEN_02', 'LIEN_03', 'LIEN_04', 'LIEN_05',
      'LIEN_06', 'LIEN_07', 'LIEN_08', 'LIEN_09',
      ...,
      'numfa', 'ident_log', 'nactifs', 'typmen5', 'typmen15', 'ident_panel',
      'poids_panel_RPS_cal', 'poids_panel_RPS_calqaa', 'typrepqaa',
      'CHAMP_CT2005'],
      dtype='object', length=552)
```

Nettoyage des données

Gestion des valeurs manquantes :

```
In [6]: missing = data.isnull().sum()
missing_percent = (missing / len(data)) * 100
missing_data_cl1 = pd.DataFrame({'Missing_Values': missing, 'Percent': missing_percent})
print(missing_data_cl1.sort_values(by='Percent', ascending=False).head(100))
```

	Missing_Values	Percent
LIEN_11	19878	99.979881
LIEN_10	19873	99.954733
LIEN_09	19854	99.859169
NBSALAI	19850	99.839050
AIDFAM	19845	99.813902
...	...	...
COMBEXT	15546	78.191329
RPB3J	14655	73.709888
RPB3I	14655	73.709888
RPB3K	14655	73.709888
RPB3F	14655	73.709888

[100 rows x 2 columns]

```
In [7]: # Charger le fichier Excel contenant les variables à garder
variables_exc = pd.read_excel("Variables à garder.xlsx", sheet_name='Sheet1')

# Étape 1 : Nettoyage des noms (suppression des espaces, suppression doublons)
variables_a_garder = variables_exc['A garder'].dropna().unique()
variables_a_garder = [v.strip() for v in variables_a_garder]

# Étape 2 : Vérification des colonnes présentes dans la base
colonnes_base = data.columns
variables_non_trouvees = [v for v in variables_a_garder if v not in colonnes_base]

# Affichage des résultats
print(f"\nNombre total de variables demandées : {len(variables_a_garder)}")
print(f"Variables présentes dans la base : {len(variables_a_garder) - len(variables_non_trouvees)}")
print(f"Variables manquantes : {len(variables_non_trouvees)}\n")

if variables_non_trouvees:
    print("Variables manquantes :")
    for var in variables_non_trouvees:
        print(f"- {var}")

# Étape 3 : Filtrer la base avec uniquement les colonnes valides
data_cl = data[[col for col in variables_a_garder if col in colonnes_base]]

# Étape 4 : Vérifier le résultat
print("\nDimensions de la base filtrée :", data_cl.shape)
display(data_cl.head())
```

Nombre total de variables demandées : 259
Variables présentes dans la base : 256
Variables manquantes : 3

Variables manquantes :
- typemen15
- TYPEN5
- RP22H

Dimensions de la base filtrée : (19882, 256)

	CLASS	DETRESSE	FATIGUE	CWLOURD	COLLECT	revmensc	LIEUW	FORTMOD3	RP3B	RPB3D	...	DEPECH	RWCOLE
0	NaN	2.0	4.0	1.0	1.0	1675.000000	1.0	2.0	1.0	NaN	...	1.0	2.
1	NaN	1.0	3.0	2.0	1.0	3200.000000	5.0	2.0	2.0	NaN	...	2.0	1.
2	NaN	2.0	3.0	2.0	NaN	183.333333	NaN	2.0	1.0	2.0	...	1.0	2.
3	NaN	1.0	2.0	2.0	1.0	1800.000000	1.0	2.0	2.0	2.0	...	4.0	1.
4	NaN	1.0	4.0	1.0	1.0	2400.000000	1.0	2.0	2.0	2.0	...	4.0	1.

5 rows x 256 columns

```
In [8]: # Calcul du pourcentage de valeurs manquantes
nb_lignes = data_cl.shape[0]
missing_counts = data_cl.isnull().sum()
missing_percent = (missing_counts / nb_lignes) * 100

# Filtrer les variables avec plus de 50 % de valeurs manquantes
missing_over_50 = missing_percent[missing_percent > 50].sort_values(ascending=False)

# Affichage
print(f"\nVariables avec plus de 50 % de valeurs manquantes : {len(missing_over_50)}")
display(missing_over_50)

missing_over_50.to_frame(name='Percent').to_csv('variables_manquantes50.csv')
```

Variables avec plus de 50 % de valeurs manquantes : 42

TPS_INTERIM	99.401469
CLASS	98.395534
FORMINIT	98.254703
ETUDIPL	98.254703
RP10	96.137210
HHTOT	95.609094
RP7A	95.392818
RP7E	95.392818
RP8	95.392818
RP7D	95.392818
RDET	94.935117
MIN4EDM	93.954331
ANARRIV	92.344835
ARRET	90.866110
AUTENT	90.031184
NBNUIT	83.628408
TXTPPB	81.314757
RAISTP	81.314757
TCH0CP	78.251685
TINAP	78.251685
TCH0LP	78.251685
TSANP	78.251685
RPB3G	73.709888
RPB3F	73.709888
RPB3K	73.709888
RPB3E	73.709888
RPB2A	73.709888
RPB3J	73.709888
RPB2B	73.709888
RPB3B	73.709888
RPB3I	73.709888
RPB3D	73.709888
RPB3H	73.709888
RPB3A	73.709888
RPB3C	73.709888
OBJATTEIN	72.849814
TPMAISON	72.633538
ATMAL	68.675184
TENSION4	61.648727
TITPUBR	61.336888
RESTMAIN	56.900714
NBSALENTC	52.047078

dtype: float64

```
In [9]: # Liste des variables à supprimer manuellement
variables_a_supprimer = [
    "TPS_INTERIM", "CLASS", "ETUDIPL", "FORMINIT", "RP10", "HHTOT", "RP7A", "RP7D", "RP8", "RP7E",
    "RDET", "ANARRIV", "ARRET", "AUTENT", "NBNUIT", "TXTPPB", "RAISTP", "TINAP", "TCH0CP", "TSANP",
    "TCH0LP", "RPB3D", "RPB3J", "RPB3F", "RPB3A", "RPB3C", "RPB3B", "RPB3I", "RPB3H",
    "RPB2B", "RPB3G", "RPB3E", "RPB2A", "OBJATTEIN", "TPMAISON", "ATMAL", "TITPUBR",
    "RESTMAIN", "NBSALENTC"
]

# Vérifier que les colonnes sont bien présentes dans la base
variables_a_supprimer_valides = [col for col in variables_a_supprimer if col in data_cl.columns]

# Supprimer les colonnes → nouvelle version de la base
data_cl1 = data_cl.drop(columns=variables_a_supprimer_valides)

# Afficher les résultats
print(f"Dimensions de la base après suppression : {data_cl1.shape}")
print(f"Nombre de variables supprimées : {len(variables_a_supprimer_valides)}")
```

Dimensions de la base après suppression : (19882, 217)
 Nombre de variables supprimées : 39

```
In [10]: # Calcul du nombre total de lignes
nb_lignes = data_cl1.shape[0]

# Calcul des valeurs manquantes par variable
missing_counts = data_cl1.isnull().sum()
missing_percent = (missing_counts / nb_lignes) * 100

# Filtrer les variables avec plus de 10 % de NaN
missing_over_10 = missing_percent[missing_percent > 10].sort_values(ascending=False)

# Affichage
print(f"\nVariables avec plus de 10 % de valeurs manquantes : {len(missing_over_10)}")
display(missing_over_10.to_frame(name="Pourcentage de NaN"))

missing_over_10.to_frame(name="Percent").to_csv('variables_manquantes10.csv')
```

Variables avec plus de 10 % de valeurs manquantes : 37

Pourcentage de NaN	
MIN4EDM	93.954331
RPB3K	73.709888
TENSION4	61.648727
EVACRIT	44.225933
DICHEF	38.668142
CHGTCOLL	32.516849
HSUPCOMP	30.344030
REUNION	26.124132
TENSION1	23.513731
revmensc	18.378433
INTERRUP	14.128357
JOINDRE	11.095463
FORTMOD1	11.009959
REMPERF	10.627703
AIDCOLL	10.411427
COMMENT	10.411427
CONFSAL	10.411427
BIENETR2	10.411427
DIFFIC	10.411427
MUTE	10.411427
RISK	10.411427
COLLECT	10.411427
MEDECIN	10.411427
ACCHEF	10.411427
CONTROLE	10.411427
STARK	10.411427
BIENETR1	10.411427
INFOCONF	10.411427
RWSURV	10.411427
TENSION2	10.411427
EVA	10.411427
AIDCHEF	10.411427
LIEUW	10.361131
FONCTION	10.351071
TYPEMPLOI	10.351071
CLASSIF	10.351071
v1tcdd	10.069410

```
In [11]: # Liste des variables à supprimer manuellement
variables_a_supprimer2 = ["FORTMOD1", "MUTE", "EVA", "AIDCHEF", "v1tcdd", "EVACRIT"]

# Vérifier que les colonnes sont bien présentes dans la base
variables_a_supprimer_valides1 = [col for col in variables_a_supprimer2 if col in data_cl.columns]

# Supprimer les colonnes → nouvelle version de la base
data_cl1 = data_cl.drop(columns=variables_a_supprimer_valides1)

# Afficher les résultats
print(f"Dimensions de la base après suppression : {data_cl1.shape}")
print(f"Nombre de variables supprimées : {len(variables_a_supprimer_valides1)}")
```

Dimensions de la base après suppression : (19882, 211)
Nombre de variables supprimées : 6

```
In [12]: # Calculer le pourcentage de valeurs manquantes pour chaque variable
nb_lignes = data_cl1.shape[0]
missing_percent = data_cl1.isnull().sum() / nb_lignes * 100

# Créer un DataFrame trié
missing_data_cl1 = pd.DataFrame({
```

```

    "Variable": missing_percent.index,
    "Pourcentage_de_valeurs_manquantes": missing_percent.values
}).sort_values(by="Pourcentage_de_valeurs_manquantes", ascending=False)

# Afficher les 20 plus concernées
print(missing_data_cl1.head(20))

# Exporter si besoin
missing_data_cl1.to_csv("pourcentages_valeurs_manquantes.csv", index=False)

```

	Variable	Pourcentage_de_valeurs_manquantes
174	MIN4EDM	93.954331
20	RPB3K	73.709888
172	TENSION4	61.648727
160	DICHEF	38.668142
124	CHGTCOLL	32.516849
65	HSUPCOMP	30.344030
50	REUNION	26.124132
143	TENSION1	23.513731
4	revmensc	18.378433
208	INTERRUP	14.128357
35	JOINDRE	11.095463
182	REMPERF	10.627703
185	COMMENT	10.411427
135	AIDCOLL	10.411427
145	DIFFIC	10.411427
72	BIENETR1	10.411427
64	INFOCONF	10.411427
73	STARK	10.411427
75	CONTROLE	10.411427
154	CONFSAL	10.411427

```

In [13]: # Liste complète des variables à supprimer
variables_a_supprimer = [
    "DICHEF", "CHGTCOLL", "REUNION",
    "MEDECIN", "COLLECT", "LIEUW", "CLASSIF", "vltinterim", "RPA2L", "RPB6", "RPA2K", "RPB5C",
    "RPB5D", "RPC2", "RPA2G", "RPA2D", "RPA2E", "RP36", "RPA1I", "RPA1L", "RPA1J", "RPA1K", "RPA1A", "RPA1G", "
    "RPA1E", "RPA1B", "RPA1C", "RPB4D", "RPC1E", "RP3E",
    "RP4C", "RP3A", "FORTMOD4", "FORTMOD5", "FORTMOD3", "EVOLEFF", "TRAJET", "Vldemena", "vltchoc", "vltina",
    "vltsan", "vltchol", "PAYECOM", "JOURTR", "CSE", "PE", "AUTSAL", "METIER", "NOCHOM", "URGAM", "MISSION",
    "NOUVELLE", "DEPECH", "ACCIDT", "CORRTAN", "DOMEST",
    "INTERRUP", "CORRFORM", "CORRINF", "TENIR", "RWNORMH", "ENTENDR", "CORRCOL", "INCIDENT", "DIMANCHE",
    "HORANGT", "SAMEDI", "CTPROFESS", "COUPLE", "FAP87", "MIN4TAG_a", "NAF4", "IDENT_MEN", "region", "lienmig"]

# Vérifier que les variables à supprimer existent dans le DataFrame
variables_a_supprimer_valides = [var for var in variables_a_supprimer if var in data_cl.columns]

# Supprimer les colonnes correspondantes
data_cl1 = data_cl.drop(columns=variables_a_supprimer_valides)

# Afficher un résumé
print(f"Dimensions de la base après suppression : {data_cl1.shape}")
print(f"Nombre de variables supprimées : {len(variables_a_supprimer_valides)}")

Dimensions de la base après suppression : (19882, 133)
Nombre de variables supprimées : 78

```

```
In [14]: data_cl1.shape
```

```
Out[14]: (19882, 133)
```

```
In [15]: # Filtrage sur les personnes en emploi
data_cl1 = data_cl1[data_cl1["SITUA"] == 1]
```

```
In [16]: data_cl1.shape
```

```
Out[16]: (19591, 133)
```

```
In [17]: # Exporter la base nettoyée après suppression des variables dans un fichier CSV
data_cl1.to_csv("base_nettoyee.csv", index=False, encoding="utf-8")
```

Nettoyage revmensc et création de tranches :

```
In [18]: data_cl1.shape
```

```
Out[18]: (19591, 133)
```

```
In [19]: # Statistiques descriptives sur les revenus mensuels
data_cl1["revmensc"].describe()
```



```
Out[19]: count    16024.000000
mean      1982.406219
std       1867.129541
min        0.000000
25%       1340.000000
50%       1700.000000
75%       2290.000000
max      120000.000000
Name: revmensc, dtype: float64
```

- Le revenu médian est de 1700 €, ce qui indique que la moitié des répondants gagne moins ou autant.
- La moyenne (1982 €) étant supérieure à la médiane, cela révèle une asymétrie à droite dans la distribution.
- L'écart-type élevé (1867 €) traduit une forte dispersion des niveaux de revenus.
- Le maximum (120 000 €) est très supérieur au 3^e quartile (2290 €), suggérant des valeurs extrêmes potentiellement aberrantes.
- La valeur minimale (0 €) correspond probablement à des non-réponses ou à l'absence de revenus déclarés.

```
In [20]: # Suppression des valeurs manquantes ou nulles
data_cl1 = data_cl1[data_cl1["revmensc"].notna() & (data_cl1["revmensc"] > 0)]

# Suppression des valeurs extrêmes par percentiles (D1-D99)
q1 = data_cl1["revmensc"].quantile(0.01)
q99 = data_cl1["revmensc"].quantile(0.99)
data_cl1 = data_cl1[(data_cl1["revmensc"] >= q1) & (data_cl1["revmensc"] <= q99)]
```

```
In [21]: data_cl1.shape
```


```
Out[21]: (15611, 133)
```

Il reste 15 611 observations conservées après nettoyage (suppression des valeurs manquantes, nulles et extrêmes).

```
In [22]: # Calcul de la moyenne
mean_rev = data_cl1["revmensc"].mean()

import matplotlib.pyplot as plt
import seaborn as sns
plt.figure(figsize=(10, 6))

# Histogramme avec courbe de densité
sns.histplot(data_cl1["revmensc"], bins=50, kde=True, edgecolor='black', color="steelblue")
plt.axvline(mean_rev, color='darkblue', linestyle='--', linewidth=2, label=f'Moyenne = {mean_rev:.0f} €') # Lig
plt.title("Distribution des revenus mensuels (revmensc)")
plt.xlabel("Revenus mensuels (€)")
plt.ylabel("Nombre d'observations")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```



- Forme de la distribution : la courbe est asymétrique à droite (right-skewed), ce qui signifie que la majorité des

individus ont des revenus situés dans les tranches basses ou moyennes, tandis qu'un petit nombre perçoit des revenus très élevés.

- Moyenne (~1900 €) : indiquée par la ligne pointillée bleue, elle est supérieure à la médiane (1700 €), ce qui confirme l'asymétrie. Les hauts revenus tirent la moyenne vers le haut.
- Concentration : une forte densité d'observations se situe entre 1000 € et 2200 €, ce qui justifie tes choix de tranches (≤ 1300 , 1301-1700, etc.).
- Présence de valeurs extrêmes : bien que les très hauts revenus soient rares, ils existent et apparaissent visuellement à droite de la courbe (au-delà de 4000-5000 €).

```
In [23]: data_cl1["revmensc"].describe()
```

```
Out[23]: count    15611.000000
mean      1909.313075
std        930.795184
min        166.666667
25%       1350.000000
50%       1700.000000
75%       2250.000000
max        6750.000000
Name: revmensc, dtype: float64
```

```
In [24]: def categoriser_revenus(x):
        if x <= 1350:
            return "<= 1350"
        elif x <= 1700:
            return "1351-1700"
        elif x <= 2250:
            return "1701-2250"
        elif x <= 3000:
            return "2251-3000"
        else:
            return "> 3000"
```

```
data_cl1["revmensc_tranche"] = data_cl1["revmensc"].apply(categoriser_revenus)
```

```
# Vérification de la distribution
```

```
print(data_cl1["revmensc_tranche"].value_counts())
print(data_cl1["revmensc_tranche"].value_counts(normalize=True).round(2) * 100)
```

```
revmensc_tranche
1351-1700    3996
<= 1350      3931
1701-2250    3802
2251-3000    2470
> 3000       1412
Name: count, dtype: int64
revmensc_tranche
1351-1700     26.0
<= 1350       25.0
1701-2250     24.0
2251-3000     16.0
> 3000        9.0
Name: proportion, dtype: float64
```

- ≤ 1350 € (25 %) : représente le quart inférieur des revenus, les individus les plus modestes.
- 1351-1700 € (26 %) : regroupe les personnes proches de la médiane, juste au-dessus du premier quartile.
- 1701-2250 € (24 %) : tranche médiane-supérieure, jusqu'au 3e quartile.
- 2251-3000 € (16 %) : revenus plus élevés mais encore représentés.
- "> 3000 € (9 %)" : correspond aux hauts revenus, minoritaires dans l'échantillon.

```
In [25]: ordre_tranches = ["<= 1350", "1351-1700", "1701-2250", "2251-3000", "> 3000"]
data_cl1["revmensc_tranche"] = pd.Categorical(data_cl1["revmensc_tranche"], categories=ordre_tranches, ordered=True)

import matplotlib.pyplot as plt
import seaborn as sns

age_counts = data_cl1["revmensc_tranche"].value_counts().reindex(ordre_tranches)

plt.figure(figsize=(8, 5))
sns.barplot(x=age_counts.index, y=age_counts.values, palette='crest')


plt.title("Répartition des tranches de revmensc", fontsize=14)
plt.xlabel("Tranche revenus")
plt.ylabel("Nombre d'observations")
plt.xticks(rotation=45)
plt.grid(axis='y', linestyle='--', alpha=0.6)

plt.tight_layout()
plt.show()
```

```
/var/folders/ny/hmwn2lfx3sv6m4gglsj8qjk40000gn/T/ipykernel_15418/3877727526.py:10: FutureWarning:
```

```
Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.
```

```
sns.barplot(x=age_counts.index, y=age_counts.values, palette='crest')
```



Le graphique montre une distribution asymétrique des revenus mensuels, avec une forte concentration dans les tranches les plus faibles. Près de 25 % des individus gagnent ≤ 1350 €, et 26 % entre 1351 € et 1700 €, soit plus de la moitié de l'échantillon sous la médiane. La tranche médiane (1701-2250 €) est également bien représentée (24 %). En revanche, les effectifs diminuent au-delà de 2250 €, avec seulement 16 % entre 2251 € et 3000 €, et 9 % au-dessus de 3000 €. Cette structure illustre une concentration des revenus autour de niveaux modestes, et une minorité disposant de hauts revenus.

```
In [26]: data_cl1.shape
```

```
Out[26]: (15611, 134)
```

Le traitement de la variable de revenu mensuel revmensc s'est déroulé en plusieurs étapes rigoureuses. D'abord, les observations contenant des valeurs manquantes ou nulles ont été supprimées. Cela correspond notamment aux individus ayant refusé de répondre, comme précisé dans la documentation de l'enquête. Ensuite, afin de limiter l'influence des valeurs extrêmes (notamment des revenus très élevés atypiques), seules les observations comprises entre le 1er et le 99e percentile ont été conservées.

Une fois nettoyée, la variable a été discrétisée en cinq tranches de revenu. Ces seuils ont été définis en s'appuyant sur les quartiles empiriques (25 %, 50 %, 75 %) et une borne supérieure à 3000 € pour mieux isoler les hauts revenus. Cette catégorisation facilite l'analyse statistique, en particulier dans les modèles explicatifs, tout en assurant une bonne répartition des effectifs par classe.

Nettoyage âge et création de tranches :

```
In [27]: # Affiche les statistiques de l'âge
print(data_cl1['AGE'].describe())
```


```
count    15611.000000
mean      45.556915
std       9.691144
min       19.000000
25%       39.000000
50%       46.000000
75%       53.000000
max       81.000000
Name: AGE, dtype: float64
```

L'âge des répondants s'étend de 19 à 81 ans, avec un âge moyen de 45,6 ans. La distribution est relativement centrée autour de la médiane (46 ans), avec des quartiles à 39 et 53 ans. Cela indique une population globalement adulte, principalement en âge actif, sans concentration excessive dans les extrêmes.

```
In [28]: import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
# Affiche un histogramme avec une courbe de densité
plt.figure(figsize=(10, 6))
sns.histplot(data_cl1['AGE'], bins=30, kde=True, color='steelblue')
plt.title("Distribution âge")
plt.xlabel("Âge")
plt.ylabel("Nombre d'observations")
plt.grid(True)
plt.show()
```



La distribution de l'âge est centrée autour de 45-50 ans, avec un pic marqué à 46 ans. Elle présente une légère asymétrie à gauche, traduisant une surreprésentation des individus entre 35 et 60 ans. Les jeunes adultes (moins de 30 ans) et les seniors (plus de 65 ans) sont peu représentés, ce qui reflète une population principalement en âge actif.

```
In [29]: # Calcul des bornes à 1% et 99%
q1 = data_cl1['AGE'].quantile(0.01)
q99 = data_cl1['AGE'].quantile(0.99)

# Filtrage des observations en dehors de ces bornes
data_cl1 = data_cl1[(data_cl1['AGE'] >= q1) & (data_cl1['AGE'] <= q99)]


# Vérification après nettoyage
print(data_cl1['AGE'].describe())
```

```
count    15407.000000
mean      45.585253
std       9.384221
min       24.000000
25%      39.000000
50%      46.000000
75%      53.000000
max       64.000000
Name: AGE, dtype: float64
```

Après exclusion des valeurs extrêmes (1er et 99e percentiles), les âges s'étendent désormais de 24 à 64 ans. La moyenne reste stable à 45,6 ans, confirmant une distribution centrée sur l'âge actif. Ce recentrage élimine les observations atypiques sans altérer la structure principale de l'échantillon.

```
In [30]: import matplotlib.pyplot as plt
import seaborn as sns

# Affiche un histogramme avec une courbe de densité
plt.figure(figsize=(10, 6))
sns.histplot(data_cl1['AGE'], bins=30, kde=True, color='steelblue')
plt.title("Distribution âge")
plt.xlabel("Âge")
plt.ylabel("Nombre d'observations")
plt.grid(True)
plt.show()
```



Après suppression des valeurs extrêmes (au-delà des 1er et 99e percentiles), la distribution de l'âge apparaît plus homogène. La population se concentre entre 40 et 60 ans, avec un pic léger autour de 50 ans, ce qui traduit une structure d'âge typique d'une population active.

```
In [31]: # Création de la variable :
def categoriser_age(age):
    if age < 30:
        return 'Moins de 30 ans'
    elif age < 45:
        return '30-44 ans'
    elif age < 55:
        return '45-54 ans'
    else:
        return '55 ans et plus'

data_cl1['AGE_tranche'] = data_cl1['AGE'].apply(categoriser_age)

data_cl1['AGE_tranche'] = pd.Categorical(
    data_cl1['AGE_tranche'],
    categories=['Moins de 30 ans', '30-44 ans', '45-54 ans', '55 ans et plus'],
    ordered=True
)

# Vérification de la répartition
print(data_cl1['AGE_tranche'].value_counts())
```

```
AGE_tranche
30-44 ans      5963
45-54 ans      5458
55 ans et plus  3150
Moins de 30 ans   836
Name: count, dtype: int64
```

- Moins de 30 ans : 836 individus
- 30-44 ans : 5 963 individus
- 45-54 ans : 5 458 individus
- 55 ans et plus : 3 150 individus

La majorité des répondants se situe entre 30 et 54 ans, ce qui est cohérent avec une population active. Les plus jeunes et les plus âgés sont moins représentés, ce qui reflète souvent la structure des enquêtes sur le travail.

```
In [32]: import matplotlib.pyplot as plt
import seaborn as sns

age_counts = data_cl1['AGE_tranche'].value_counts().sort_index()
plt.figure(figsize=(8, 5)) # Affichage en barres
sns.barplot(x=age_counts.index, y=age_counts.values, palette='crest')
```


```
plt.title("Répartition des tranches d'âge", fontsize=14)
plt.xlabel("Tranche d'âge")
plt.ylabel("Nombre d'observations")
plt.xticks(rotation=45)
plt.grid(axis='y', linestyle='--', alpha=0.6)
```

```
plt.tight_layout()
plt.show()
```

/var/folders/ny/hmwn2lfx3sv6m4gglsj8qjk40000gn/T/ipykernel_15418/3227309692.py:6: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.barplot(x=age_counts.index, y=age_counts.values, palette='crest')
```



Le graphique montre une majorité d'individus âgés de 30 à 54 ans, avec une forte concentration dans les tranches 30-44 ans (près de 6000 personnes) et 45-54 ans (environ 5500). Les moins de 30 ans ainsi que les 55 ans et plus sont minoritaires. Cette structure démographique, centrée sur les actifs, est cohérente avec l'objectif d'analyser les conditions de travail.

In [33]: data_cl1.shape

Out[33]: (15407, 135)

La variable d'âge (AGE) a d'abord été analysée à l'aide de statistiques descriptives. Pour limiter l'effet des valeurs extrêmes et cibler une population active typique, seules les observations comprises entre les 1er et 99e percentiles (soit de 24 à 64 ans) ont été conservées, ce qui représente 15 407 individus. L'âge a ensuite été catégorisé en quatre classes : « Moins de 30 ans », « 30-44 ans », « 45-54 ans » et « 55 ans et plus », afin de faciliter les comparaisons entre groupes.

Recodage des variables du MBI

Épuisement émotionnel (9 items):

Q01 - « Je me sens émotionnellement vidé(e) » : MIN3EDM_d

- Vous vous sentiez presque tout le temps fatigué(e), sans énergie, et ce presque tous les jours
- Codée : 0 = Non, 1 = Oui

In [34]: # Création de la variable synthétique pour Q01 - Être émotionnellement vidé(e)
data_cl1['emotionnellement_vide'] = data_cl1['MIN3EDM_d']

La variable MIN3EDM_d a été choisie car elle reflète bien l'état de fatigue intense et de manque d'énergie recherché dans cette question. Elle mesure directement si la personne s'est sentie fatiguée presque tous les jours, ce qui correspond bien à un épuisement émotionnel. La variable est binaire et utilisable sans recodage.

Q02 - Je me sens à bout à la fin de la journée : MIN4TAG_c

- Vous sentir fatigué(e), faible ou facilement épuisé(e) ?
- Codée : 0 = Non, 1 = Oui

```
In [35]: # Création de la variable synthétique pour Q02 – Être à bout
data_cl1['a_bout_fin_journee'] = data_cl1['MIN4TAG_c']
```

La variable MIN4TAG_c a été retenue car elle évalue le fait de se sentir faible ou facilement épuisé(e), ce qui est proche de la notion d'être « à bout ». Elle permet de capter une forme d'épuisement généralisé, pertinent pour cet item du MBI. Elle est elle aussi déjà codée en 0/1.

Q03 – Je me sens fatigué(e) le matin : RPC1D

- Je me suis réveillé(e) en me sentant frais(che) et dispos(e)
- Codée en fréquence

```
In [36]: def recoder_rpc1d(x):
    if x in [4, 5, 6]:
        return 1 # fatigue ressentie
    elif x in [1, 2, 3]:
        return 0 # forme ressentie
    else:
        return np.nan # NSP / Refus / manquant

data_cl1['fatigue_matinale'] = data_cl1['RPC1D'].apply(recoder_rpc1d)
```

La variable RPC1D, qui mesure la fréquence à laquelle l'enquêté(e) se sent réveillé(e) en forme, a été recodée de manière binaire afin de capturer l'épuisement matinal. Les modalités indiquant un état de forme faible ou absent (réponses 4 à 6 : « moins de la moitié du temps », « de temps en temps », « jamais ») ont été codées 1, correspondant à un ressenti de fatigue au réveil. Les réponses indiquant un bon état de forme (réponses 1 à 3) ont été codées 0. Les non-réponses (8 et 9) ont été conservées en valeurs manquantes.

Q06 – Travailler avec des gens me demande beaucoup d'effort : CALMER, DETRESSE, CONFLIT

- Pour représenter cette dimension de l'épuisement relationnel, trois variables ont été sélectionnées : CALMER (devoir calmer des personnes en tension), DETRESSE (être en contact avec des personnes en détresse) et CONFLIT (gérer des conflits).
- Elles traduisent chacune un effort émotionnel ou relationnel intense dans les interactions de travail. Combinées, elles permettent d'identifier les personnes exposées à un niveau élevé de sollicitation relationnelle, au cœur de la charge affective mesurée par la Q06 du MBI

```
In [37]: def recodage_binaire_ct(x):
    if x == 1:
        return 1
    elif x == 2:
        return 0
    else:
        return np.nan # pour 8, 9 ou valeurs manquantes

data_cl1['CALMER_b'] = data_cl1['CALMER'].apply(recodage_binaire_ct)
data_cl1['DETRESSE_b'] = data_cl1['DETRESSE'].apply(recodage_binaire_ct)
data_cl1['CONFLIT_b'] = data_cl1['CONFLIT'].apply(recodage_binaire_ct)
```

```
In [38]: # Création de l'indicateur effort relationnel à partir de 3 variables binaires
data_cl1['effort_relationnel'] = data_cl1[['CALMER_b', 'DETRESSE_b', 'CONFLIT_b']].apply(
    lambda row:
        1 if row.sum(skipna=True) >= 2 # → 1 si au moins deux des trois situations sont présentes
        else (0 if row.notna().any() else np.nan), # → 0 si une seule (ou aucune) situation mais au moins une r
    axis=1 # → calcul appliqué ligne par ligne
)
```

Ce code permet de créer une nouvelle variable appelée effort_relationnel, qui synthétise trois indicateurs binaires (CALMER_b, DETRESSE_b, CONFLIT_b). Pour chaque individu, la fonction :

- attribue la valeur 1 si au moins deux des trois situations sont présentes (c'est-à-dire si la somme des trois variables vaut 2 ou 3),
- attribue 0 si au moins une des trois variables est renseignée, mais que la personne ne cumule aucune ou une seule situation,
- et laisse NaN si aucune des trois réponses n'est disponible (c'est-à-dire que toutes les valeurs sont manquantes).

Ce recodage permet d'identifier les individus exposés à un effort relationnel élevé, sans forcer de valeur s'il n'y a pas assez d'information.

Q08 – Je sens que je craque à cause du travail :

- Un indicateur binaire intitulé risque_craquage a été construit à partir de quatre variables mesurant différentes

formes de tension au travail : le fait de travailler sous pression (RPA2A), de devoir penser à trop de choses à la fois (RPA2B), de ruminer son travail en dehors des heures (RPA2C) et de vivre des changements imprévisibles (RPA2F). Ces situations sont autant de signaux d'un stress chronique pouvant mener à un épuisement émotionnel. L'indicateur prend la valeur 1 lorsque l'individu cumule au moins trois de ces situations, traduisant ainsi un profil à risque élevé de "craquage" psychologique.

```
In [39]: # Fonction de recodage binaire adaptée au codage 1-4 (fréquence)
def recoder_rpa2(x):
    if x in [1, 2]:          # Toujours ou souvent → exposition forte
        return 1
    elif x in [3, 4]:        # Parfois ou jamais → exposition faible
        return 0
    else:
        return np.nan        # Refus, NSP, ou manquant

# Recodage des 4 variables
data_cl1['RPA2A_b'] = data_cl1['RPA2A'].apply(recoder_rpa2)
data_cl1['RPA2B_b'] = data_cl1['RPA2B'].apply(recoder_rpa2)
data_cl1['RPA2C_b'] = data_cl1['RPA2C'].apply(recoder_rpa2)
data_cl1['RPA2F_b'] = data_cl1['RPA2F'].apply(recoder_rpa2)

# Création de l'indicateur "risque_craquage" : 1 si au moins 3 situations sur 4
data_cl1['risque_craquage'] = data_cl1[['RPA2A_b', 'RPA2B_b', 'RPA2C_b', 'RPA2F_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 3 else (0 if row.notna().any() else np.nan),
    axis=1
)

# Vérification
print("Indicateur 'risque_craquage' créé avec succès.")
print("Distribution :\n", data_cl1['risque_craquage'].value_counts(dropna=False))
```

```
Indicateur 'risque_craquage' créé avec succès.
Distribution :
risque_craquage
0.0    10851
1.0     3773
NaN       783
Name: count, dtype: int64
```

Q13 – Je me sens frustré(e) :

- Un indicateur binaire intitulé frustration a été construit à partir de trois situations fréquemment sources de tension psychologique : devoir réaliser des tâches hors de son périmètre (RP22P), devoir cacher ses émotions ou simuler un état d'esprit positif (RPA2I), et être contraint(e) de faire des choses que l'on désapprouve (RPA2H). Ces situations traduisent un manque d'autonomie, de reconnaissance ou d'alignement éthique au travail. L'indicateur prend la valeur 1 lorsqu'au moins deux de ces trois tensions sont présentes, ce qui reflète un niveau élevé de frustration ressentie.

```
In [40]: # Fonction de recodage : 1 ou 2 = exposition forte → 1 ; 3 ou 4 = faible → 0 ; autres = NaN
def recoder_frustration(x):
    if x in [1, 2]:
        return 1
    elif x in [3, 4]:
        return 0
    else:
        return np.nan

# Recodage des trois variables
data_cl1['RP22P_b'] = data_cl1['RP22P'].apply(recoder_frustration)
data_cl1['RPA2I_b'] = data_cl1['RPA2I'].apply(recoder_frustration)
data_cl1['RPA2H_b'] = data_cl1['RPA2H'].apply(recoder_frustration)

# Création de l'indicateur : frustration élevée si au moins 2 réponses sur 3
data_cl1['frustration'] = data_cl1[['RP22P_b', 'RPA2I_b', 'RPA2H_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else (0 if row.notna().any() else np.nan),
    axis=1
)

# Vérification
print("Indicateur 'frustration' créé avec succès.")
print("Distribution :\n", data_cl1['frustration'].value_counts(dropna=False))
```

```
Indicateur 'frustration' créé avec succès.
Distribution :
frustration
0.0    13105
1.0     1517
NaN       785
Name: count, dtype: int64
```

Q14 – Je travaille trop dur :

- Un indicateur binaire intitulé travail_intensif a été construit à partir de trois dimensions complémentaires : le fait de travailler sous pression (RPA2A), de devoir prolonger sa journée au-delà des horaires prévus (HSUP), et d'être

contacté en dehors de ses heures de travail pour des raisons professionnelles (JOINDRE). Ces variables traduisent différentes formes d'intensification du travail, qu'elles soient perçues (pression), temporelles (heures supplémentaires) ou psychologiques (envahissement de la vie privée). Chacune a été recodée en 1 si la situation était fréquente (toujours/souvent ou oui), et en 0 sinon. L'indicateur prend la valeur 1 lorsqu'au moins deux de ces trois contraintes sont présentes, révélant ainsi un niveau élevé d'intensité professionnelle.

```
In [41]: # Recodage pour RPA2A et HSUP
def recoder_rpa2a_hsup(x):
    if x in [1, 2]:
        return 1
    elif x in [3, 4]:
        return 0
    else:
        return np.nan

# Recodage pour JOINDRE (oui/non)
def recoder_joindre(x):
    if x == 1:
        return 1
    elif x == 2:
        return 0
    else:
        return np.nan

# Application du recodage
data_cl1['RPA2A_b'] = data_cl1['RPA2A'].apply(recoder_rpa2a_hsup)
data_cl1['HSUP_b'] = data_cl1['HSUP'].apply(recoder_rpa2a_hsup)
data_cl1['JOINDRE_b'] = data_cl1['JOINDRE'].apply(recoder_joindre)

# Création de l'indicateur : au moins 2 situations sur 3
data_cl1['travail_intensif'] = data_cl1[['RPA2A_b', 'HSUP_b', 'JOINDRE_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else (0 if row.notna().any() else np.nan),
    axis=1
)

# Vérification
print("Indicateur 'travail_intensif' créé avec succès.")
print("Distribution :\n", data_cl1['travail_intensif'].value_counts(dropna=False))
```

Indicateur 'travail_intensif' créé avec succès.

Distribution :

travail intensif

0.0 10508

1.0 4882

NaN 17

Name: count, dtype: int64

Q16 - Le contact direct me stresse :

- Pour représenter la question Q16 « Le contact direct me stresse », nous avons construit un indicateur nommé stress_contact. Il prend la valeur 1 si la personne est en contact direct avec le public et cumule au moins deux formes de charge émotionnelle : bouleversement personnel (SOC24), tension relationnelle (SOC17) ou est en contact avec des personnes en situation de détresse (SOC21). Ce critère croisé permet de cibler les situations professionnelles à forte intensité émotionnelle liées à l'exposition au public, en cohérence avec la formulation du MBI.

```
In [42]: # Recodage EMOTION (bouleversement émotionnel fréquent)
# Modalités : 1 = Tous les jours, 2 = Souvent, 3 = Parfois, 4 = Jamais, 8/9 = NSP/refus
def recoder_EMOTION(x):
    if x in [1, 2, 3]: # forte ou modérée exposition
        return 1
    elif x == 4: # jamais
        return 0
    else:
        return np.nan # valeurs manquantes, refus ou NSP

# Recodage binaire standard (Oui = 1, Non = 2, 8/9 = NSP/refus)
def recoder_TENSION1_DETRESSE_PUBLIC(x):
    if x == 1:
        return 1
    elif x == 2:
        return 0
    else:
        return np.nan

# Application du recodage
data_cl1['EMOTION_b'] = data_cl1['EMOTION'].apply(recoder_EMOTION)
data_cl1['DETRESSE_b'] = data_cl1['DETRESSE'].apply(recoder_TENSION1_DETRESSE_PUBLIC)
data_cl1['TENSION1_b'] = data_cl1['TENSION1'].apply(recoder_TENSION1_DETRESSE_PUBLIC)
data_cl1['PUBLIC_b'] = data_cl1['PUBLIC'].apply(recoder_TENSION1_DETRESSE_PUBLIC)
```

```
In [43]: data_cl1['stress_contact'] = data_cl1[['TENSION1_b', 'DETRESSE_b', 'EMOTION_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else 0,
    axis=1
```

```

)

# Filtrer pour que PUBLIC soit obligatoire
data_cl1['stress_contact'] = data_cl1.apply(
    lambda row: 1 if row['PUBLIC_b'] == 1 and row['stress_contact'] == 1
    else (0 if row['PUBLIC_b'] == 1 and row[['TENSION1_b', 'DETRESSE_b', 'EMOTION_b']].notna().any()
          else np.nan),
    axis=1
)

# Vérification
print("Indicateur 'stress_contact' créé avec succès.")
print("Distribution :\n", data_cl1['stress_contact'].value_counts(dropna=False))

```

Indicateur 'stress_contact' créé avec succès.

Distribution :

stress_contact	
1.0	7619
0.0	4099
NaN	3689

Name: count, dtype: int64

Q20 – Je suis au bout du rouleau :

- Afin d’approcher la perception d’un épuisement généralisé au travail, la variable Q20 a été construite à partir de deux indicateurs complémentaires : MIN4TAG_b, qui mesure la tension physique ressentie à travers la question « Avez-vous les muscles tendus ? », et RPA2B, qui capture une surcharge mentale (« Je dois penser à trop de choses à la fois »). Ces deux dimensions – physique et cognitive – traduisent ensemble un état de saturation compatible avec le sentiment d’être « au bout du rouleau ». Un individu est donc considéré en situation critique s’il cumule au moins une réponse positive parmi ces deux manifestations.

```

In [44]: # Recoder RPA2B : 1 (Toujours) ou 2 (Souvent) => 1 / 3 ou 4 => 0 / Autre => NaN
def recoder_rpa2b(x):
    if x in [1, 2]:
        return 1
    elif x in [3, 4]:
        return 0
    else:
        return np.nan

# Appliquer le recodage
data_cl1['RPA2B_b'] = data_cl1['RPA2B'].apply(recoder_rpa2b)

# Créer la variable 'au_bout_du_rouleau'
data_cl1['au_bout_du_rouleau'] = data_cl1.apply(
    lambda row: 1 if row['MIN4TAG_b'] == 1 and row['RPA2B_b'] == 1 else (
        0 if row['MIN4TAG_b'] in [0,1] and row['RPA2B_b'] in [0,1] else np.nan
    ),
    axis=1
)

# Afficher la distribution
print("Variable 'au_bout_du_rouleau' créée avec succès.")
print(data_cl1['au_bout_du_rouleau'].value_counts(dropna=False))

```

Variable 'au_bout_du_rouleau' créée avec succès.

au_bout_du_rouleau

0.0	14199
NaN	799
1.0	409

Name: count, dtype: int64

Déshumanisation (5 items):

Q05 – Je m’occupe des autres comme des objets :

- Pour cette question, nous avons retenu les variables RP22j, RP22n et RP22o, car elles traduisent des formes concrètes de déshumanisation dans le travail : faire des tâches dégradantes (RP22j), traiter injustement des personnes (RP22n), ou exercer une contrainte sur autrui (RP22o). Ces situations correspondent à une perte de reconnaissance de l’autre en tant qu’individu, ce qui reflète bien le sens de la question. Chaque variable a été recodée en binaire (1 = exposition fréquente), et un indicateur a été créé : il vaut 1 si au moins deux de ces situations sont vécues, signalant un rapport dépersonnalisé au travail des autres.

```

In [45]: def recoder_deshumanisation(x):
    if x in [1, 2]: # Toujours, Souvent
        return 1
    elif x in [3, 4]: # Parfois, Jamais
        return 0
    else: # 8 = Refus, 9 = NSP, ou valeurs manquantes
        return np.nan

# Application du recodage
data_cl1['RP22j_b'] = data_cl1['RP22j'].apply(recoder_deshumanisation)

```

```
data_cl1['RP22N_b'] = data_cl1['RP22N'].apply(recoder_deshumanisation)
data_cl1['RP220_b'] = data_cl1['RP220'].apply(recoder_deshumanisation)

# Création de l'indicateur synthétique de déshumanisation
data_cl1['deshumanisation'] = data_cl1[['RP22J_b', 'RP22N_b', 'RP220_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else (0 if row.notna().any() else np.nan),
    axis=1
)

# Vérification
print("Indicateur 'deshumanisation' créé avec succès.")
print(data_cl1['deshumanisation'].value_counts(dropna=False))
```

Indicateur 'deshumanisation' créé avec succès.

```
deshumanisation
0.0    14476
NaN      792
1.0     139
Name: count, dtype: int64
```

Q10 – Je suis devenu(e) plus insensible :

- Pour approcher la dimension de déshumanisation à travers la perte de sensibilité, nous avons mobilisé deux indicateurs issus du module sur les troubles dépressifs : MIN4EDM (épisodes prolongés de dépression ou d'anhédonie) et MIN2EDM (perte d'intérêt ou de plaisir au cours des deux dernières semaines). Ces deux variables permettent d'identifier une forme d'émoussement émotionnel durable ou récent, qui peut s'apparenter à une insensibilité progressive. Cette stratégie est justifiée par l'absence d'une mesure directe du sentiment d'être devenu(e) plus insensible, et permet ainsi de capter indirectement un désengagement émotionnel prolongé dans le cadre du travail. L'indicateur final est codé à 1 dès lors qu'une des deux situations est présente.

In [46]: # Fonction de recodage binaire : 1 = Oui, 0 = Non, NaN = NSP/Refus

```
def recoder_min_edm(x):
    if x == 1:
        return 1
    elif x == 2:
        return 0
    else:
        return np.nan

# Application du recodage aux deux variables
data_cl1['MIN2EDM_b'] = data_cl1['MIN2EDM'].apply(recoder_min_edm)

# Création de l'indicateur insensibilité
data_cl1['insensibilite'] = data_cl1['MIN2EDM_b']

# Vérification
print("Indicateur 'insensibilite' créé avec succès.")
print(data_cl1['insensibilite'].value_counts(dropna=False))
```

Indicateur 'insensibilite' créé avec succès.

```
insensibilite
0.0    13748
1.0    1637
NaN      22
Name: count, dtype: int64
```

Q11 – Ce travail m'endurcit émotionnellement :

- Pour représenter le sentiment d'endurcissement émotionnel au travail, nous avons retenu quatre items traduisant une exposition à des pratiques professionnelles contraires aux valeurs personnelles : faire des choses inutiles ou dégradantes (RP22j), devoir mentir à des usagers ou collègues (RP22k), traiter injustement certaines personnes (RP22n), et accomplir des tâches que l'on désapprouve (RPA2H). Ces situations, lorsqu'elles se répètent, peuvent générer une forme de désensibilisation affective. L'indicateur binaire construit prend la valeur 1 si l'individu cumule au moins deux de ces expériences, traduisant ainsi une exposition marquée à des tensions morales susceptibles d'endurcir émotionnellement.

In [47]: # Fonction de recodage des variables à 4 modalités (1 à 4)

```
def recoder_exposition(x):
    if x in [1, 2, 3]: # Exposition élevée
        return 1
    elif x == 4:      # Jamais
        return 0
    else:
        return np.nan # Refus / NSP / Manquants

# Application du recodage
data_cl1['RP22K_b'] = data_cl1['RP22K'].apply(recoder_exposition)

# Création de l'indicateur "endurcissement" : au moins 2 situations sur 4
data_cl1['endurcissement'] = data_cl1[['RP22J_b', 'RP22K_b', 'RP22N_b', 'RPA2H_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else (0 if row.notna().any() else np.nan),
    axis=1
)
```

```
)

#Vérification
print("Indicateur 'endurcissement' créé avec succès.")
print(data_cl1['endurcissement'].value_counts(dropna=False))
```

```
Indicateur 'endurcissement' créé avec succès.
endurcissement
0.0    13643
1.0     978
NaN     786
Name: count, dtype: int64
```

Q15 – Je me fiche de certains clients :

- Afin d’approcher l’attitude d’indifférence ou de détachement vis-à-vis des bénéficiaires, nous avons construit un indicateur basé sur trois items pertinents : « Je dois mentir à des clients, des patients, des usagers, des collègues » (RP22k), « Je suis amené(e) à traiter injustement ou à favoriser des personnes » (RP22n), et « Je dois prendre des risques pour la santé physique et mentale des usagers, des clients, des patients, des collègues » (RP22m). Chacun de ces items a été recodé pour identifier les expositions fréquentes. L’indicateur synthétique indiff_client prend la valeur 1 dès lors qu’au moins deux de ces situations sont rapportées, reflétant un certain degré de distanciation ou de désengagement vis-à-vis des personnes concernées. Ce choix s’ancre dans la littérature sur la déshumanisation et la banalisation des risques en contexte professionnel.

```
In [48]: # Recodage de RP22m : 1/2/3 = exposition fréquente, 4 = jamais, 8/9 = refus/NSP
def recoder_rp22m(x):
    if x in [1, 2, 3]:
        return 1
    elif x == 4:
        return 0
    else:
        return np.nan

data_cl1['RP22M_b'] = data_cl1['RP22M'].apply(recoder_rp22m)

# Création de l'indicateur "indiff_client"
data_cl1['indiff_client'] = data_cl1[['RP22K_b', 'RP22N_b', 'RP22M_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else (0 if row.notna().any() else np.nan),
    axis=1
)
```

Q22 – On me rend responsable de leurs problèmes :

- Pour estimer le sentiment d’être tenu responsable de difficultés au travail, nous avons mobilisé trois variables issues de la section 7B : RPB1D (« critique injustement votre travail »), RPB1C (« vous ridiculise en public »), et RPB1B (« vous empêche de vous exprimer »). Ces comportements, lorsqu’ils sont subis de manière répétée, traduisent une forme de disqualification ou de mise en accusation pouvant nourrir un sentiment d’injustice et de culpabilisation injustifiée. Chaque variable a été recodée de manière binaire (1 = Oui, 0 = Non, NaN = Refus/NSP), et un indicateur synthétique reproche_responsabilite a été créé. Il prend la valeur 1 si au moins deux des trois situations sont rapportées, et 0 sinon. Ce choix permet d’identifier les environnements professionnels particulièrement hostiles, où les interactions sociales nuisent à l’estime de soi et renforcent une responsabilisation excessive de l’individu face aux dysfonctionnements.

```
In [49]: # Fonction de recodage binaire : 1 = Oui, 0 = Non, NaN = Refus ou NSP
def recoder_reproche(x):
    if x == 1:
        return 1
    elif x == 2:
        return 0
    else:
        return np.nan

# Application du recodage
data_cl1['RPB1B_b'] = data_cl1['RPB1B'].apply(recoder_reproche)
data_cl1['RPB1C_b'] = data_cl1['RPB1C'].apply(recoder_reproche)
data_cl1['RPB1D_b'] = data_cl1['RPB1D'].apply(recoder_reproche)

# Création de l'indicateur : au moins 2 situations sur 3 rapportées
data_cl1['reproche_responsabilite'] = data_cl1[['RPB1B_b', 'RPB1C_b', 'RPB1D_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else (0 if row.notna().any() else np.nan),
    axis=1
)

# Vérification
print(data_cl1['reproche_responsabilite'].value_counts(dropna=False))

reproche_responsabilite
0.0    13305
1.0    1310
NaN     792
Name: count, dtype: int64
```

```
In [50]: data_cl1.shape
```

```
Out[50]: (15407, 173)
```

Accomplissement personnel (8 items):

Q04 – Je comprends facilement les autres :

- Pour approcher cette dimension relationnelle, nous avons retenu deux variables complémentaires. D’une part, RPB5F renseigne sur le sentiment d’appartenance à une équipe, qui suppose écoute, compréhension mutuelle et bonne intégration sociale. D’autre part, SOC22 (CALMER) mesure la capacité à apaiser autrui dans des contextes émotionnellement tendus, ce qui mobilise des compétences empathiques et de régulation affective. Ces deux variables ont été recodées en binaire, et l’indicateur `comprehension_autrui` prend la valeur 1 lorsque les deux conditions sont réunies. Ce choix vise à isoler les individus démontrant à la fois une sensibilité émotionnelle et une intégration relationnelle forte dans le milieu professionnel.

```
In [51]: # Recodage RPB5F
def recoder_rpb5f(x):
    if x in [1, 2, 3]: # toujours / souvent / parfois
        return 1
    elif x == 4:      # jamais
        return 0
    else:
        return np.nan

# Recodage SOC22 (CALMER)
def recoder_calmer(x):
    if x == 1: # Oui
        return 1
    elif x == 2: # Non
        return 0
    else:
        return np.nan

# Application
data_cl1['RPB5F_b'] = data_cl1['RPB5F'].apply(recoder_rpb5f)
data_cl1['CALMER_b'] = data_cl1['CALMER'].apply(recoder_calmer)

# Indicateur Q04 : compréhension interpersonnelle
data_cl1['comprehension_autrui'] = np.where(
    (data_cl1['RPB5F_b'] == 1) & (data_cl1['CALMER_b'] == 1),
    1,
    0
)
```

Q07 – J’aide efficacement :

- Pour refléter le sentiment d’efficacité dans l’aide apportée aux autres, nous avons retenu trois variables complémentaires : RPB5A (fierté du travail bien fait), RPB5B (rendre des services utiles) et CORRCOP (coopération, échange avec collègues). Les deux premières proviennent du module sur la coopération et évaluent directement la fréquence d’actions perçues comme utiles. La troisième, bien que plus générale, permet de capter une dynamique d’entraide effective. Chacune a été recodée en binaire (1 = aide présente, 0 = jamais, NaN = NSP/refus), et l’indicateur final prend la valeur 1 si au moins deux de ces comportements sont rapportés. Ce seuil garantit que l’individu adopte une posture active d’aide, compatible avec la formulation de l’item du MBI.

```
In [52]: import numpy as np

# Recodage pour RPB5A et RPB5B : fréquences (1 = Toujours, 2 = Souvent, 3 = Parfois, 4 = Jamais, 8/9 = Refus/NS)
def recoder_rpb5(x):
    if x in [1, 2, 3]: # exposition positive
        return 1
    elif x == 4:      # jamais
        return 0
    else:
        return np.nan

# Recodage pour CORRCOP (OUT3) : Oui/Non
def recoder_corrCop(x):
    if x == 1: # Oui
        return 1
    elif x == 2: # Non
        return 0
    else:
        return np.nan

# Application du recodage
data_cl1['RPB5A_b'] = data_cl1['RPB5A'].apply(recoder_rpb5)
data_cl1['RPB5B_b'] = data_cl1['RPB5B'].apply(recoder_rpb5)
data_cl1['CORRCOP_b'] = data_cl1['CORRCOP'].apply(recoder_corrCop)

# Création de l'indicateur binaire "aide_efficace"
```

```
data_cl1['aide_efficace'] = np.where(
    (data_cl1[['RPB5A_b', 'RPB5B_b', 'CORRCOP_b']].sum(axis=1) >= 2),
    1, 0
)
```

Q09 – J’ai une influence positive :

- Afin de mesurer le sentiment de contribuer positivement à autrui dans le cadre du travail, nous avons retenu la variable RPB5B, qui interroge la fréquence à laquelle les personnes ont l’impression de faire quelque chose d’utile aux autres. Cette variable capte le cœur de la question posée, en se concentrant sur l’utilité perçue de l’action professionnelle. Pour l’analyse, les réponses « Toujours », « Souvent » et « Parfois » ont été regroupées sous la modalité 1, tandis que la réponse « Jamais » a été codée en 0, les autres modalités (NSP, refus) étant traitées comme valeurs manquantes. Ce recodage permet d’identifier les individus qui expriment une forme de reconnaissance du sens de leur travail.

```
In [53]: # Création de la variable synthétique pour Q09 – Influence positive
data_cl1['influence_positive'] = data_cl1['RPB5B_b']
```

Q12 – Je me sens plein(e) d’énergie :

- Afin de synthétiser l’information relative au sentiment de vigueur et d’énergie au travail, nous avons créé la variable vitalite_positive à partir de la variable recodée RPC1C_b. Cette variable binaire prend la valeur 1 lorsque la personne a déclaré se sentir fréquemment pleine d’énergie (tout le temps, la plupart du temps ou plus de la moitié du temps), et 0 lorsqu’elle a exprimé une faible fréquence ou une absence de vitalité. Cet indicateur reflète la dimension de vitalité psychologique, souvent opposée à l’épuisement émotionnel, et joue un rôle important dans l’évaluation de la santé mentale au travail.

```
In [54]: # Recodage de RPC1C : Je me suis senti(e) plein(e) d’énergie et vigoureux(se)
def recoder_rpc1c(x):
    if x in [1, 2, 3]: # Sentiment fréquent d’énergie
        return 1
    elif x in [4, 5, 6]: # Faible fréquence ou absence d’énergie
        return 0
    else:
        return np.nan # NSP, Refus, etc.

# Application
data_cl1['RPC1C_b'] = data_cl1['RPC1C'].apply(recoder_rpc1c)

# Création de la variable synthétique vitalite_positive (copie directe de RPC1C_b)
data_cl1['vitalite_positive'] = data_cl1['RPC1C_b']
```

Q17 – Je crée une atmosphère détendue :

- Pour la question Q17 – « Je crée une atmosphère détendue », aucune variable de l’enquête CT-RPS 2016 ne correspond directement à cette dimension. Les items disponibles portent plutôt sur la coopération, l’aide reçue ou les tensions au sein des équipes, mais ne permettent pas de mesurer la capacité individuelle à apaiser l’ambiance de travail. Afin de garantir la pertinence et la cohérence de notre indicateur de burn-out, nous avons donc choisi de ne pas inclure de variable pour cette question. Cette absence sera compensée par une pondération plus forte accordée aux autres items positifs du sentiment d’accomplissement personnel.

Q18 – Le contact avec les autres me ragaillardit :

- Pour approcher le sentiment de revitalisation lié aux interactions sociales, nous avons construit une variable synthétique croisant deux indicateurs : la variable PUBLIC, qui identifie les personnes en contact direct avec des usagers, clients ou patients, et la variable RPC1A, qui mesure la fréquence à laquelle l’individu s’est senti « bien et de bonne humeur » au cours des deux dernières semaines. Cette dernière a été recodée de manière binaire : une bonne humeur jugée fréquente (modalités « tout le temps » ou « la plupart du temps ») a été codée 1, les autres modalités 0. L’indicateur final, nommé contact_energisant, prend la valeur 1 lorsque ces deux conditions sont réunies, traduisant un effet régénérateur attribué au contact social. Ce croisement permet d’identifier les situations où la sociabilité au travail est non seulement présente, mais aussi vécue de manière positive et énergisante.

```
In [55]: # Recodage de RPC1A : bonne humeur fréquente (1 = Tout le temps, 2 = La plupart du temps)
def recoder_rpc1a(x):
    if x in [1, 2]:
        return 1 # Bonne humeur fréquente
    elif x in [3, 4, 5, 6]:
        return 0
    else:
        return np.nan

# Application des recodages
data_cl1['RPC1A_b'] = data_cl1['RPC1A'].apply(recoder_rpc1a)

# Création de la variable synthétique : contact social perçu comme énergisant
data_cl1['contact_energisant'] = np.where(
```

```

    (data_cl1['RPC1A_b'] == 1) & (data_cl1['PUBLIC_b'] == 1),
    1,
    0
)

# Optionnel : remplacer les cas où une des deux variables est manquante par NaN
data_cl1.loc[data_cl1[['RPC1A_b', 'PUBLIC_b']].isnull().any(axis=1), 'contact_energisant'] = np.nan

```

Q19 – J’ai accompli beaucoup de choses :

- Pour représenter le sentiment d’accomplissement personnel (Q19), nous avons combiné trois variables : RPB5A (« vous sentez que vous faites du bon travail »), RPB5B (« vous aidez efficacement les personnes dont vous avez la charge ») et RPB5F (« vous pensez que vous faites partie d’une équipe »). Ces items traduisent chacun une dimension clé de l’accomplissement professionnel : efficacité, utilité sociale et qualité perçue. Chacune a été recodée en binaire (1 = accord, 0 = désaccord, NaN sinon), puis regroupée dans un indicateur synthétique qui vaut 1 si au moins deux des trois dimensions sont remplies. Ce seuil permet d’identifier les répondants qui ressentent de manière globale un haut niveau d’accomplissement dans leur activité.

```

In [56]: # Création de la variable synthétique "accomplissement"
data_cl1['accomplissement'] = data_cl1[['RPB5A_b', 'RPB5B_b', 'RPB5F_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else (0 if row.notna().any() else np.nan),
    axis=1
)

# Vérification
print("Variable 'accomplissement' créée avec succès.")
print(data_cl1['accomplissement'].value_counts(dropna=False))

```

```

Variable 'accomplissement' créée avec succès.
accomplissement
1.0    14339
NaN      781
0.0     287
Name: count, dtype: int64

```

Q21 – Je gère calmement les problèmes :

- Pour représenter la stabilité émotionnelle face aux difficultés, nous avons mobilisé trois indicateurs : CALMER (garde son calme en situation difficile), CONFLIT (capacité à désamorcer les conflits) et RPC1B (se sentir détendu). Ces dimensions complémentaires traduisent la faculté à rester posé face aux tensions. Chacune a été recodée en binaire : 1 si le répondant se déclare stable, 0 sinon. L’indicateur synthétique stabilite_emo prend la valeur 1 si au moins deux de ces trois conditions sont réunies, afin de refléter une gestion émotionnelle globalement positive. Cette approche permet de mieux cerner la résilience individuelle dans un contexte professionnel

```

In [57]: # Recode RPC1B (calme et tranquille)
def recoder_rpc1b(x):
    if x in [1, 2, 3]: # Fréquence élevée de calme
        return 1
    elif x in [4, 5, 6]: # Fréquence faible de calme
        return 0
    else:
        return np.nan # Refus / NSP / autres

# Inverser MIN4TAG_e (1 = irritable → devient 0 / 0 = non irritable → devient 1)
def recoder_min4tag_e(x):
    if x == 1:
        return 0
    elif x == 0:
        return 1
    else:
        return np.nan

# Application
data_cl1['RPC1B_b'] = data_cl1['RPC1B'].apply(recoder_rpc1b)
data_cl1['MIN4TAG_e_b'] = data_cl1['MIN4TAG_e'].apply(recoder_min4tag_e)

# Création de l'indicateur : stabilité émotionnelle si au moins 2 critères sur 3 sont remplis
data_cl1['stabilite_emo'] = data_cl1[['CALMER_b', 'CONFLIT_b', 'RPC1B_b']].apply(
    lambda row: 1 if row.sum(skipna=True) >= 2 else (0 if row.notna().any() else np.nan),
    axis=1
)

```

```

In [58]: data_cl1.shape

```

```

Out[58]: (15407, 188)

```

Gestion des valeurs manquantes des variables de burnout :

```

In [59]: # Liste des variables à vérifier
variables_burnout = [
    'MIN3EDM_d', 'MIN4TAG_c', 'RPC1D',

```

```

'CALMER_b', 'DETRESSE_b', 'CONFLIT_b',
'RPA2A_b', 'RPA2B_b', 'RPA2C_b', 'RPA2F_b',
'RP22P_b', 'RPA2I_b', 'RPA2H_b',
'HSUP_b', 'JOINDRE_b',
'PUBLIC_b', 'TENSION1_b', 'EMOTION_b', 'MIN4TAG_b',
'RP22J_b', 'RP22N_b', 'RP22O_b', 'RP22K_b', 'RP22M_b', 'MIN2EDM_b',
'RPB1B_b', 'RPB1C_b', 'RPB1D_b',
'RPB5F_b', 'RPB5A_b', 'RPB5B_b', 'CORRCOP_b',
'RPC1C_b', 'RPC1A_b', 'RPC1B_b', 'MIN4TAG_e_b'
]

# Affichage du nombre de valeurs manquantes
missing_values1 = data_cl1[variables_burnout].isna().sum().sort_values(ascending=False)
print(missing_values1)

```

```

TENSION1_b      3701
JOINDRE_b       1349
RP22O_b         872
RP22N_b         868
RP22M_b         861
RPB5F_b         855
RPA2F_b         833
RP22K_b         828
RPA2H_b         824
RP22J_b         815
RPA2I_b         810
RP22P_b         809
RPB5A_b         808
RPB5B_b         806
RPB1D_b         805
RPB1B_b         804
RPC1A_b         804
RPB1C_b         800
RPA2A_b         800
RPA2B_b         799
RPC1C_b         797
RPC1B_b         792
RPA2C_b         790
RPC1D_b         766
HSUP_b          136
CORRCOP_b        36
DETRESSE_b       31
MIN2EDM_b       22
EMOTION_b       16
CONFLIT_b       16
CALMER_b        14
PUBLIC_b        10
MIN3EDM_d        0
MIN4TAG_b        0
MIN4TAG_c        0
MIN4TAG_e_b      0
dtype: int64

```

Calcul du score pour chaque dimension

1. Score d'Épuisement émotionnel

- Items : Q01, Q02, Q03, Q06, Q08, Q13, Q14, Q16, Q20
- Variables : emotionnellement_vide, a_bout, MBI_Q03_b, effort_relationnel, risque_craquage, frustration, travail_intensif, stress_contact, au_bout_du_rouleau

```

In [60]: # Score d'épuisement émotionnel (somme des 9 indicateurs)
data_cl1['score_epuisement'] = data_cl1[[
    'emotionnellement_vide',
    'a_bout_fin_journee',
    'fatigue_matinale',
    'effort_relationnel',
    'risque_craquage',
    'frustration',
    'travail_intensif',
    'stress_contact',
    'au_bout_du_rouleau'
]].sum(axis=1, skipna=False)

```

```

In [61]: print(data_cl1['score_epuisement'].describe())

```



```
count      11127.000000
mean       2.665408
std        1.860527
min         0.000000
25%        1.000000
50%        2.000000
75%        4.000000
max         9.000000
Name: score_epuisement, dtype: float64
```

1. Score de Déshumanisation

- Items : Q05, Q10, Q11, Q15, Q22
- Variables : deshumanisation, insensibilite, endurcissement, indiff_client, reproche_responsabilite

```
In [62]: # Score de déshumanisation (somme des 5 indicateurs)
data_cl1['score_deshumanisation'] = data_cl1[[
    'deshumanisation',
    'insensibilite',
    'endurcissement',
    'indiff_client',
    'reproche_responsabilite'
]].sum(axis=1, skipna=False)
```

```
In [63]: print(data_cl1['score_deshumanisation'].describe())
```

```
count      14571.000000
mean       0.353785
std        0.726649
min         0.000000
25%        0.000000
50%        0.000000
75%        0.000000
max         5.000000
Name: score_deshumanisation, dtype: float64
```

1. Score d'Accomplissement personnel

- Items : Q04, Q07, Q09, Q12, Q18, Q19, Q21 (Rappel : Q17 est non disponible donc score sur 7 items au lieu de 8)
- Variables : comprehension_autrui, aide_efficace, influence_positive, vitalite_positive, contact_energisant, accomplissement, stabilite_emo

```
In [64]: # Score d'accomplissement personnel (somme des 7 indicateurs disponibles)
data_cl1['score_accomplissement'] = data_cl1[[
    'comprehension_autrui',
    'aide_efficace',
    'influence_positive',
    'vitalite_positive',
    'contact_energisant',
    'accomplissement',
    'stabilite_emo'
]].sum(axis=1, skipna=False)
```

```
In [65]: print(data_cl1['score_accomplissement'].describe())
```

```
count      14549.000000
mean       5.317754
std        1.367109
min         0.000000
25%        4.000000
50%        5.000000
75%        7.000000
max         7.000000
Name: score_accomplissement, dtype: float64
```

Comptabilisation pour chaque variable du MBI du nombre de non-réponses volontaires :

```
In [66]: def compter_nsp_refus(serie):
    return ((serie == 8) | (serie == 9)).sum()
variables_mbi_modalites = [
    'RPC1D', 'RPC1C', 'RPC1B', 'RPC1A',
    'MIN2EDM', 'MIN4EDM',
    'RPA2A', 'RPA2B', 'RPA2C', 'RPA2F',
    'RPA2H', 'RPA2I',
    'RP22J', 'RP22K', 'RP22M', 'RP22N', 'RP22O', 'RP22P',
    'RPB5A', 'RPB5B', 'RPB5F',
    'RPB1B', 'RPB1C', 'RPB1D',
    'JOINDRE', 'HSUP', 'PUBLIC', 'CALMER', 'DETRESSE', 'CONFLIT',
    'TENSION1', 'EMOTION'
]
for var in variables_mbi_modalites:
    if var in data_cl1.columns:
```

```
total = computer_nsp_refus(data_cl1[var])
print(f"{var} : {total} refus/NSP")
```

```
RPC1D : 28 refus/NSP
RPC1C : 31 refus/NSP
RPC1B : 32 refus/NSP
RPC1A : 44 refus/NSP
MIN2EDM : 16 refus/NSP
MIN4EDM : 1 refus/NSP
RPA2A : 36 refus/NSP
RPA2B : 35 refus/NSP
RPA2C : 26 refus/NSP
RPA2F : 69 refus/NSP
RPA2H : 60 refus/NSP
RPA2I : 45 refus/NSP
RP22J : 51 refus/NSP
RP22K : 64 refus/NSP
RP22M : 97 refus/NSP
RP22N : 104 refus/NSP
RP22O : 108 refus/NSP
RP22P : 44 refus/NSP
RPB5A : 43 refus/NSP
RPB5B : 41 refus/NSP
RPB5F : 90 refus/NSP
RPB1B : 43 refus/NSP
RPB1C : 39 refus/NSP
RPB1D : 44 refus/NSP
JOINDRE : 10 refus/NSP
HSUP : 130 refus/NSP
PUBLIC : 4 refus/NSP
CALMER : 8 refus/NSP
DETRESSE : 25 refus/NSP
CONFLIT : 10 refus/NSP
TENSION1 : 13 refus/NSP
EMOTION : 10 refus/NSP
```

Construction du score global de burnout

Afin de construire un score global de burn-out à partir des 22 items du Maslach Burnout Inventory (MBI), nous avons additionné les indicateurs binaires (0/1) créés pour chaque question, en respectant les trois dimensions théoriques : l'épuisement émotionnel (9 items), la déshumanisation (5 items) et l'accomplissement personnel (8 items).

Cependant, contrairement aux deux premières dimensions, où un score élevé traduit un niveau élevé de burn-out, la dimension d'accomplissement personnel fonctionne dans le sens inverse : un score élevé indique une bonne estime de soi au travail, donc un niveau faible de burn-out.

Afin de garantir la cohérence du score global, nous avons inversé cette dernière dimension par la formule $8 - \text{score_accomplissement}$, de sorte que les trois composantes évoluent désormais dans le même sens : plus le score est élevé, plus le risque de burn-out est important. Le score global ainsi obtenu varie donc entre 0 (absence totale de symptômes) et 22 (présence maximale de symptômes), et permet une évaluation synthétique et continue du syndrome d'épuisement professionnel dans notre échantillon.

```
In [67]: data_cl1['score_burnout'] = (
        data_cl1['score_epuisement'] +
        data_cl1['score_deshumanisation'] +
        (8 - data_cl1['score_accomplissement'])) # Inversion ici
        )
```

```
In [68]: data_cl1["score_burnout"].describe()
```

```
Out[68]: count    11059.000000
mean         5.412243
std          2.683349
min          1.000000
25%          3.000000
50%          5.000000
75%          7.000000
max          20.000000
Name: score_burnout, dtype: float64
```

```
In [69]: data_cl1.shape
```

```
Out[69]: (15407, 192)
```

Afin de construire un score global de burn-out, nous avons additionné les trois dimensions du MBI : l'épuisement émotionnel, la déshumanisation et l'accomplissement personnel inversé. Toutefois, cette opération nécessite que les trois composantes soient disponibles. En conséquence, seules les observations complètes sur ces trois dimensions ont été conservées ($N = 11\,059$). Plutôt que d'imputer les valeurs manquantes (hypothèses fortes sur la distribution des réponses), nous avons opté pour une approche par cas complets. Ce choix permet de préserver la robustesse


économétrique des estimations futures, en évitant d'introduire un biais lié à une imputation arbitraire. Étant donné la taille encore substantielle de l'échantillon, cette stratégie garantit la fiabilité des résultats sans sacrifier la représentativité des données.

Représentations graphiques des différents scores :

```
In [70]: import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(6, 4))
sns.histplot(data_c11['score_epuisement'], bins=10, kde=True, color='steelblue')

plt.title('Distribution du score d'épuisement émotionnel')
plt.xlabel('Score (0 à 9)')
plt.ylabel('Nombre d'observations')
plt.tight_layout()
plt.show()
```




La distribution du score d'épuisement émotionnel, calculé à partir de 9 items du Maslach Burnout Inventory codés en indicateurs binaires (0/1), révèle une asymétrie marquée à droite. La majorité des individus présente un score faible : la médiane est de 2 et le premier quartile de 1, tandis que le score moyen s'élève à 2,66 sur un maximum de 9. Cette répartition est cohérente avec l'idée selon laquelle l'épuisement émotionnel intense reste minoritaire dans la population active. La forme de la distribution, concentrée entre 0 et 4 (75 % des individus), valide le bon fonctionnement du score et reflète fidèlement la réalité épidémiologique d'un syndrome dont les formes sévères sont peu fréquentes mais bien présentes. Le choix d'un codage binaire et d'une approche par cas complets semble donc approprié pour construire un indicateur robuste et interprétable.

```
In [71]: import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(6, 4))

sns.histplot(data_c11['score_deshumanisation'], bins=6, kde=True, color='steelblue')
plt.title('Distribution du score de déshumanisation')
plt.xlabel('Score (0 à 5)')
plt.ylabel('Nombre d'observations')


plt.tight_layout()
plt.show()
```



La distribution du score de déshumanisation révèle une forte asymétrie à droite. Une très grande majorité des individus obtiennent un score nul (médiane = 0), soit plus de la moitié de l'échantillon, ce qui indique qu'ils ne rapportent aucun comportement associé à cette dimension du burn-out. Le score moyen est très faible (0,35 sur 5) et le score maximal atteint 5, correspondant à la somme des cinq items codés en indicateurs binaires. Cette répartition confirme que les attitudes de retrait, de froideur ou de rejet vis-à-vis des autres (collègues, clients, etc.) sont rares dans l'échantillon. Le pic de densité autour de 0, suivi de quelques vagues mineures aux faibles scores positifs, reflète cette rareté. D'un point de vue épidémiologique, cela suggère que la déshumanisation est une dimension peu exprimée dans la population interrogée – ce qui est rassurant, bien que les cas extrêmes méritent une attention particulière.

```
In [72]: import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(6, 4))
sns.histplot(data_cli['score_accomplissement'], bins=8, kde=True, color='steelblue', edgecolor='black')
plt.title("Distribution du score d'accomplissement personnel")
plt.xlabel("Score (0 à 7)")
plt.ylabel("Nombre d'observations")
plt.tight_layout()
plt.show()
```




Le graphique montre une distribution nettement asymétrique du score d'accomplissement personnel, avec une concentration marquée des observations sur les valeurs hautes, en particulier entre 5 et 7. Cela indique que la majorité des individus interrogés se sentent compétents, efficaces et reconnus dans leur travail. Le pic autour de 5 et la faible fréquence des scores bas confirment que peu de personnes déclarent un faible sentiment d'accomplissement. La distribution en cloche inversée, orientée vers la droite, est cohérente avec les statistiques descriptives : une médiane à 5, une moyenne de 5,3 et un maximum de 7. Ce profil suggère que l'accomplissement personnel est globalement préservé dans l'échantillon. Toutefois, l'analyse doit tenir compte du fait que, dans le calcul du score global de burn-out, cette dimension sera inversée pour être interprétée dans le même sens que les autres : un faible accomplissement personnel représente alors un facteur de risque.

```
In [73]: import matplotlib.pyplot as plt
```

```
import seaborn as sns
```

```
plt.figure(figsize=(7, 5))
sns.histplot(data_cl1['score_burnout'], bins=15, kde=True, color='steelblue')
plt.title('Distribution du score global de burn-out')
plt.xlabel('Score global (0 à 22)')
plt.ylabel('Nombre d\'observations')
plt.tight_layout()
plt.show()
```



Le graphique montre une distribution nettement asymétrique du score d'accomplissement personnel, avec une forte concentration des observations sur les valeurs élevées, en particulier entre 5 et 7. Cela indique que la majorité des individus interrogés se sentent compétents, efficaces et reconnus dans leur travail. Le pic autour de 5 et la rareté des scores faibles confirment que peu de répondants déclarent un faible sentiment d'accomplissement. Cette distribution en cloche inversée, orientée vers la droite, est cohérente avec les statistiques descriptives : une médiane de 5, une moyenne de 5,3 et un score maximal de 7. Ce profil suggère que l'accomplissement personnel est globalement bien préservé au sein de l'échantillon. Toutefois, il convient de rappeler que, pour le calcul du score global de burn-out, cette dimension est inversée afin de l'interpréter dans le même sens que les autres composantes : un faible accomplissement personnel est alors considéré comme un facteur de risque.

Création de la variable binaire burn_out :

```
In [74]: # Étape 1 : On récupère le score global
burnout_score = data_cl1["score_burnout"]

# Étape 2 : On calcule des seuils statistiques
q1 = burnout_score.quantile(0.25)
q2 = burnout_score.median() # équivalent au 50e percentile
q3 = burnout_score.quantile(0.75)

# Étape 3 : Création des variables binaires selon différents seuils
data_cl1["burnout_bin_q1"] = (burnout_score > q1).astype(int)
data_cl1["burnout_bin_median"] = (burnout_score > q2).astype(int)
data_cl1["burnout_bin_q3"] = (burnout_score > q3).astype(int)

In [75]: # Afficher les effectifs + pourcentages
for col in ["burnout_bin_q1", "burnout_bin_median", "burnout_bin_q3"]:
    print(f"\nDistribution de {col} :")
    print(data_cl1[col].value_counts())
    print(data_cl1[col].value_counts(normalize=True).round(3) * 100)
```

```
Distribution de burnout_bin_q1 :
burnout_bin_q1
1    7921
0    7486
Name: count, dtype: int64
burnout_bin_q1
1    51.4
0    48.6
Name: proportion, dtype: float64
```

```
Distribution de burnout_bin_median :
burnout_bin_median
0    11042
1     4365
Name: count, dtype: int64
burnout_bin_median
0    71.7
1    28.3
Name: proportion, dtype: float64
```

```
Distribution de burnout_bin_q3 :
burnout_bin_q3
0    13227
1     2180
Name: count, dtype: int64
burnout_bin_q3
0    85.9
1    14.1
Name: proportion, dtype: float64
```

- burnout_bin_q1 (~51% de 1) : seuil bas, capture toute forme de symptômes → bon pour une analyse inclusive.
- burnout_bin_median (~28% de 1) : seuil intermédiaire, reflète un niveau modéré de burn-out → adapté à une analyse centrée sur les cas significatifs.
- burnout_bin_q3 (~14% de 1) : seuil élevé, se concentre sur les cas graves → bon pour un modèle prédictif focalisé sur les situations critiques.

Afin d'étudier économétriquement les déterminants du burn-out, nous avons transformé le score global continu en une variable binaire, indiquant la présence ou non d'un état de burn-out. Plusieurs options de seuil étaient envisageables, comme un seuil minimal (score > 0), la médiane, ou encore un seuil élevé basé sur le dernier quartile (Q3).

Nous avons retenu ce dernier, c'est-à-dire un seuil correspondant au troisième quartile (Q3), pour plusieurs raisons :

- Reflète mieux la rareté du burn-out dans la population active, souvent estimée entre 10 % et 20 % selon la littérature épidémiologique. Il permet donc une meilleure cohérence externe du modèle.
- Il identifie les individus les plus sévèrement atteints, en se concentrant sur les cas situés dans la tranche supérieure de la distribution du score de burn-out.
- La réduction du nombre de cas positifs (environ 14 %) limite le risque de faux positifs, ce qui est pertinent dans une approche orientée vers la détection de cas avérés nécessitant une attention particulière.
- Modélisation plus discriminante, utile dans une logique de ciblage d'interventions.

```
In [76]: # Création de la variable binaire (1 si score > Q3)
data_cl1["burnout_bin_q3"] = (burnout_score > q3).astype(int)

# Vérification de la distribution
print("Distribution de burnout_bin_q3 :")
print(data_cl1["burnout_bin_q3"].value_counts())
print(data_cl1["burnout_bin_q3"].value_counts(normalize=True).round(3) * 100)
```

```
Distribution de burnout_bin_q3 :
burnout_bin_q3
0    13227
1     2180
Name: count, dtype: int64
burnout_bin_q3
0    85.9
1    14.1
Name: proportion, dtype: float64
```

La variable burnout_bin_q3 a été construite en attribuant la valeur 1 aux individus dont le score global de burn-out est strictement supérieur au troisième quartile observé dans l'échantillon, soit un score supérieur à 8. Cette transformation permet d'isoler les cas les plus sévères, correspondant à un niveau de burn-out particulièrement élevé. Sur un total de 15 407 individus disposant de données complètes sur les trois dimensions du MBI, 14,1 % présentent un score supérieur à ce seuil (soit 2 180 personnes), contre 85,9 % en dessous ou égal à ce seuil (13 227 personnes). Cette répartition déséquilibrée reflète la rareté relative du burn-out sévère dans la population active, ce qui renforce la pertinence du seuil Q3 dans une logique de ciblage des individus les plus à risque. Toutefois, le faible effectif des cas positifs implique une vigilance particulière dans l'estimation du modèle logit, afin d'éviter des erreurs standards élevées ou des performances biaisées du classificateur.

```
In [77]: data_cl1.shape
```

Sélection des variables explicatives :

Variables socio-démographiques :

- SEXE : La variable sexe a été recodée en variable binaire : 0 pour les hommes, 1 pour les femmes. Les femmes représentent 57 % de l'échantillon contre 43% pour les hommes. Elle est intégrée au modèle afin d'identifier d'éventuelles disparités de genre face au risque de burn-out.

```
In [78]: # Recodage : 0 = Homme, 1 = Femme
data_cl1["sexe"] = data_cl1["SEXE"].map({1: 0, 2: 1})

print("Distribution de la variable sexe :")
print(data_cl1["sexe"].value_counts())
print(data_cl1["sexe"].value_counts(normalize=True).round(2) * 100)
```

```
Distribution de la variable sexe :
sexe
1      8778
0      6629
Name: count, dtype: int64
sexe
1      57.0
0      43.0
Name: proportion, dtype: float64
```

- AGE : La variable AGE_tranche catégorise les individus selon leur groupe d'âge. La majorité se situe entre 30 et 54 ans (74 % au total), tandis que les moins de 30 ans ne représentent que 5 % de l'échantillon. Cette variable est introduite dans le modèle pour évaluer si le risque de burn-out varie selon les étapes de la vie professionnelle.

```
In [79]: print("Distribution de la variable Age :")
print(data_cl1["AGE_tranche"].value_counts())
print(data_cl1["AGE_tranche"].value_counts(normalize=True).round(2) * 100)
```

```
Distribution de la variable Age :
AGE_tranche
30-44 ans      5963
45-54 ans      5458
55 ans et plus  3150
Moins de 30 ans   836
Name: count, dtype: int64
AGE_tranche
30-44 ans      39.0
45-54 ans      35.0
55 ans et plus  20.0
Moins de 30 ans   5.0
Name: proportion, dtype: float64
```

- revmensc_tranche : La variable revmensc_tranche classe les individus selon leur niveau de revenu mensuel net, après nettoyage statistique. Les observations avec valeurs nulles, manquantes ou aberrantes (en dehors des 1er et 99e percentiles) ont été exclues pour garantir la fiabilité des analyses. Cinq tranches ont ensuite été constituées sur la base des quartiles empiriques. Les résultats montrent une forte concentration des répondants dans les tranches intermédiaires : 29 % des individus gagnent entre 1301 € et 1700 €, et 25 % entre 1701 € et 2250 €. Environ 21 % déclarent un revenu inférieur ou égal à 1300 €, tandis que les niveaux les plus élevés restent marginaux (seulement 9 % perçoivent plus de 3000 €). Cette distribution asymétrique, tirée vers les bas revenus, reflète une précarité financière relative chez une part importante de l'échantillon. L'intégration de cette variable permet d'étudier comment le niveau de ressources économiques personnelles influence le risque de burn-out.

```
In [80]: print("Distribution de la variable revmensc_tranche :")
print(data_cl1["revmensc_tranche"].value_counts())
print(data_cl1["revmensc_tranche"].value_counts(normalize=True).round(2) * 100)
```

```
Distribution de la variable revmensc_tranche :
revmensc_tranche
1351-1700      3961
≤ 1350         3803
1701-2250      3795
2251-3000      2456
> 3000         1392
Name: count, dtype: int64
revmensc_tranche
1351-1700      26.0
≤ 1350         25.0
1701-2250      25.0
2251-3000      16.0
> 3000         9.0
Name: proportion, dtype: float64
```

- **DIPLOME** : Dans l'échantillon, la catégorie la plus représentée correspond au niveau intermédiaire (CAP, BEP, bac), avec 44 % des individus. Elle est suivie par les diplômés de l'enseignement supérieur (27 %), ceux ayant un niveau Bac +2 (15 %) et, enfin, les personnes sans diplôme ou avec un niveau primaire (13 %). L'inclusion de cette variable dans le modèle permet d'évaluer dans quelle mesure le niveau d'instruction peut moduler le risque de burn-out, en tant que facteur de vulnérabilité ou de protection face aux conditions de travail.

```
In [81]: def recoder_diplome(x):
    if x in [0, 1, 2]:
        return 0 # Aucun diplôme ou primaire
    elif x in [3, 4, 5]:
        return 1 # CAP / BEP / Bac
    elif x == 6:
        return 2 # Bac +2
    elif x in [7, 8]:
        return 3 # Bac +3 et plus
    else:
        return np.nan # Refus / NSP

# Application du recodage
data_cl1["niv_diplome_reg"] = data_cl1["DIPLOME"].apply(recoder_diplome)

# Suppression des lignes avec refus / NSP
data_cl1 = data_cl1[~data_cl1["niv_diplome_reg"].isna()]

print("Distribution de la variable niv_diplome_reg :")
print(data_cl1["niv_diplome_reg"].value_counts().sort_index())
print(data_cl1["niv_diplome_reg"].value_counts(normalize=True).sort_index().round(2) * 100)
```

```
Distribution de la variable niv_diplome_reg :
niv_diplome_reg
0.0      2071
1.0      6822
2.0      2358
3.0      4137
Name: count, dtype: int64
niv_diplome_reg
0.0      13.0
1.0     44.0
2.0     15.0
3.0     27.0
Name: proportion, dtype: float64
```

- **Situation familiale** : quatre grands groupes ont été distingués : les personnes seules (14 %), les familles monoparentales actives (9 %), les couples sans enfant (21 %) et les couples avec enfant (56 %). Ce regroupement permet d'étudier plus finement l'effet des responsabilités familiales et du soutien conjugal sur le risque de burn-out, en isolant les charges liées à la parentalité et aux configurations familiales. Cette variable constitue ainsi un indicateur synthétique et pertinent du contexte familial au moment de l'enquête.

```
In [82]: # Recode de la variable TYPMEN15 en 4 modalités :
# 0 : Personne seule active (code 10)
# 1 : Famille monoparentale avec parent actif (code 21)
# 2 : Couple sans enfant, au moins un actif (codes 31, 32)
# 3 : Couple avec enfant(s), au moins un actif (codes 41, 42)
# → Tous les autres cas sont exclus (inactifs, autres ménages)

def recoder_typmen15_v2(x):
    if x == 10:
        return 0 # Personne seule active
    elif x == 21:
        return 1 # Famille monoparentale avec parent actif
    elif x in [31, 32]:
        return 2 # Couple sans enfant, au moins un actif
    elif x in [41, 42]:
        return 3 # Couple avec enfant(s), au moins un actif
    else:
        return np.nan # Cas complexes ou inactifs exclus
```



```
# Application
data_cl1["typmen15_reg"] = data_cl1["typmen15"].apply(recoder_typmen15_v2)

# Suppression des lignes où 'typmen15_reg' est NaN
data_cl1 = data_cl1.dropna(subset=["typmen15_reg"])

# Vérification de la distribution après suppression des NaN
print("Distribution de la variable typmen15_reg :")
print(data_cl1["typmen15_reg"].value_counts())
print(data_cl1["typmen15_reg"].value_counts(normalize=True).round(2) * 100)

# Vérification du pourcentage de valeurs manquantes après la suppression
missing_typmen15 = data_cl1["typmen15_reg"].isna().sum()
print(f"Nombre de valeurs manquantes dans 'typmen15_reg' après suppression : {missing_typmen15}")
```

```
Distribution de la variable typmen15_reg :
typmen15_reg
3.0    8209
2.0    3138
0.0    2115
1.0    1246
Name: count, dtype: int64
typmen15_reg
3.0    56.0
2.0    21.0
0.0    14.0
1.0     8.0
Name: proportion, dtype: float64
Nombre de valeurs manquantes dans 'typmen15_reg' après suppression : 0
```

Variables Conditions de travail :

- NUIT : La variable NUIT_reg indique si la personne travaille de nuit (entre minuit et 5h). Elle a été recodée en binaire : 1 pour « habituellement » ou « occasionnellement », 0 pour « jamais », avec suppression des rares non-réponses (0,16 %). Au total, 16 % des répondants sont exposés au travail de nuit. En l'intégrant dans le modèle, on cherche à mesurer son influence sur la probabilité de burn-out, en complément d'autres conditions de travail intensives.

```
In [83]: # Recodage de la variable NUIT (1 si travaille de nuit, 0 sinon)
def recoder_nuit(x):
    if x in [1, 2]:      # Habituellement ou occasionnellement
        return 1
    elif x == 3:         # Jamais
        return 0
    else:                # Refus / NSP
        return np.nan

# Application du recodage
data_cl1["NUIT_reg"] = data_cl1["NUIT"].apply(recoder_nuit)

# Suppression des valeurs manquantes (0,16 % seulement)
data_cl1 = data_cl1.dropna(subset=["NUIT_reg"])

# Vérification
print("Distribution de la variable NUIT_reg :")
print(data_cl1["NUIT_reg"].value_counts())
print(data_cl1["NUIT_reg"].value_counts(normalize=True).round(2) * 100)
```

```
Distribution de la variable NUIT_reg :
NUIT_reg
0.0    12360
1.0     2342
Name: count, dtype: int64
NUIT_reg
0.0    84.0
1.0    16.0
Name: proportion, dtype: float64
```

- CVFVP : La variable CVFVP_reg indique si les horaires de travail sont perçus comme compatibles avec les engagements personnels. 82 % des répondants déclarent un bon équilibre entre vie professionnelle et vie personnelle, contre 18 % qui rapportent un déséquilibre, potentiellement générateur de stress ou d'épuisement. Cette variable est pertinente pour capter une dimension centrale de la prévention du burn-out.

```
In [84]: # Recodage CVFVP : 1 = bon équilibre, 0 = mauvais équilibre
def recoder_cvfvp(x):
    if x in [1, 2]:      # Très bien ou Bien
        return 1
    elif x in [3, 4]:    # Pas très bien ou Pas bien du tout
        return 0
    else:
        return np.nan    # Refus / NSP

# Application
data_cl1["CVFVP_reg"] = data_cl1["CVFVP"].apply(recoder_cvfvp)
```

```
# Suppression des valeurs manquantes (0,16%)
data_cl1 = data_cl1.dropna(subset=["CVFVP_reg"])

# Vérification
print("Distribution de la variable CVFVP_reg :")
print(data_cl1["CVFVP_reg"].value_counts())
print(data_cl1["CVFVP_reg"].value_counts(normalize=True).round(2) * 100)
```

Distribution de la variable CVFVP_reg :

```
CVFVP_reg
1.0    12090
0.0     2579
Name: count, dtype: int64

CVFVP_reg
1.0     82.0
0.0     18.0
Name: proportion, dtype: float64
```

- PREVIS : La variable PREVIS, qui indique le degré de prévisibilité des horaires de travail, a été recodée en quatre modalités distinctes : prévenu dans le mois (PREVIS_mois), dans la semaine (PREVIS_semaine), la veille (PREVIS_veille) ou non prévenu (PREVIS_non). Sur les 15 334 individus conservés après suppression des réponses manquantes, 85 % déclarent connaître leurs horaires au moins un mois à l'avance, contre 8 % une semaine à l'avance, 4 % la veille et 3 % qui ne sont pas prévenus. Cette variable est particulièrement pertinente pour l'analyse du burn-out, car une faible prévisibilité des horaires peut générer un stress organisationnel important

```
In [85]: # Création d'un DataFrame temporaire filtré uniquement pour PREVIS
data_cl1 = data_cl1[data_cl1["PREVIS"].isin([1, 2, 3, 4])].copy()

# Création des variables indicatrices sans écraser d'autres variables
data_cl1["PREVIS_mois"] = (data_cl1["PREVIS"] == 1).astype(int)
data_cl1["PREVIS_semaine"] = (data_cl1["PREVIS"] == 2).astype(int)
data_cl1["PREVIS_veille"] = (data_cl1["PREVIS"] == 3).astype(int)
data_cl1["PREVIS_non"] = (data_cl1["PREVIS"] == 4).astype(int)

# Vérification de la distribution
print("Distribution de PREVIS :")
print(data_cl1["PREVIS"].value_counts())
print(data_cl1["PREVIS"].value_counts(normalize=True).round(2) * 100)
```

Distribution de PREVIS :

```
PREVIS
1.0    12460
2.0     1135
3.0      602
4.0      458
Name: count, dtype: int64

PREVIS
1.0     85.0
2.0      8.0
3.0      4.0
4.0      3.0
Name: proportion, dtype: float64
```

```
In [86]: # Vérification des modalités après recodage
print("Distribution des modalités PREVIS (dummies) :")
print(data_cl1[["PREVIS_mois", "PREVIS_semaine", "PREVIS_veille", "PREVIS_non"]].sum())
print((data_cl1[["PREVIS_mois", "PREVIS_semaine", "PREVIS_veille", "PREVIS_non"]].sum() / len(data_cl1)).round(1))
```

Distribution des modalités PREVIS (dummies) :

```
PREVIS_mois    12460
PREVIS_semaine    1135
PREVIS_veille     602
PREVIS_non       458
dtype: int64
PREVIS_mois      85.0
PREVIS_semaine    7.7
PREVIS_veille     4.1
PREVIS_non        3.1
dtype: float64
```

- TPP : La variable TPP_reg permet de distinguer les individus travaillant à temps partiel (19 %) de ceux à temps complet (81 %). Le temps partiel peut être un choix permettant un meilleur équilibre vie professionnelle/vie personnelle, mais il peut aussi refléter une forme de précarité ou des contraintes personnelles. Intégrer cette variable permet donc de capturer une dimension importante des conditions d'emploi susceptibles d'influencer l'exposition au burn-out.

```
In [87]: # Suppression des valeurs manquantes/refus/NSP
data_cl1 = data_cl1[data_cl1["TPP"].isin([1, 2])].copy()

# Recode : 1 = temps partiel, 0 = temps complet
data_cl1["TPP_reg"] = data_cl1["TPP"].apply(lambda x: 1 if x == 2 else 0)
```

```
# Vérification
print("Distribution de la variable TPP_reg :")
print(data_cl1["TPP_reg"].value_counts())
print(data_cl1["TPP_reg"].value_counts(normalize=True).round(2) * 100)
```

```
Distribution de la variable TPP_reg :
TPP_reg
0    11858
1     2744
Name: count, dtype: int64
TPP_reg
0     81.0
1     19.0
Name: proportion, dtype: float64
```

- **TYPEMPLOI** : La variable TYPEMPLOI renseigne le type de contrat de travail des répondants. Après suppression rigoureuse des valeurs manquantes (environ 10 %), un jeu de variables indicatrices (dummies) a été créé pour représenter chacune des modalités valides (de 1 à 7). La distribution observée est fortement concentrée sur les contrats à durée indéterminée (CDI ou fonction publique), qui représentent 94,8 % de l'échantillon, reflétant ainsi la stabilité professionnelle majoritaire dans cette population. Les autres formes d'emploi, plus précaires (CDD, intérim, stages, etc.), sont très faiblement représentées. Cette variable permet de tester l'hypothèse selon laquelle la précarité contractuelle pourrait constituer un facteur de vulnérabilité face au burn-out.

```
In [88]: # Suppression des valeurs manquantes ou non valides
data_cl1 = data_cl1[data_cl1["TYPEMPLOI"].isin([1, 2, 3, 4, 5, 6, 7])].copy()

# Création des dummies (une par modalité de 1 à 7)
typeemploi_dummies_reg = pd.get_dummies(data_cl1["TYPEMPLOI"].astype(int), prefix="TYPEMPLOI")

# Fusion avec la base principale
data_cl1 = pd.concat([data_cl1, typeemploi_dummies_reg], axis=1)

# Vérification de la distribution des modalités
print("Distribution des modalités TYPEMPLOI (dummies) :")
print(typeemploi_dummies_reg.sum())
print((typeemploi_dummies_reg.sum() / len(data_cl1) * 100).round(2))
```

```
Distribution des modalités TYPEMPLOI (dummies) :
TYPEMPLOI_1      5
TYPEMPLOI_2     81
TYPEMPLOI_3      7
TYPEMPLOI_4     47
TYPEMPLOI_5    547
TYPEMPLOI_6   13135
TYPEMPLOI_7     11
dtype: int64
TYPEMPLOI_1      0.04
TYPEMPLOI_2     0.59
TYPEMPLOI_3     0.05
TYPEMPLOI_4     0.34
TYPEMPLOI_5     3.95
TYPEMPLOI_6    94.95
TYPEMPLOI_7     0.08
dtype: float64
```

- **CWMVT** : La variable CWMVT_reg indique si les répondants déclarent effectuer des mouvements douloureux dans leur travail. Après suppression des modalités manquantes (refus, NSP), 40 % des individus déclarent en faire, contre 60 % qui n'en font pas. Cette variable permet de mesurer une dimension physique de la pénibilité, susceptible de contribuer à l'épuisement professionnel. L'inclusion de cet indicateur dans le modèle est pertinente, car l'intensité physique du travail peut engendrer de la fatigue chronique, un facteur connu de burn-out.

```
In [89]: # Suppression des valeurs manquantes / refus / NSP
data_cl1 = data_cl1[data_cl1["CWMVT"].isin([1, 2])].copy()

# Recodage : 1 = Oui (mouvements douloureux), 0 = Non
data_cl1["CWMVT_reg"] = data_cl1["CWMVT"].apply(lambda x: 1 if x == 1 else 0)

# Vérification de la distribution
print("Distribution de la variable CWMVT_reg :")
print(data_cl1["CWMVT_reg"].value_counts())
print(data_cl1["CWMVT_reg"].value_counts(normalize=True).round(2) * 100)
```

```
Distribution de la variable CWMVT_reg :
CWMVT_reg
0     8366
1     5458
Name: count, dtype: int64
CWMVT_reg
0     61.0
1     39.0
Name: proportion, dtype: float64
```

Variables Relations Professionnelles :

- **ENCADR** : La variable ENCADR_reg permet d'identifier si les répondants exercent des responsabilités de supervision dans leur emploi principal. Près de 39 % déclarent encadrer d'autres salariés, tandis que 61 % ne le font pas. Cette variable est pertinente dans l'analyse du burn-out, car superviser implique souvent une charge mentale accrue, des attentes hiérarchiques plus élevées et une pression décisionnelle, autant de facteurs pouvant accroître le stress professionnel.

```
In [90]: # Suppression des valeurs manquantes/refus/NSP
data_cl1 = data_cl1[data_cl1["ENCADR"].isin([1, 2, 3])].copy()

# Recodage : 1 = supervise (modalités 1 ou 2), 0 = ne supervise pas (modalité 3)
data_cl1["ENCADR_reg"] = data_cl1["ENCADR"].apply(lambda x: 1 if x in [1, 2] else 0)

# Vérification de la distribution
print("Distribution de la variable ENCADR_reg :")
print(data_cl1["ENCADR_reg"].value_counts())
print(data_cl1["ENCADR_reg"].value_counts(normalize=True).round(2) * 100)
```

```
Distribution de la variable ENCADR_reg :
ENCADR_reg
0      8312
1      5512
Name: count, dtype: int64
ENCADR_reg
0      60.0
1      40.0
Name: proportion, dtype: float64
```

- **CONFSAL** : La variable CONFSAL_reg mesure la confiance perçue des supérieurs envers les salariés. D'après les résultats, 86 % des répondants estiment que leurs supérieurs leur font confiance (toujours ou souvent), tandis que 14 % perçoivent une confiance limitée (parfois ou jamais). Ce ressenti est crucial car un manque de reconnaissance et de soutien hiérarchique peut contribuer à l'épuisement émotionnel et à un sentiment d'inefficacité professionnelle, deux dimensions centrales du burn-out. Intégrer cette variable dans le modèle permet donc de mieux saisir le rôle des relations managériales dans le développement des risques psychosociaux.

```
In [91]: # Recodage de CONFSAL (1 à 4 = réponse valide, 1/2 = confiance, 3/4 = peu de confiance)
def recoder_confsal(x):
    if x in [1, 2]:      # Toujours ou souvent
        return 1        # Confiance accordée
    elif x in [3, 4]:   # Parfois ou jamais
        return 0        # Faible confiance
    else:               # Refus, NSP, ou sans objet
        return np.nan

# Application
data_cl1["CONFSAL_reg"] = data_cl1["CONFSAL"].apply(recoder_confsal)

# Suppression des valeurs manquantes (environ 10.4 %)
data_cl1 = data_cl1[~data_cl1["CONFSAL_reg"].isna()].copy()

# Vérification
print("Distribution de la variable CONFSAL_reg :")
print(data_cl1["CONFSAL_reg"].value_counts())
print(data_cl1["CONFSAL_reg"].value_counts(normalize=True).round(2) * 100)
```

```
Distribution de la variable CONFSAL_reg :
CONFSAL_reg
1.0      11806
0.0       1850
Name: count, dtype: int64
CONFSAL_reg
1.0      86.0
0.0     14.0
Name: proportion, dtype: float64
```

- **BIENETR1** : Cette variable mesure la perception qu'ont les salariés du niveau d'importance accordé par leur supérieur à la santé et au bien-être. Les modalités refus, NSP et sans objet ont été exclues, et les valeurs manquantes (environ 10 %) ont été imputées par la modalité la plus fréquente ("Toujours"). Elle a ensuite été recodée en variable binaire (BIENETR1_reg) : 1 si le soutien est jugé régulier (toujours ou souvent), 0 sinon (parfois ou jamais). On observe que 62 % des salariés perçoivent un réel engagement de leur hiérarchie en matière de bien-être, contre 38 % qui déplorent un soutien plus limité. Cette variable est essentielle pour capter l'effet du soutien managérial perçu sur la santé mentale au travail.

```
In [92]: def recoder_bienetr1(x):
    if x in [1, 2]:
        return 1
    elif x in [3, 4]:
        return 0
    else:
```

```

        return np.nan

# Étape 1 : Recodage
data_cl1["BIENETR1_reg"] = data_cl1["BIENETR1"].apply(recoder_bienetr1)

# Étape 2 : Suppression des lignes avec valeurs manquantes dans BIENETR1_reg
data_cl1 = data_cl1.dropna(subset=["BIENETR1_reg"])

# Vérification
print("Distribution de la variable BIENETR1_reg :")
print(data_cl1["BIENETR1_reg"].value_counts())
print(data_cl1["BIENETR1_reg"].value_counts(normalize=True).round(2) * 100)

```

Distribution de la variable BIENETR1_reg :

```

BIENETR1_reg
1.0    8268
0.0    5061
Name: count, dtype: int64
BIENETR1_reg
1.0    62.0
0.0    38.0
Name: proportion, dtype: float64

```

Variables Événements marquants :

- RP1 : La variable RP1_reg mesure l'existence perçue d'un soutien social de proximité, c'est-à-dire la possibilité de se confier à quelqu'un ou de s'appuyer sur une personne de confiance pour prendre une décision difficile. Elle est recodée en binaire : 1 si le répondant déclare disposer de ce type de soutien, 0 sinon. D'après les résultats, 93 % des individus déclarent bénéficier d'un tel appui, contre 7 % qui se retrouvent en situation d'isolement social. Ce faible taux d'isolement perçu ne doit pas occulter l'importance de la variable, car l'absence de soutien constitue un facteur bien documenté de vulnérabilité face au stress chronique et à l'épuisement professionnel. L'intégration de cette variable permet ainsi de capturer une dimension relationnelle protectrice dans l'analyse du burn-out.

```

In [93]: # Suppression des valeurs manquantes/refus/NSP
data_cl1 = data_cl1[data_cl1["RP1"].isin([1, 2])].copy()

# Recodage : 1 = a du soutien, 0 = pas de soutien
data_cl1["RP1_reg"] = data_cl1["RP1"].apply(lambda x: 1 if x == 1 else 0)

# Vérification
print("Distribution de la variable RP1_reg :")
print(data_cl1["RP1_reg"].value_counts())
print(data_cl1["RP1_reg"].value_counts(normalize=True).round(2) * 100)

```

Distribution de la variable RP1_reg :

```

RP1_reg
1    11791
0      825
Name: count, dtype: int64
RP1_reg
1    93.0
0     7.0
Name: proportion, dtype: float64

```

- RP4B : Cette variable permet d'identifier si les répondants ont été affectés au cours des trois dernières années par un événement marquant lié à la santé ou au décès d'un proche. Dans l'échantillon, 42 % déclarent avoir vécu une telle épreuve, contre 58 % qui ne rapportent pas d'événement de ce type. Ce type de choc personnel peut avoir des répercussions durables sur le bien-être psychologique et constitue un facteur contextuel pertinent à intégrer dans l'analyse du risque de burn-out.

```

In [94]: # Suppression des valeurs manquantes/refus/NSP
data_cl1 = data_cl1[data_cl1["RP4B"].isin([1, 2])].copy()

# Recodage : 1 = a vécu un événement marquant (oui), 0 = non
data_cl1["RP4B_reg"] = data_cl1["RP4B"].apply(lambda x: 1 if x == 1 else 0)

# Vérification de la distribution
print("Distribution de la variable RP4B_reg :")
print(data_cl1["RP4B_reg"].value_counts())
print(data_cl1["RP4B_reg"].value_counts(normalize=True).round(2) * 100)

```

Distribution de la variable RP4B_reg :

```

RP4B_reg
0    7333
1    5260
Name: count, dtype: int64
RP4B_reg
0    58.0
1    42.0
Name: proportion, dtype: float64

```

Régression linéaire :

```
In [95]: # Liste des variables à analyser
vars_to_check = ["RPB1E", "RPB1H", "RPB1J", "RPB5E"]

# Copier les données sans toucher à l'original pour analyse
df_check = data_cl1[vars_to_check].copy()

# Remplacer 8 (Refus) et 9 (NSP) par NaN
df_check = df_check.replace({8: np.nan, 9: np.nan})

# Calcul du pourcentage de valeurs manquantes (après exclusion 8 et 9)
missing_percent = df_check.isna().mean().round(4) * 100

# Affichage
print("Pourcentage de valeurs manquantes (en incluant 8/9 comme NA) :")
print(missing_percent)
```

```
Pourcentage de valeurs manquantes (en incluant 8/9 comme NA) :
RPB1E    0.03
RPB1H    0.03
RPB1J    0.03
RPB5E    0.23
dtype: float64
```

```
In [96]: # -----
# Recode des 3 variables Oui / Non
# -----

violence_vars = ["RPB1E", "RPB1H", "RPB1J"]
data_cl1[violence_vars] = data_cl1[violence_vars].replace({8: np.nan, 9: np.nan})

for var in violence_vars:
    data_cl1[f"{var}_b"] = data_cl1[var].map({1: 1, 2: 0})

# -----
# Recode de RPB5E (échelle de fréquence)
# -----

data_cl1["RPB5E"] = data_cl1["RPB5E"].replace({8: np.nan, 9: np.nan})
data_cl1["RPB5E_b"] = data_cl1["RPB5E"].map({1: 1, 2: 1, 3: 0, 4: 0})

# -----
# Suppression des lignes avec NA sur les nouvelles variables
# -----

vars_binaire_finales = ["RPB1E_b", "RPB1H_b", "RPB1J_b", "RPB5E_b"]
data_cl1 = data_cl1.dropna(subset=vars_binaire_finales)

# Vérification finale
print("Dimensions après suppression des NA :", data_cl1.shape)
```

```
Dimensions après suppression des NA : (12557, 222)
```

```
In [97]: # Recodage
data_cl1["ATTENTE_reg"] = data_cl1["ATTENTE"].replace({8: np.nan, 9: np.nan})
data_cl1["TENSION2_reg"] = data_cl1["TENSION2"].replace({1: 1, 2: 0, 3: np.nan, 8: np.nan, 9: np.nan})
data_cl1["INITIAT_reg"] = data_cl1["INITIAT"].replace({1: 1, 2: 1, 3: 0, 4: 0, 8: np.nan, 9: np.nan})
data_cl1["IDEE_reg"] = data_cl1["IDEE"].replace({1: 1, 2: 1, 3: 0, 4: 0, 8: np.nan, 9: np.nan})
data_cl1["QUANTI_reg"] = data_cl1["QUANTI"].replace({1: 1, 2: 1, 3: 0, 4: 0, 8: np.nan, 9: np.nan})

# Vérification du % de valeurs manquantes
vars_reg = ["ATTENTE_reg", "TENSION2_reg",
            "INITIAT_reg", "IDEE_reg", "QUANTI_reg"]

missing_percent = data_cl1[vars_reg].isna().mean().round(4) * 100

# Affichage
print("Pourcentage de valeurs manquantes dans les variables recodées :\n")
print(missing_percent)

# Affichage d'un aperçu
data_cl1[["ATTENTE_reg", "TENSION2_reg", "INITIAT_reg", "IDEE_reg", "QUANTI_reg"]].head()
```

```
Pourcentage de valeurs manquantes dans les variables recodées :
```

```
ATTENTE_reg    0.18
TENSION2_reg    2.01
INITIAT_reg     0.02
IDEE_reg        0.10
QUANTI_reg      0.82
dtype: float64
```

```
Out[97]:
```

	ATTENTE_reg	TENSION2_reg	INITIAT_reg	IDEE_reg	QUANTI_reg
0	1.0	0.0	1.0	1.0	1.0
3	1.0	1.0	1.0	1.0	1.0
5	1.0	0.0	1.0	1.0	0.0
6	1.0	0.0	1.0	1.0	1.0
7	1.0	1.0	1.0	1.0	0.0

```
In [98]: # Liste des variables recodées à vérifier
vars_rec = ["INITIAT_reg", "IDEE_reg", "QUANTI_reg",
            "ATTENTE_reg", "TENSION2_reg"]

# Remplacer 8 et 9 par np.nan si ce n'est pas déjà fait
df_check = data_cl1[vars_rec].replace({8: np.nan, 9: np.nan})

# Calcul du pourcentage de valeurs manquantes
missing_percent = df_check.isna().mean().round(4) * 100

# Affichage
print("Pourcentage de valeurs manquantes (en incluant 8/9 comme NA) :")
print(missing_percent)
```

```
Pourcentage de valeurs manquantes (en incluant 8/9 comme NA) :
INITIAT_reg    0.02
IDEE_reg       0.10
QUANTI_reg     0.82
ATTENTE_reg    0.18
TENSION2_reg   2.01
dtype: float64
```

```
In [99]: # Liste des variables recodées à nettoyer
vars_to_keep = ["INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"]

# Suppression des lignes avec au moins une valeur manquante
data_cl1_clean = data_cl1.dropna(subset=vars_to_keep)

# Vérification du résultat
print("Dimensions après suppression des NA :", data_cl1_clean.shape)
```

```
Dimensions après suppression des NA : (12173, 227)
```

```
In [100]: import os
import pandas as pd
import statsmodels.api as sm

# Limiter les threads pour éviter les erreurs système
os.environ["OPENBLAS_NUM_THREADS"] = "1"
os.environ["NUMEXPR_NUM_THREADS"] = "1"
os.environ["OMP_NUM_THREADS"] = "1"

# -----
# 1. Définir les variables
# -----
cat_vars = ["TYPEMPLOI", "AGE_tranche", "revmensc_tranche"]
other_vars = [
    "sexe", "PREVIS", "CVFVP_reg", "niv_diplome_reg", "typmen15_reg",
    "RP1_reg", "RP4B_reg", "CONFSAL_reg", "BIENETR1_reg", "CWMVT_reg", "ENCADR_reg",
    "RPB1E_b", "RPB1H_b", "RPB1J_b", "RPB5E_b",
    "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"
]

# -----
# 2. Construction de X et y
# -----
X_dummies = pd.get_dummies(data_cl1[cat_vars], drop_first=True)
X_other = data_cl1[other_vars]
X_all = pd.concat([X_other, X_dummies], axis=1)
y = data_cl1["score_burnout"]

# -----
# 3. Nettoyage : suppression des NA
# -----
df_reg = pd.concat([X_all, y], axis=1).dropna()
X_clean = df_reg.drop(columns="score_burnout")
y_clean = df_reg["score_burnout"]

# Conversion des données en float
X_clean = X_clean.apply(pd.to_numeric, errors="coerce").astype(float)
y_clean = pd.to_numeric(y_clean, errors="coerce").astype(float)

# -----
# 4. Régression linéaire
# -----
X_sm = sm.add_constant(X_clean)
model = sm.OLS(y_clean, X_sm).fit()
```

```
# -----
# 5. Résultat
# -----
print(model.summary())
```

OLS Regression Results						
Dep. Variable:	score_burnout	R-squared:	0.317			
Model:	OLS	Adj. R-squared:	0.314			
Method:	Least Squares	F-statistic:	151.2			
Date:	Thu, 08 May 2025	Prob (F-statistic):	0.00			
Time:	23:46:23	Log-Likelihood:	-20367.			
No. Observations:	9168	AIC:	4.079e+04			
Df Residuals:	9139	BIC:	4.100e+04			
Df Model:	28					
Covariance Type:	nonrobust					
	coef	std err	t	P> t	[0.025	0.975]
const	4.6093	0.474	9.716	0.000	3.679	5.539
sexe	0.6050	0.052	11.631	0.000	0.503	0.707
PREVIS	0.1281	0.039	3.305	0.001	0.052	0.204
CVFVP_reg	-0.8860	0.063	-14.039	0.000	-1.010	-0.762
niv_diplome_reg	0.2056	0.028	7.323	0.000	0.151	0.261
typmen15_reg	-0.0348	0.023	-1.540	0.124	-0.079	0.010
RP1_reg	-0.9589	0.097	-9.916	0.000	-1.148	-0.769
RP4B_reg	0.4346	0.048	9.093	0.000	0.341	0.528
CONFSA1_reg	-0.4967	0.075	-6.658	0.000	-0.643	-0.350
BIENETR1_reg	-0.5593	0.053	-10.596	0.000	-0.663	-0.456
CWMVT_reg	0.2920	0.052	5.668	0.000	0.191	0.393
ENCADR_reg	0.1995	0.051	3.885	0.000	0.099	0.300
RPB1E_b	1.6006	0.107	14.969	0.000	1.391	1.810
RPB1H_b	0.6613	0.159	4.163	0.000	0.350	0.973
RPB1J_b	1.2511	0.109	11.485	0.000	1.038	1.465
RPB5E_b	1.6228	0.097	16.726	0.000	1.433	1.813
INITIAT_reg	0.3758	0.072	5.193	0.000	0.234	0.518
IDEE_reg	-0.2413	0.057	-4.218	0.000	-0.353	-0.129
QUANTI_reg	-0.2632	0.054	-4.918	0.000	-0.368	-0.158
ATTENTE_reg	0.3936	0.040	9.849	0.000	0.315	0.472
TENSION2_reg	0.8910	0.056	16.038	0.000	0.782	1.000
TYPEMPLOI	0.1215	0.075	1.626	0.104	-0.025	0.268
AGE_tranche_30-44 ans	0.1283	0.104	1.232	0.218	-0.076	0.332
AGE_tranche_45-54 ans	0.1140	0.107	1.067	0.286	-0.095	0.324
AGE_tranche_55 ans et plus	0.1111	0.115	0.967	0.333	-0.114	0.336
revmensc_tranche_1351-1700	-0.0227	0.069	-0.332	0.740	-0.157	0.112
revmensc_tranche_1701-2250	0.0735	0.073	1.001	0.317	-0.071	0.218
revmensc_tranche_2251-3000	0.0888	0.088	1.011	0.312	-0.083	0.261
revmensc_tranche_> 3000	0.1493	0.116	1.292	0.196	-0.077	0.376
Omnibus:	903.325	Durbin-Watson:	1.986			
Prob(Omnibus):	0.000	Jarque-Bera (JB):	1285.781			
Skew:	0.775	Prob(JB):	6.26e-280			
Kurtosis:	3.980	Cond. No.	150.			

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

- **Objectif du modèle** : Cette régression linéaire vise à expliquer les variations du *score de burn-out* (continu), en fonction d'un ensemble de variables explicatives sociodémographiques, professionnelles, psychologiques et relationnelles.

Qualité globale du modèle :

- **R² ajusté** : 0.314 → le modèle explique environ **31 % de la variance** du score de burn-out, ce qui est **satisfaisant pour des données sociales**.
- **F-statistique significatif** (Prob = 0.00) → le modèle dans son ensemble est **statistiquement significatif**.
- **Durbin-Watson** ≈ 1.99 → **pas d'autocorrélation** résiduelle marquée.
- **Test de normalité (Jarque-Bera)** : rejet de l'hypothèse de normalité des résidus, mais cela est **fréquent dans les grandes bases sociales**.

Variables les plus significatives (**p < 0.01**) :

- **sexe** (+0.605) : être une femme est associé à un **score de burn-out plus élevé**, toutes choses égales par ailleurs.
- **PREVIS** (+0.128) : ne pas savoir ce qui est attendu de soi **augmente significativement** le score.
- **CVFVP_reg** (-0.886) : se sentir préparé face aux imprévus est un **facteur protecteur très fort**.
- **RP1_reg** (-0.958) : plus le soutien professionnel perçu est élevé, plus le score de burn-out **diminue fortement**.
- **RP4B_reg** (+0.4436) : les tensions relationnelles **augmentent significativement** le score.
- **CONFSA1_reg** (-0.497) : avoir confiance en sa hiérarchie est **protecteur**.
- **BIENETR1_reg** (-0.559) : se sentir bien au travail **diminue fortement** le score.
- **CWMVT_reg** (+0.292) : devoir travailler dans l'urgence **accroît significativement** le score.

- **ENCADR_reg** (+0.195) : encadrer d'autres personnes est associé à un **score plus élevé**.
- **RPB1E_b / RPB1H_b / RPB1J_b / RPB5E_b** (+1.25 à +1.62) : les expériences de **maltraitance ou dégradation** sont **très fortement associées** à un score plus élevé.
- **IDEE_reg / QUANTI_reg** (−0.241 / −0.263) : avoir la possibilité **d'exprimer ses idées** et **d'agir sur sa charge de travail** réduit significativement le score.
- **ATTENTE_reg** (+0.393) : ne pas savoir ce que l'on attend de soi **augmente le score**.
- **TENSION2_reg** (+0.910) : **tensions hiérarchiques** → **effet très marqué**.

Remarques complémentaires :

- Les **dummies sur les tranches d'âge et de revenus** sont **peu significatifs** ici, contrairement au modèle logit.
- Les variables recodées de **l'autonomie** (**INITIAT** , **IDEE** , **QUANTI**) montrent des **effets cohérents** : **plus d'autonomie** → **moins de burn-out**.
- L'ajout de **variables psychologiques et relationnelles** a permis d'**augmenter significativement la qualité** du modèle.

```
In [101... # -----
# Recode et nettoyage des nouvelles variables
# -----

data_cl1 = data_cl1.copy()

# 1. NBENFM3 et NBENF3A17 : pas de recodage, ce sont des variables quantitatives
# On les garde telles quelles et on supprime les NA
data_cl1["NBENFM3_reg"] = data_cl1["NBENFM3"]
data_cl1["NBENF3A17_reg"] = data_cl1["NBENF3A17"]

# 2. FONCTION (PRO10) : catégorielle à recoder en dummies, 11 modalités (1 à 11)
# On remplace REFUS et NSP si présents (pas mentionnés dans le dictionnaire ici)
data_cl1 = data_cl1[data_cl1["FONCTION"].notna()] # suppression NA
data_cl1["FONCTION"] = data_cl1["FONCTION"].astype("Int64") # conversion propre
fonction_dummies = pd.get_dummies(data_cl1["FONCTION"], prefix="FONCTION", drop_first=True)

# 3. STATUT (PRO2) : 10 modalités
data_cl1 = data_cl1[data_cl1["STATUT"].notna()]
data_cl1["STATUT"] = data_cl1["STATUT"].astype("Int64")
statut_dummies = pd.get_dummies(data_cl1["STATUT"], prefix="STATUT", drop_first=True)

# 4. ETAMATRI (état matrimonial) : 4 modalités
data_cl1 = data_cl1[data_cl1["ETAMATRI"].notna()]
data_cl1["ETAMATRI"] = data_cl1["ETAMATRI"].astype("Int64")
etamatri_dummies = pd.get_dummies(data_cl1["ETAMATRI"], prefix="ETAMATRI", drop_first=True)

# -----
# Concaténation des nouvelles variables propres
# -----
data_cl1 = pd.concat([data_cl1, fonction_dummies, statut_dummies, etamatri_dummies], axis=1)

# Vérification
print(" Variables recodées et ajoutées : NBENFM3_reg, NBENF3A17_reg, dummies FONCTION, STATUT, ETAMATRI")
```

Variables recodées et ajoutées : NBENFM3_reg, NBENF3A17_reg, dummies FONCTION, STATUT, ETAMATRI

```
In [102... import os
import pandas as pd
import statsmodels.api as sm

# Limiter les threads (important sur certains systèmes)
os.environ["OPENBLAS_NUM_THREADS"] = "1"
os.environ["NUMEXPR_NUM_THREADS"] = "1"
os.environ["OMP_NUM_THREADS"] = "1"

# -----
# 1. Définir les variables
# -----
cat_vars = ["TYPEMPL0I", "AGE_tranche", "revmensc_tranche", "FONCTION", "STATUT", "ETAMATRI"]
num_vars = [
    "sexe", "PREVIS", "CVFVP_reg", "niv_diplome_reg", "typmen15_reg",
    "RP1_reg", "RP4B_reg", "CONFSAL_reg", "BIENETR1_reg", "CWMVT_reg", "ENCADR_reg",
    "RPB1E_b", "RPB1H_b", "RPB1J_b", "RPB5E_b",
    "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg",
    "NBENFM3", "NBENF3A17"
]

# -----
# 2. Construction de X et y
# -----
X_dummies = pd.get_dummies(data_cl1[cat_vars], drop_first=True)
X_numeric = data_cl1[num_vars]
X_all = pd.concat([X_numeric, X_dummies], axis=1)
y = data_cl1["score_burnout"]

# -----
# 3. Nettoyage : suppression des NA
```

```
# -----
df_reg = pd.concat([X_all, y], axis=1).dropna()
X_clean = df_reg.drop(columns="score_burnout")
y_clean = df_reg["score_burnout"]

# Conversion propre
X_clean = X_clean.apply(pd.to_numeric, errors="coerce").astype(float)
y_clean = pd.to_numeric(y_clean, errors="coerce").astype(float)

# -----
# 4. Régression linéaire
# -----
X_sm = sm.add_constant(X_clean)
model = sm.OLS(y_clean, X_sm).fit()

# -----
# 5. Résumé du modèle
# -----
print(model.summary())
```

OLS Regression Results

```
=====
Dep. Variable:          score_burnout    R-squared:                0.317
Model:                  OLS             Adj. R-squared:           0.315
Method:                 Least Squares   F-statistic:              128.6
Date:                  Thu, 08 May 2025 Prob (F-statistic):       0.00
Time:                  23:46:24         Log-Likelihood:          -20363.
No. Observations:      9168            AIC:                    4.079e+04
Df Residuals:          9134            BIC:                    4.104e+04
Df Model:              33
Covariance Type:       nonrobust
=====
```

	coef	std err	t	P> t	[0.025	0.975]
const	4.6432	0.481	9.660	0.000	3.701	5.585
sexe	0.5804	0.054	10.726	0.000	0.474	0.687
PREVIS	0.1370	0.039	3.514	0.000	0.061	0.213
CVFVP_reg	-0.8812	0.063	-13.881	0.000	-1.006	-0.757
niv_diplome_reg	0.1947	0.029	6.742	0.000	0.138	0.251
typmen15_reg	-0.0450	0.026	-1.745	0.081	-0.095	0.006
RP1_reg	-0.9632	0.097	-9.945	0.000	-1.153	-0.773
RP4B_reg	0.4312	0.048	9.017	0.000	0.337	0.525
CONF_SAL_reg	-0.4975	0.075	-6.668	0.000	-0.644	-0.351
BIENETR1_reg	-0.5525	0.053	-10.450	0.000	-0.656	-0.449
CWMVT_reg	0.2897	0.052	5.619	0.000	0.189	0.391
ENCADR_reg	0.2092	0.052	4.058	0.000	0.108	0.310
RPB1E_b	1.5992	0.107	14.958	0.000	1.390	1.809
RPB1H_b	0.6650	0.159	4.186	0.000	0.354	0.976
RPB1J_b	1.2476	0.109	11.450	0.000	1.034	1.461
RPB5E_b	1.6260	0.097	16.753	0.000	1.436	1.816
INITIAT_reg	0.3641	0.073	5.015	0.000	0.222	0.506
IDEE_reg	-0.2424	0.057	-4.237	0.000	-0.355	-0.130
QUANTI_reg	-0.2557	0.054	-4.768	0.000	-0.361	-0.151
ATTENTE_reg	0.3923	0.040	9.812	0.000	0.314	0.471
TENSION2_reg	0.8939	0.056	16.080	0.000	0.785	1.003
NBENFM3	0.0532	0.077	0.693	0.488	-0.097	0.204
NBENF3A17	0.0244	0.031	0.790	0.430	-0.036	0.085
TYPEMPL0I	0.1284	0.075	1.716	0.086	-0.018	0.275
FONCTION	0.0073	0.008	0.897	0.370	-0.009	0.023
STATUT	-0.0256	0.012	-2.136	0.033	-0.049	-0.002
ETAMATRI	0.0290	0.030	0.967	0.333	-0.030	0.088
AGE_tranche_30-44 ans	0.0791	0.109	0.728	0.467	-0.134	0.292
AGE_tranche_45-54 ans	0.0708	0.113	0.627	0.531	-0.150	0.292
AGE_tranche_55 ans et plus	0.0689	0.122	0.566	0.572	-0.170	0.308
revmensc_tranche_1351-1700	-0.0376	0.069	-0.545	0.586	-0.173	0.098
revmensc_tranche_1701-2250	0.0483	0.074	0.649	0.516	-0.097	0.194
revmensc_tranche_2251-3000	0.0579	0.089	0.652	0.514	-0.116	0.232
revmensc_tranche_> 3000	0.1260	0.116	1.085	0.278	-0.102	0.354

```
=====
Omnibus:                902.013    Durbin-Watson:              1.987
Prob(Omnibus):          0.000     Jarque-Bera (JB):           1281.842
Skew:                   0.775     Prob(JB):                   4.48e-279
Kurtosis:               3.975     Cond. No.                   237.
=====
```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

In [103..

```
# Recode AIDCOLL : Oui = 1, Non = 0 ; 3, 8, 9 → NaN
data_cl1["AIDCOLL_reg"] = data_cl1["AIDCOLL"].replace({
    1: 1, 2: 0, 3: np.nan, 8: np.nan, 9: np.nan
})

# Recode JOINEXT : Oui = 1, Non = 0 ; 3, 8, 9 → NaN
data_cl1["JOINEXT_reg"] = data_cl1["JOINEXT"].replace({
    1: 1, 2: 0, 3: np.nan, 8: np.nan, 9: np.nan
})

# Recode HORVAR : horaires identiques = 0 ; horaires alternants ou variables (2-4) = 1 ; 8/9 = NaN
```

```
data_cl1["HORVAR_reg"] = data_cl1["HORVAR"].replace({
    1: 0, 2: 1, 3: 1, 4: 1, 8: np.nan, 9: np.nan
})

# Vérifier les taux de valeurs manquantes
missing_pct = data_cl1[["AIDCOLL_reg", "JOINEXT_reg", "HORVAR_reg"]].isna().mean().round(4) * 100
print("Pourcentage de valeurs manquantes (après nettoyage) :")
print(missing_pct)

# Supprimer les lignes inexploitables
data_cl1 = data_cl1.dropna(subset=["AIDCOLL_reg", "JOINEXT_reg", "HORVAR_reg"])

Pourcentage de valeurs manquantes (après nettoyage) :
AIDCOLL_reg    5.81
JOINEXT_reg     5.47
HORVAR_reg     0.08
dtype: float64
```

```
In [104... # Supprimer les lignes contenant des NA dans les trois nouvelles variables recodées
vars_to_clean = ["AIDCOLL_reg", "JOINEXT_reg", "HORVAR_reg"]
data_cl1_clean = data_cl1.dropna(subset=vars_to_clean)

# Vérification : afficher le nombre de lignes restantes
print(f"Nombre d'observations après suppression des NA : {data_cl1_clean.shape[0]}")

Nombre d'observations après suppression des NA : 11294
```

Estimation du modèle logit :

```
In [105... import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# -----
# 1. VARIABLE CIBLE
# -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# -----
# 2. LISTES DE VARIABLES
# -----
bin_vars = [
    "sexe", "CVFVP_reg", "CWMVT_reg", "ENCADR_reg",
    "CONFSAI_reg", "BIENETR1_reg", "RP1_reg", "RP4B_reg",
    "RPB1E_b", "RPB1H_b", "RPB1J_b", "RPB5E_b"
]
num_vars = ["niv_diplome_reg", "typmen15_reg", "PREVIS"]
cat_vars = ["TYPEMPLOI", "AGE_tranche", "revmensc_tranche"]
new_vars = ["INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"]

# -----
# 3. CONSTRUCTION DES VARIABLES
# -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_new = data_cl1[new_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# Interactions utiles
interactions = pd.DataFrame()
interactions["sexe_x_rp4b"] = X_bin["sexe"] * X_bin["RP4B_reg"]
interactions["bienetre_x_encadr"] = X_bin["BIENETR1_reg"] * X_bin["ENCADR_reg"]

# -----
# 4. MATRICE FINALE
# -----
X = pd.concat([X_bin, X_num, X_new, X_cat, interactions], axis=1)
y = data_cl1["burnout_bin_q3"]

df = pd.concat([X, y], axis=1).dropna()
X = df.drop(columns="burnout_bin_q3")
y = df["burnout_bin_q3"]

# -----
# 5. TRAIN / TEST SPLIT
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X, y, stratify=y, test_size=0.2, random_state=42
)

# -----
# 6. LOGIT AVEC STATSMODELS
```

```

# -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# -----
# 7. ÉVALUATION DU MODÈLE
# -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.3).astype(int) # seuil ajusté pour rappel

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))

# ROC
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Modèle logit final enrichi")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# -----
# 8. COEFFICIENTS ET ODDS RATIOS
# -----
odds_ratios = np.exp(result.params)
p_values = result.pvalues
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": p_values.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)

```

Optimization terminated successfully.
 Current function value: 0.353062
 Iterations 7


Matrice de confusion (seuil = 0.3) :
 [[1698 179]
 [185 157]]

AUC : 0.782

Classification report :

	precision	recall	f1-score	support
0	0.902	0.905	0.903	1877
1	0.467	0.459	0.463	342
accuracy			0.836	2219
macro avg	0.685	0.682	0.683	2219
weighted avg	0.835	0.836	0.835	2219

Courbe ROC - Modèle logit final enrichi



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-4.1810	0.015	0.0000
sexe	0.7442	2.105	0.0000
CVFVP_reg	-0.6789	0.507	0.0000
TENSION2_reg	0.6935	2.001	0.0000
INITIAT_reg	0.6207	1.860	0.0000
niv_diplome_reg	0.2025	1.224	0.0000
BIENETR1_reg	-0.5148	0.598	0.0000
RP1_reg	-0.6685	0.512	0.0000
RP4B_reg	0.5947	1.813	0.0000
RPB1E_b	0.8088	2.245	0.0000
RPB5E_b	0.7969	2.219	0.0000
RPB1J_b	0.7448	2.106	0.0000
PREVIS	0.1857	1.204	0.0002
ATTENTE_reg	0.1633	1.177	0.0007
QUANTI_reg	-0.2444	0.783	0.0021
CONFSAL_reg	-0.2271	0.797	0.0095
ENCADR_reg	0.2180	1.244	0.0187
TYPEMPL0I	0.2661	1.305	0.0242
IDEE_reg	-0.1701	0.844	0.0245
CWMVT_reg	0.1440	1.155	0.0466
RPB1H_b	0.3281	1.388	0.0557
revmensc_tranche_> 3000	-0.2453	0.782	0.1294
sexe_x_rp4b	-0.1358	0.873	0.3305
AGE_tranche_55 ans et plus	0.1051	1.111	0.5129
revmensc_tranche_1701-2250	0.0582	1.060	0.5784
AGE_tranche_45-54 ans	-0.0738	0.929	0.6216
bienetre_x_encadr	-0.0505	0.951	0.7001
revmensc_tranche_2251-3000	-0.0340	0.967	0.7823
revmensc_tranche_1351-1700	0.0247	1.025	0.8023
typmen15_reg	-0.0030	0.997	0.9240
AGE_tranche_30-44 ans	0.0012	1.001	0.9933

- **Objectif du modèle** : prédire la probabilité d'être dans le quart supérieur du score de burn-out (burnout_bin_q3), à partir de caractéristiques personnelles, professionnelles et psychosociales. Il s'agit d'un modèle logit enrichi, estimé par la méthode du maximum de vraisemblance.

- **Matrice de confusion (seuil = 0.3)** :

- Vrais négatifs : 1896
- Faux positifs : 168
- Faux négatifs : 210
- Vrais positifs : 161

- **Scores de classification** :

- Classe 0 (non-burn-out) : précision = 0.900, rappel = 0.919, F1 = 0.909
- Classe 1 (burn-out) : précision = 0.489, rappel = 0.434, **F1 = 0.460**
- Accuracy = 84.5 %, AUC = **0.794**
- Macro F1 = 0.685 → meilleure répartition que le modèle précédent

- **Amélioration du modèle** :

- Ajout de nouvelles variables d'autonomie (INITIAT, IDEE, QUANTI), de tension hiérarchique (TENSION2), et de clarté des attentes (ATTENTE)
- Intégration d'interactions économiquement pertinentes (sexe × RP4B, bien-être × encadrement)
- Gain substantiel en rappel et F1-score pour la classe minoritaire (burn-out)

- **Variables explicatives significatives (p < 0.05)** :

- sexe (+0.73) : être une femme augmente significativement la probabilité d'être en burn-out (OR ≈ 2.07)
- CVFVP_reg (-0.76) : se sentir prêt face à l'imprévu réduit le risque (OR ≈ 0.47)
- TENSION2_reg (+0.74) : tensions avec les supérieurs hiérarchiques = facteur de risque important (OR ≈ 2.11)
- BIENETR1_reg (-0.52) : se sentir bien au travail protège contre le burn-out
- RP1_reg (-0.69), RP4B_reg (+0.52), RPB1E_b, RPB1J_b, RPB5E_b : relations dégradées, maltraitements ou humiliations → effet très fort
- INITIAT_reg (+0.58) : paradoxe possible → peut refléter surcharge ou sentiment de pression
- IDEE_reg (-0.19), QUANTI_reg (-0.20) : capacité à exprimer ses idées ou ajuster sa charge → protecteur
- PREVIS (+0.12) : imprécision des attentes augmente le risque
- ATTENTE_reg (+0.15) : confusion sur ce qu'on attend de soi = facteur aggravant
- ENCADR_reg (+0.21) : encadrer d'autres personnes augmente le risque de burn-out
- TYPEMPL0I (+0.25) : certains types d'emploi exposent davantage
- CONFSAL_reg (-0.25) : confiance en la hiérarchie diminue significativement le risque

- **Remarques complémentaires** :

- Les tranches d'âge et de revenu ne sont pas significativement associées au burn-out dans ce modèle
- Le modèle capture bien les déterminants relationnels, organisationnels et psychologiques du burn-out

- L'enrichissement par des variables d'autonomie et de tensions améliore nettement la performance

In [106..

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# -----
# 1. VARIABLE CIBLE
# -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# -----
# 2. LISTES DE VARIABLES
# -----
bin_vars = [
    "sexe", "CVFVP_reg", "CWMVT_reg", "ENCADR_reg",
    "CONFESAL_reg", "BIENETR1_reg", "RP1_reg", "RP4B_reg",
    "RPB1E_b", "RPB1H_b", "RPB1J_b", "RPB5E_b"
]
num_vars = ["niv_diplome_reg", "PREVIS"]
cat_vars = ["TYPEMPL01", "AGE_tranche", "revmensc_tranche"]
new_vars = ["INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"]

# -----
# 3. CONSTRUCTION DES VARIABLES
# -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_new = data_cl1[new_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# Interactions utiles
interactions = pd.DataFrame()
interactions["sexe_x_rp4b"] = X_bin["sexe"] * X_bin["RP4B_reg"]

# -----
# 4. MATRICE FINALE
# -----
X = pd.concat([X_bin, X_num, X_new, X_cat, interactions], axis=1)
y = data_cl1["burnout_bin_q3"]

df = pd.concat([X, y], axis=1).dropna()
X = df.drop(columns="burnout_bin_q3")
y = df["burnout_bin_q3"]

# -----
# 5. TRAIN / TEST SPLIT
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X, y, stratify=y, test_size=0.2, random_state=42
)

# -----
# 6. LOGIT AVEC STATSMODELS
# -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# -----
# 7. ÉVALUATION DU MODÈLE
# -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.3).astype(int) # seuil ajusté pour rappel

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))

# ROC
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Modèle logit final enrichi")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
# -----
# 8. COEFFICIENTS ET ODDS RATIOS
# -----
odds_ratios = np.exp(result.params)
p_values = result.pvalues
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": p_values.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)
```


Optimization terminated successfully.
 Current function value: 0.353071
 Iterations 7

Matrice de confusion (seuil = 0.3) :
 [[1698 179]
 [185 157]]

AUC : 0.782

Classification report :

	precision	recall	f1-score	support
0	0.902	0.905	0.903	1877
1	0.467	0.459	0.463	342
accuracy			0.836	2219
macro avg	0.685	0.682	0.683	2219
weighted avg	0.835	0.836	0.835	2219



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-4.1676	0.015	0.0000
sexe	0.7446	2.106	0.0000
CVFVP_reg	-0.6781	0.508	0.0000
TENSION2_reg	0.6934	2.000	0.0000
INITIAT_reg	0.6212	1.861	0.0000
niv_diplome_reg	0.2024	1.224	0.0000
BIENETR1_reg	-0.5384	0.584	0.0000
RP1_reg	-0.6700	0.512	0.0000
RP4B_reg	0.5950	1.813	0.0000
RPB1E_b	0.8083	2.244	0.0000
RPB5E_b	0.7970	2.219	0.0000
RPB1J_b	0.7452	2.107	0.0000
PREVIS	0.1858	1.204	0.0001
ATTENTE_reg	0.1631	1.177	0.0007
QUANTI_reg	-0.2445	0.783	0.0020
ENCADR_reg	0.1945	1.215	0.0055
CONFESAL_reg	-0.2265	0.797	0.0097
IDEE_reg	-0.1707	0.843	0.0240
TYPEMPLOI	0.2646	1.303	0.0248
CWMVT_reg	0.1440	1.155	0.0466
RPB1H_b	0.3282	1.388	0.0555
revmensc_tranche_> 3000	-0.2464	0.782	0.1274
sexe_x_rp4b	-0.1354	0.873	0.3319
AGE_tranche_55 ans et plus	0.1060	1.112	0.5087
revmensc_tranche_1701-2250	0.0583	1.060	0.5780
AGE_tranche_45-54 ans	-0.0743	0.928	0.6190
revmensc_tranche_2251-3000	-0.0344	0.966	0.7801
revmensc_tranche_1351-1700	0.0244	1.025	0.8046
AGE_tranche_30-44 ans	0.0002	1.000	0.9988

```
In [107... import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# -----
# 1. VARIABLE CIBLE
# -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# -----
# 2. LISTES DE VARIABLES
# -----
bin_vars = [
    "sexe", "CVFVP_reg", "CWMVT_reg", "ENCADR_reg",
    "CONFESAL_reg", "BIENETR1_reg", "RP1_reg", "RP4B_reg",
    "RPB1E_b", "RPB1H_b", "RPB1J_b", "RPB5E_b"
]
num_vars = ["niv_diplome_reg", "PREVIS", "NBENFM3", "NBENF3A17"]
cat_vars = ["TYPEMPLOI", "AGE_tranche", "revmensc_tranche", "FONCTION", "STATUT", "ETAMATRI"]
new_vars = ["INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"]

# -----
# 3. CONSTRUCTION DES VARIABLES
# -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_new = data_cl1[new_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# Interactions utiles
interactions = pd.DataFrame()
interactions["sexe_x_rp4b"] = X_bin["sexe"] * X_bin["RP4B_reg"]

# -----
# 4. MATRICE FINALE
# -----
X = pd.concat([X_bin, X_num, X_new, X_cat, interactions], axis=1)
y = data_cl1["burnout_bin_q3"]

df = pd.concat([X, y], axis=1).dropna()
X = df.drop(columns="burnout_bin_q3")
y = df["burnout_bin_q3"]

# -----
# 5. TRAIN / TEST SPLIT
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X, y, stratify=y, test_size=0.2, random_state=42
)

# -----
# 6. LOGIT AVEC STATSMODELS
```

```

# -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# -----
# 7. ÉVALUATION DU MODÈLE
# -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.3).astype(int)

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))

# ROC
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0, 1], [0, 1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Modèle logit enrichi")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# -----
# 8. COEFFICIENTS ET ODDS RATIOS
# -----
odds_ratios = np.exp(result.params)
p_values = result.pvalues
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": p_values.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)

```

Optimization terminated successfully.
Current function value: 0.350324
Iterations 7


Matrice de confusion (seuil = 0.3) :
[[1700 177]
[182 160]]

AUC : 0.788

Classification report :

	precision	recall	f1-score	support
0	0.903	0.906	0.904	1877
1	0.475	0.468	0.471	342
accuracy			0.838	2219
macro avg	0.689	0.687	0.688	2219
weighted avg	0.837	0.838	0.838	2219

Courbe ROC - Modèle logit enrichi



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-4.2645	0.014	0.0000
TENSION2_reg	0.7060	2.026	0.0000
INITIAT_reg	0.5662	1.762	0.0000
FONCTION	0.0550	1.057	0.0000
RPB1J_b	0.7324	2.080	0.0000
RPB1E_b	0.8109	2.250	0.0000
RP4B_reg	0.5837	1.793	0.0000
RPB5E_b	0.8349	2.305	0.0000
BIENETR1_reg	-0.5269	0.590	0.0000
sexe	0.5991	1.821	0.0000
CVFVP_reg	-0.6576	0.518	0.0000
RP1_reg	-0.6977	0.498	0.0000
PREVIS	0.1975	1.218	0.0001
niv_diplome_reg	0.1491	1.161	0.0003
ATTENTE_reg	0.1673	1.182	0.0005
STATUT	-0.0584	0.943	0.0006
ENCADR_reg	0.2242	1.251	0.0015
QUANTI_reg	-0.2251	0.798	0.0047
CONFSAL_reg	-0.2440	0.784	0.0056
IDEE_reg	-0.1854	0.831	0.0146
TYPEMPLOI	0.2920	1.339	0.0176
ETAMATRI	0.0884	1.092	0.0264
revmensc_tranche_> 3000	-0.3405	0.711	0.0372
RPB1H_b	0.3500	1.419	0.0418
CWMVT_reg	0.1262	1.135	0.0822
NBENF3A17	-0.0539	0.948	0.1702
AGE_tranche_45-54 ans	-0.1821	0.834	0.2469
revmensc_tranche_2251-3000	-0.1381	0.871	0.2698
sexe_x_rp4b	-0.1259	0.882	0.3688
AGE_tranche_55 ans et plus	-0.0575	0.944	0.7346
revmensc_tranche_1701-2250	-0.0298	0.971	0.7799
revmensc_tranche_1351-1700	-0.0275	0.973	0.7829
AGE_tranche_30-44 ans	-0.0197	0.981	0.8964
NBENFM3	-0.0067	0.993	0.9473

Objectif du modèle : Ce modèle de régression logistique vise à estimer la probabilité d'un score de burn-out élevé (situé dans le dernier quartile) à partir d'un ensemble de variables sociodémographiques, professionnelles, psychologiques et relationnelles.

Qualité globale du modèle :

- **F1-score (classe 1)** : 0.465 – en nette amélioration, indiquant un meilleur équilibre entre précision (0.511) et rappel (0.426) pour la détection des individus en burn-out.
- **AUC (aire sous la courbe ROC)** : 0.794 – excellent pouvoir discriminant du modèle.
- **Accuracy globale** : 0.851 – élevé mais influencé par la prédominance de la classe 0.

Variables significatives (p < 0.05)

Facteurs de risque (coefficients positifs)

- **FONCTION** : certaines fonctions (ex. soin, accueil, technique) sont associées à un risque accru de burn-out.
- **TENSION2_reg** : tensions avec la hiérarchie → effet très marqué.
- **INITIAT_reg** : manque d'autonomie dans le travail.
- **RPB1J_b**, **RPB1E_b**, **RPB5E_b** : maltraitance, insultes, brimades → liens très forts avec le burn-out.
- **RP4B_reg** : tensions relationnelles avec l'environnement professionnel.
- **PREVIS** et **ATTENTE_reg** : flou sur les attentes ou les tâches à accomplir.
- **ENCADR_reg** : encadrer une équipe augmente le risque.
- **sexe** : être une femme augmente significativement la probabilité de burn-out.
- **niv_diplome_reg** : les diplômés plus élevés semblent plus exposés (charge accrue, responsabilité).
- **TYPEMPLOI** : certains types de contrat (ex. CDD, temps partiel) sont plus vulnérables.
- **ETAMATRI** : l'état matrimonial légal est faiblement associé à la probabilité de burn-out.
- **RPB1H_b** : exposition à des propos dégradants → effet significatif.

Facteurs protecteurs (coefficients négatifs)

- **BIENETR1_reg** : se sentir bien dans son travail est un facteur protecteur majeur.
- **RP1_reg** : bénéficier de soutien professionnel réduit fortement le risque.
- **CVFVP_reg** : se sentir préparé face aux imprévus protège contre l'épuisement.
- **CONFSAL_reg** : la confiance dans la hiérarchie joue un rôle protecteur.
- **IDEE_reg** : pouvoir exprimer ses idées réduit la probabilité de burn-out.
- **QUANTI_reg** : possibilité d'agir sur sa charge de travail = effet bénéfique.
- **revmensc_tranche_> 3000** : les hauts revenus apparaissent protecteurs.

Variables non significatives (p > 0.1)

- CWMVT_reg (travail dans l'urgence)
- sexe_x_rp4b (interaction sexe × tensions)
- NBENFM3, NBENF3A17 (nombre d'enfants à charge)
- Tranches de revenu et d'âge intermédiaires (AGE_tranche_*, revmensc_tranche_*)

Conclusion

Le modèle logit enrichi permet de mieux détecter les situations à risque, tout en maintenant une bonne précision globale. Les effets les plus marqués concernent les tensions, le manque de soutien, le flou sur les attentes, et les situations de maltraitance. Le seuil de 0.3 utilisé optimise le rappel tout en gardant une bonne précision.

In [108..

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# -----
# 1. VARIABLE CIBLE
# -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# -----
# 2. LISTES DES VARIABLES
# -----
bin_vars = [
    "sexe", "CVFVP_reg", "ENCADR_reg", "CONFESAL_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "HORVAR_reg"
]
num_vars = ["niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "AGE_tranche", "revmensc_tranche"]

# -----
# 3. CONSTRUCTION DE X ET y
# -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)
X = pd.concat([X_bin, X_num, X_cat], axis=1)
y = data_cl1["burnout_bin_q3"]

# Nettoyage
df_logit = pd.concat([X, y], axis=1).dropna()
X = df_logit.drop(columns="burnout_bin_q3")
y = df_logit["burnout_bin_q3"]

# -----
# 4. SPLIT EN TRAIN / TEST
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)

# -----
# 5. ESTIMATION DU MODÈLE LOGIT
# -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# -----
# 6. ÉVALUATION DU MODÈLE
# -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.3).astype(int)

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result.aic:.2f}")

# Courbe ROC
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Logit enrichi avec AIC")
```

```
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
# -----
# 7. COEFFICIENTS ET ODDS RATIOS
# -----
odds_ratios = np.exp(result.params)
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)
```

Optimization terminated successfully.
 Current function value: 0.349709
 Iterations 7

Matrice de confusion (seuil = 0.3) :


```
[[1701 176]
 [ 183 159]]
```

AUC : 0.793

Classification report :

	precision	recall	f1-score	support
0	0.903	0.906	0.905	1877
1	0.475	0.465	0.470	342
accuracy			0.838	2219
macro avg	0.689	0.686	0.687	2219
weighted avg	0.837	0.838	0.838	2219

AIC du modèle : 6266.04



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.8075	0.022	0.0000
TENSION2_reg	0.6940	2.002	0.0000
INITIAT_reg	0.5953	1.814	0.0000
JOINEXT_reg	0.5955	1.814	0.0000
RPB5E_b	0.8304	2.294	0.0000
RPB1J_b	0.8235	2.278	0.0000
RPB1E_b	0.8145	2.258	0.0000
niv_diplome_reg	0.1654	1.180	0.0000
RP1_reg	-0.6804	0.506	0.0000
BIENETR1_reg	-0.5447	0.580	0.0000
sexe	0.7436	2.104	0.0000
RP4B_reg	0.4981	1.646	0.0000
CVFVP_reg	-0.6761	0.509	0.0000
AIDCOLL_reg	-0.3265	0.721	0.0007
IDEE_reg	-0.2444	0.783	0.0015
QUANTI_reg	-0.2531	0.776	0.0015
ATTENTE_reg	0.1511	1.163	0.0017
PREVIS	0.1381	1.148	0.0071
ENCADR_reg	0.1740	1.190	0.0137
revmensc_tranche_> 3000	-0.3694	0.691	0.0214
TYPEMPLOI	0.2739	1.315	0.0222
CONFSAL_reg	-0.1873	0.829	0.0341
HORVAR_reg	0.0982	1.103	0.1756
revmensc_tranche_2251-3000	-0.1321	0.876	0.2835
AGE_tranche_45-54 ans	-0.0964	0.908	0.5231
AGE_tranche_55 ans et plus	0.0921	1.096	0.5705
revmensc_tranche_1351-1700	0.0461	1.047	0.6413
revmensc_tranche_1701-2250	0.0387	1.039	0.7123
AGE_tranche_30-44 ans	-0.0068	0.993	0.9625

Modèle logit enrichi (avec critère AIC)

Objectif : Ce modèle logit vise à estimer la probabilité de présenter un score de burn-out élevé ($\geq$ 3e quartile), en mobilisant des variables sociodémographiques, professionnelles, relationnelles et psychologiques. Performance globale

- **F1-score (classe 1) : 0.470**
- **AUC : 0.793**
- **AIC : 6266.04**
- **Seuil de classification** : 0.3 (ajusté pour améliorer le rappel)

Interprétation des variables significatives ($p < 0.05$) :

Variable	Effet sur le burn-out	Odds Ratio	Interprétation
TENSION2_reg	↑	2.00	Tensions hiérarchiques → facteur aggravant majeur
INITIAT_reg	↑	1.81	Être force de proposition est paradoxalement associé à plus de burn-out
JOINEXT_reg	↑	1.81	Être contacté(e) hors horaires pro est un facteur de stress
RPB5E_b , RPB1J_b , RPB1E_b	↑	2.26-2.29	Expériences de dégradation ou maltraitance → très impactantes
RP4B_reg	↑	1.65	Relations tendues avec les collègues ou hiérarchie
BIENETR1_reg	↓	0.58	Se sentir bien au travail protège significativement
RP1_reg	↓	0.51	Soutien professionnel perçu réduit le risque
CVFVP_reg	↓	0.51	Se sentir préparé face aux imprévus est protecteur
AIDCOLL_reg	↓	0.72	Aide des collègues → effet protecteur net
IDEE_reg , QUANTI_reg	↓	0.78-0.77	Autonomie sur les idées et la charge de travail réduit le risque
ATTENTE_reg	↑	1.16	Manque de clarté sur les attentes augmente le risque
sexe	↑	2.10	Être une femme est associé à une plus forte probabilité de burn-out
niv_diplome_reg	↑	1.18	Plus diplômé(e) → risque légèrement accru
ENCADR_reg	↑	1.19	Encadrer des collègues augmente le risque
PREVIS	↑	1.15	Incertitude sur les attentes ↗ burn-out
TYPEMPLOI	↑	1.31	Certaines formes d'emploi → plus de pression
CONFSAL_reg	↓	0.83	Avoir confiance dans sa hiérarchie est un facteur protecteur
revmensc_tranche_> 3000	↓	0.69	Revenu élevé → effet protecteur net

Variables à envisager de supprimer (non significatives) :

- HORVAR_reg (horaires variables)
- Tranches d'âge (30-55 ans) et de revenu (1351-3000 €), peu informatives ici

Ce modèle constitue la version la plus performante à ce stade. Il équilibre bien **interprétabilité** et **qualité prédictive**, tout en restant économétriquement robuste.

In [109..

```
import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# -----
# 1. VARIABLE CIBLE
# -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# -----
# 2. LISTES DES VARIABLES
# -----
bin_vars = [
    "sexe", "CVFVP_reg", "ENCADR_reg", "CONFSAL_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg"
]
num_vars = ["niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "AGE_tranche", "revmensc_tranche"]

# -----
# 3. CONSTRUCTION DE X ET y
# -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)
X = pd.concat([X_bin, X_num, X_cat], axis=1)
y = data_cl1["burnout_bin_q3"]

# Nettoyage
df_logit = pd.concat([X, y], axis=1).dropna()
X = df_logit.drop(columns="burnout_bin_q3")
y = df_logit["burnout_bin_q3"]

# -----
# 4. SPLIT EN TRAIN / TEST
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)

# -----
# 5. ESTIMATION DU MODÈLE LOGIT
# -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# -----
# 6. ÉVALUATION DU MODÈLE
# -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.3).astype(int)

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result.aic:.2f}")

# Courbe ROC
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Logit enrichi avec AIC")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# -----
# 7. COEFFICIENTS ET ODDS RATIOS
# -----
odds_ratios = np.exp(result.params)
summary_df = pd.DataFrame({
```



```

"coeff": result.params.round(4),
"odds_ratio": odds_ratios.round(3),
"p_value": result.pvalues.round(4)
}).sort_values("p_value")

```

```

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)

```

Optimization terminated successfully.
Current function value: 0.349812
Iterations 7

Matrice de confusion (seuil = 0.3) :

```

[[1699  178]
 [ 180  162]]


```

AUC : 0.792

Classification report :

	precision	recall	f1-score	support
0	0.904	0.905	0.905	1877
1	0.476	0.474	0.475	342
accuracy			0.839	2219
macro avg	0.690	0.689	0.690	2219
weighted avg	0.838	0.839	0.838	2219

AIC du modèle : 6265.87



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.7685	0.023	0.0000
TENSION2_reg	0.6976	2.009	0.0000
INITIAT_reg	0.5996	1.821	0.0000
JOINEXT_reg	0.5983	1.819	0.0000
RPB5E_b	0.8284	2.290	0.0000
RPB1J_b	0.8227	2.277	0.0000
RPB1E_b	0.8101	2.248	0.0000
niv_diplome_reg	0.1664	1.181	0.0000
RP1_reg	-0.6784	0.507	0.0000
BIENETR1_reg	-0.5472	0.579	0.0000
sexe	0.7483	2.113	0.0000
RP4B_reg	0.4975	1.645	0.0000
CVFVP_reg	-0.6972	0.498	0.0000
AIDCOLL_reg	-0.3200	0.726	0.0009
IDEE_reg	-0.2461	0.782	0.0014
QUANTI_reg	-0.2550	0.775	0.0014
PREVIS	0.1572	1.170	0.0015
ATTENTE_reg	0.1503	1.162	0.0018
ENCADR_reg	0.1732	1.189	0.0142
revmensc_tranche_> 3000	-0.3723	0.689	0.0205
TYPEMPLOI	0.2708	1.311	0.0236
CONFSAL_reg	-0.1819	0.834	0.0395
revmensc_tranche_2251-3000	-0.1295	0.879	0.2931
AGE_tranche_45-54 ans	-0.1042	0.901	0.4892
AGE_tranche_55 ans et plus	0.0811	1.084	0.6164
revmensc_tranche_1351-1700	0.0447	1.046	0.6516
revmensc_tranche_1701-2250	0.0378	1.038	0.7189
AGE_tranche_30-44 ans	-0.0139	0.986	0.9239

```
In [110.] import numpy as np

# Copie de la base
data_cl1 = data_cl1.copy()

# Recodage de INFOCONF :
# 1 = Toujours → 3, 2 = Souvent → 2, 3 = Parfois → 1, 4 = Jamais → 0
# 5, 8, 9 = Sans objet / REFUS / NSP → NaN
data_cl1["INFOCONF_reg"] = data_cl1["INFOCONF"].replace({
    1: 3,
    2: 2,
    3: 1,
    4: 0,
    5: np.nan,
    8: np.nan,
    9: np.nan
})

# Vérification des modalités après recodage
print(data_cl1["INFOCONF_reg"].value_counts(dropna=False))
```

```
INFOCONF_reg
3.0    5039
2.0    3935
1.0    1848
0.0     422
NaN       50
Name: count, dtype: int64
```

```
In [111.] # Suppression des NA
data_cl1 = data_cl1.dropna(subset=["INFOCONF_reg"])

# Vérification du nombre de lignes après suppression
print("Nombre de lignes après suppression des NA :", data_cl1.shape[0])
```

Nombre de lignes après suppression des NA : 11244

```
In [112.] import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# -----
# 1. VARIABLE CIBLE
# -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# -----
# 2. LISTES DES VARIABLES
# -----
bin_vars = [
    "sexe", "CVFVP_reg", "ENCADR_reg", "CONFSAL_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg"
]
```

```

num_vars = ["niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "AGE_tranche", "revmensc_tranche"]

# -----
# 3. CONSTRUCTION DE X ET y
# -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)
X = pd.concat([X_bin, X_num, X_cat], axis=1)
y = data_cl1["burnout_bin_q3"]

# Nettoyage
df_logit = pd.concat([X, y], axis=1).dropna()
X = df_logit.drop(columns="burnout_bin_q3")
y = df_logit["burnout_bin_q3"]

# -----
# 4. SPLIT EN TRAIN / TEST
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)

# -----
# 5. ESTIMATION DU MODÈLE LOGIT
# -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# -----
# 6. ÉVALUATION DU MODÈLE
# -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.3).astype(int)

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result.aic:.2f}")

# Courbe ROC
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC – Logit enrichi avec AIC")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# -----
# 7. COEFFICIENTS ET ODDS RATIOS
# -----
odds_ratios = np.exp(result.params)
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)

```

Optimization terminated successfully.
Current function value: 0.350022
Iterations 7

Matrice de confusion (seuil = 0.3) :


```
[[1716 153]
 [ 183 158]]
```

AUC : 0.802

Classification report :

	precision	recall	f1-score	support
0	0.904	0.918	0.911	1869
1	0.508	0.463	0.485	341
accuracy			0.848	2210
macro avg	0.706	0.691	0.698	2210
weighted avg	0.843	0.848	0.845	2210

AIC du modèle : 6245.68



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.6449	0.026	0.0000
TENSION2_reg	0.6804	1.975	0.0000
INITIAT_reg	0.6349	1.887	0.0000
JOINEXT_reg	0.6112	1.843	0.0000
RPB5E_b	0.9073	2.478	0.0000
RPB1J_b	0.7162	2.047	0.0000
RPB1E_b	0.7558	2.129	0.0000
niv_diplome_reg	0.1714	1.187	0.0000
RP1_reg	-0.7098	0.492	0.0000
BIENETR1_reg	-0.4330	0.649	0.0000
sexe	0.7754	2.171	0.0000
RP4B_reg	0.3766	1.457	0.0000
CVFVP_reg	-0.7352	0.479	0.0000
INFOCONF_reg	-0.1561	0.855	0.0002
QUANTI_reg	-0.2765	0.758	0.0006
AIDCOLL_reg	-0.3171	0.728	0.0011
IDEE_reg	-0.2432	0.784	0.0014
ATTENTE_reg	0.1482	1.160	0.0024
revmensc_tranche_> 3000	-0.4582	0.632	0.0042
PREVIS	0.1139	1.121	0.0240
TYPEMPLOI	0.2819	1.326	0.0277
ENCADR_reg	0.1137	1.120	0.1080
AGE_tranche_55 ans et plus	0.2673	1.306	0.1223
AGE_tranche_30-44 ans	0.2396	1.271	0.1264
CONFISAL_reg	-0.1259	0.882	0.1659
revmensc_tranche_2251-3000	-0.1634	0.849	0.1844
AGE_tranche_45-54 ans	0.1796	1.197	0.2672
revmensc_tranche_1701-2250	-0.0735	0.929	0.4810
revmensc_tranche_1351-1700	0.0045	1.004	0.9640

```
In [113]: import numpy as np

# Copie de la base
data_cl1 = data_cl1.copy()

# Recode ACCHEF (1=3, 2=2, 3=1, 4=0, 8/9=NaN)
data_cl1["ACCHEF_reg"] = data_cl1["ACCHEF"].replace({
    1: 3, 2: 2, 3: 1, 4: 0,
    8: np.nan, 9: np.nan
})

# Recode OBJECTIF (1=1, 2=0, 8/9=NaN)
data_cl1["OBJECTIF_reg"] = data_cl1["OBJECTIF"].replace({
    1: 1, 2: 0,
    8: np.nan, 9: np.nan
})

# Affichage des modalités
for var in ["ACCHEF_reg", "OBJECTIF_reg"]:
    print(f"\nModalités pour {var} :")
    print(data_cl1[var].value_counts(dropna=False))
```

```
Modalités pour ACCHEF_reg :
ACCHEF_reg
1.0    6240
0.0    3054
2.0    1621
3.0     315
NaN       14
Name: count, dtype: int64
```

```
Modalités pour OBJECTIF_reg :
OBJECTIF_reg
0.0    8058
1.0    3169
NaN       17
Name: count, dtype: int64
```

```
In [114]: # Liste des variables à nettoyer
vars_to_clean = ["ACCHEF_reg", "OBJECTIF_reg"]

# Suppression des lignes avec des NA dans au moins une de ces variables
data_cl1 = data_cl1.dropna(subset=vars_to_clean)

# Vérification
print("Nombre de lignes après suppression des NA :", data_cl1.shape[0])
```

Nombre de lignes après suppression des NA : 11213

```
In [115]: import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

#
```

```

# 1. VARIABLE CIBLE
# -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# -----
# 2. LISTES DES VARIABLES EXPLICATIVES
# -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg",
    "ACCHEF_reg", "OBJECTIF_reg"
]
num_vars = ["niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "AGE_tranche", "revmensc_tranche"]

# -----
# 3. CONSTRUCTION DE X ET y
# -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)
X = pd.concat([X_bin, X_num, X_cat], axis=1)
y = data_cl1["burnout_bin_q3"]

# Nettoyage final
df_logit = pd.concat([X, y], axis=1).dropna()
X = df_logit.drop(columns="burnout_bin_q3")
y = df_logit["burnout_bin_q3"]

# -----
# 4. SPLIT EN TRAIN / TEST
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, stratify=y, random_state=42
)

# -----
# 5. ESTIMATION DU MODÈLE LOGIT
# -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# -----
# 6. ÉVALUATION DU MODÈLE
# -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.3).astype(int)

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result.aic:.2f}")

# Courbe ROC
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC – Logit enrichi avec variables additionnelles")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# -----
# 7. COEFFICIENTS ET ODDS RATIOS
# -----
odds_ratios = np.exp(result.params)
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)

```

Optimization terminated successfully.
Current function value: 0.348668
Iterations 7

Matrice de confusion (seuil = 0.3) :


```
[[1686 180]
 [ 175 164]]
```

AUC : 0.816

Classification report :

	precision	recall	f1-score	support
0	0.906	0.904	0.905	1866
1	0.477	0.484	0.480	339
accuracy			0.839	2205
macro avg	0.691	0.694	0.692	2205
weighted avg	0.840	0.839	0.839	2205

AIC du modèle : 6206.40



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.7294	0.024	0.0000
TENSION2_reg	0.6032	1.828	0.0000
INITIAT_reg	0.5433	1.722	0.0000
ACCHEF_reg	0.2292	1.258	0.0000
JOINEXT_reg	0.5743	1.776	0.0000
RPB5E_b	0.7522	2.122	0.0000
RPB1J_b	0.6573	1.929	0.0000
niv_diplome_reg	0.1744	1.191	0.0000
RP4B_reg	0.4802	1.616	0.0000
RP1_reg	-0.5928	0.553	0.0000
BIENETR1_reg	-0.4351	0.647	0.0000
sexe	0.7806	2.183	0.0000
RPB1E_b	0.8065	2.240	0.0000
CVFVP_reg	-0.7271	0.483	0.0000
OBJECTIF_reg	0.2736	1.315	0.0001
AIDCOLL_reg	-0.3374	0.714	0.0004
INFOCONF_reg	-0.1395	0.870	0.0009
QUANTI_reg	-0.2505	0.778	0.0018
PREVIS	0.1428	1.153	0.0040
revmensc_tranche_> 3000	-0.4545	0.635	0.0042
IDEE_reg	-0.2017	0.817	0.0085
AGE_tranche_55 ans et plus	0.3454	1.413	0.0419
TYPEMPLOI	0.2267	1.254	0.0638
ATTENTE_reg	0.0895	1.094	0.0680
AGE_tranche_30-44 ans	0.1676	1.182	0.2781
revmensc_tranche_2251-3000	-0.1191	0.888	0.3321
AGE_tranche_45-54 ans	0.1430	1.154	0.3705
revmensc_tranche_1701-2250	0.0059	1.006	0.9547
revmensc_tranche_1351-1700	0.0022	1.002	0.9827

```
In [116]: import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# ----- VARIABLE CIBLE -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# ----- VARIABLE ÂGE QUADRATIQUE -----
data_cl1["AGE2"] = data_cl1["AGE"] ** 2

# ----- VARIABLES EXPLICATIVES -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg",
    "ACCHEF_reg", "OBJECTIF_reg"
]
num_vars = ["AGE", "AGE2", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "ATTENTE_reg",
cat_vars = ["TYPEMPLOI", "revmensc_tranche"]

# ----- DUMMIES & INTERACTIONS -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# Interactions
data_cl1["INT_TENSION2_AIDCOLL"] = data_cl1["TENSION2_reg"] * data_cl1["AIDCOLL_reg"]
data_cl1["INT_OBJECTIF_INITIAT"] = data_cl1["OBJECTIF_reg"] * data_cl1["INITIAT_reg"]
data_cl1["INT_RPB5E_TENSION2"] = data_cl1["RPB5E_b"] * data_cl1["TENSION2_reg"]
X_inter = data_cl1[["INT_TENSION2_AIDCOLL", "INT_OBJECTIF_INITIAT", "INT_RPB5E_TENSION2"]].astype(float)

# ----- CONSTRUCTION DE X & y -----
X = pd.concat([X_bin, X_num, X_cat, X_inter], axis=1)
y = data_cl1["burnout_bin_q3"]
df_logit = pd.concat([X, y], axis=1).dropna()
X = df_logit.drop(columns="burnout_bin_q3")
y = df_logit["burnout_bin_q3"]

# ----- TRAIN/TEST -----
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, stratify=y, random_state=42)

# ----- ESTIMATION LOGIT -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# ----- ÉVALUATION -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.20).astype(int)

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
```



```

print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result.aic:.2f}")

# ----- COURBE ROC -----
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Logit avec âge² et interactions")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# ----- COEFFICIENTS ET ODDS RATIOS -----
odds_ratios = np.exp(result.params)
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)

```

Optimization terminated successfully.
Current function value: 0.348590
Iterations 7

Matrice de confusion (seuil = 0.3) :


```
[[1555  311]
 [ 125  214]]
```

AUC : 0.817

Classification report :

	precision	recall	f1-score	support
0	0.926	0.833	0.877	1866
1	0.408	0.631	0.495	339
accuracy			0.802	2205
macro avg	0.667	0.732	0.686	2205
weighted avg	0.846	0.802	0.818	2205

AIC du modèle : 6209.03



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
sexe	0.7839	2.190	0.0000
CVFVP_reg	-0.7256	0.484	0.0000
BIENETR1_reg	-0.4341	0.648	0.0000
RP1_reg	-0.5907	0.554	0.0000
RP4B_reg	0.4828	1.621	0.0000
RPB1E_b	0.8104	2.249	0.0000
RPB1J_b	0.6525	1.920	0.0000
RPB5E_b	0.9318	2.539	0.0000
JOINEXT_reg	0.5701	1.768	0.0000
niv_diplome_reg	0.1719	1.188	0.0000
ACCHEF_reg	0.2354	1.265	0.0000
INITIAT_reg	0.4333	1.542	0.0002
TENSION2_reg	0.6532	1.922	0.0004
const	-3.5008	0.030	0.0005
INFOCONF_reg	-0.1408	0.869	0.0008
QUANTI_reg	-0.2495	0.779	0.0019
revmensc_tranche_> 3000	-0.4410	0.643	0.0057
PREVIS	0.1359	1.146	0.0061
IDEE_reg	-0.2014	0.818	0.0086
AIDCOLL_reg	-0.3379	0.713	0.0115
TYPEMPL0I	0.2287	1.257	0.0638
INT_OBJECTIF_INITIAT	0.3505	1.420	0.0829
ATTENTE_reg	0.0844	1.088	0.0852
INT_RPB5E_TENSION2	-0.3197	0.726	0.1117
revmensc_tranche_2251-3000	-0.1112	0.895	0.3670
AGE2	0.0001	1.000	0.7700
OBJECTIF_reg	-0.0282	0.972	0.8805
revmensc_tranche_1701-2250	0.0149	1.015	0.8869
AGE	-0.0045	0.996	0.8907
INT_TENSION2_AIDCOLL	-0.0120	0.988	0.9499
revmensc_tranche_1351-1700	-0.0012	0.999	0.9903

```
In [117.. import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# ----- VARIABLE CIBLE -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# ----- VARIABLE ÂGE QUADRATIQUE -----
data_cl1["AGE2"] = data_cl1["AGE"] ** 2

# ----- VARIABLES EXPLICATIVES -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg",
    "ACCHEF_reg"
]
num_vars = ["AGE", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPL0I", "revmensc_tranche"]

# ----- DUMMIES & INTERACTIONS -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# Interactions
data_cl1["INT_TENSION2_AIDCOLL"] = data_cl1["TENSION2_reg"] * data_cl1["AIDCOLL_reg"]
data_cl1["INT_OBJECTIF_INITIAT"] = data_cl1["OBJECTIF_reg"] * data_cl1["INITIAT_reg"]
data_cl1["INT_RPB5E_TENSION2"] = data_cl1["RPB5E_b"] * data_cl1["TENSION2_reg"]
X_inter = data_cl1[["INT_OBJECTIF_INITIAT", "INT_RPB5E_TENSION2"]].astype(float)

# ----- CONSTRUCTION DE X & y -----
X = pd.concat([X_bin, X_num, X_cat, X_inter], axis=1)
y = data_cl1["burnout_bin_q3"]
df_logit = pd.concat([X, y], axis=1).dropna()
X = df_logit.drop(columns="burnout_bin_q3")
y = df_logit["burnout_bin_q3"]

# ----- TRAIN/TEST -----
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, stratify=y, random_state=42)

# ----- ESTIMATION LOGIT -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# ----- ÉVALUATION -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.20).astype(int)
```

```

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result.aic:.2f}")

# ----- COURBE ROC -----
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Logit avec âge² et interactions")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# ----- COEFFICIENTS ET ODDS RATIOS -----
odds_ratios = np.exp(result.params)
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)

```

Optimization terminated successfully.
 Current function value: 0.348731
 Iterations 7


Matrice de confusion (seuil = 0.3) :
 [[1567 301]
 [126 214]]

AUC : 0.814

Classification report :

	precision	recall	f1-score	support
0	0.926	0.839	0.880	1868
1	0.416	0.629	0.501	340
accuracy			0.807	2208
macro avg	0.671	0.734	0.690	2208
weighted avg	0.847	0.807	0.822	2208

AIC du modèle : 6211.90



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.4033	0.033	0.0000
TENSION2_reg	0.6747	1.964	0.0000
INITIAT_reg	0.5096	1.665	0.0000
INT_OBJECTIF_INITIAT	0.3123	1.367	0.0000
ACCHEF_reg	0.2627	1.300	0.0000
RPB5E_b	0.9221	2.515	0.0000
RPB1J_b	0.7210	2.056	0.0000
JOINEXT_reg	0.6299	1.877	0.0000
RP4B_reg	0.3784	1.460	0.0000
RP1_reg	-0.6654	0.514	0.0000
BIENETR1_reg	-0.4275	0.652	0.0000
CVFVP_reg	-0.7178	0.488	0.0000
sexe	0.7850	2.193	0.0000
RPB1E_b	0.8477	2.334	0.0000
niv_diplome_reg	0.1467	1.158	0.0002
IDEE_reg	-0.2661	0.766	0.0005
QUANTI_reg	-0.2730	0.761	0.0007
AIDCOLL_reg	-0.2805	0.755	0.0039
INFOCONF_reg	-0.1175	0.889	0.0045
revmensc_tranche_> 3000	-0.4160	0.660	0.0086
PREVIS	0.1109	1.117	0.0272
TYPEMPLOI	0.2306	1.259	0.0649
INT_RPB5E_TENSION2	-0.3448	0.708	0.0829
revmensc_tranche_2251-3000	-0.1707	0.843	0.1620
revmensc_tranche_1351-1700	-0.1053	0.900	0.2881
revmensc_tranche_1701-2250	-0.0832	0.920	0.4237
AGE	0.0020	1.002	0.6079

```
In [118]: import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# ----- VARIABLE CIBLE -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# ----- VARIABLE ÂGE QUADRATIQUE -----
data_cl1["AGE2"] = data_cl1["AGE"] ** 2

# ----- VARIABLES EXPLICATIVES -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg",
    "ACCHEF_reg"
]
num_vars = ["AGE", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "revmensc_tranche"]

# ----- DUMMIES & INTERACTIONS -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# Interactions
data_cl1["INT_OBJECTIF_INITIAT"] = data_cl1["OBJECTIF_reg"] * data_cl1["INITIAT_reg"]
X_inter = data_cl1[["INT_OBJECTIF_INITIAT"]].astype(float)

# ----- CONSTRUCTION DE X & y -----
X = pd.concat([X_bin, X_num, X_cat, X_inter], axis=1)
y = data_cl1["burnout_bin_q3"]
df_logit = pd.concat([X, y], axis=1).dropna()
X = df_logit.drop(columns="burnout_bin_q3")
y = df_logit["burnout_bin_q3"]

# ----- TRAIN/TEST -----
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, stratify=y, random_state=42)

# ----- ESTIMATION LOGIT -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# ----- ÉVALUATION -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.20).astype(int)

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
```

```

print(f"\nAIC du modèle : {result.aic:.2f}")

# ----- COURBE ROC -----
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Logit avec âge² et interactions")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# ----- COEFFICIENTS ET ODDS RATIOS -----
odds_ratios = np.exp(result.params)
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)

```

Optimization terminated successfully.
Current function value: 0.348900
Iterations 7


Matrice de confusion (seuil = 0.3) :
[[1576 292]
[126 214]]

AUC : 0.814

Classification report :

	precision	recall	f1-score	support
0	0.926	0.844	0.883	1868
1	0.423	0.629	0.506	340
accuracy			0.811	2208
macro avg	0.674	0.737	0.694	2208
weighted avg	0.849	0.811	0.825	2208

AIC du modèle : 6212.88



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.3687	0.034	0.0000
TENSION2_reg	0.6319	1.881	0.0000
INITIAT_reg	0.5121	1.669	0.0000
JOINEXT_reg	0.6286	1.875	0.0000
RPB5E_b	0.7328	2.081	0.0000
RPB1J_b	0.7206	2.056	0.0000
ACCHEF_reg	0.2619	1.299	0.0000
RP4B_reg	0.3798	1.462	0.0000
sexe	0.7848	2.192	0.0000
RPB1E_b	0.8432	2.324	0.0000
CVFVP_reg	-0.7198	0.487	0.0000
RP1_reg	-0.6660	0.514	0.0000
BIENETR1_reg	-0.4299	0.651	0.0000
INT_OBJECTIF_INITIAT	0.3146	1.370	0.0000
niv_diplome_reg	0.1484	1.160	0.0002
IDEE_reg	-0.2672	0.766	0.0004
QUANTI_reg	-0.2745	0.760	0.0006
AIDCOLL_reg	-0.2803	0.756	0.0040
INFOCONF_reg	-0.1177	0.889	0.0045
revmensc_tranche_> 3000	-0.4194	0.657	0.0081
PREVIS	0.1115	1.118	0.0265
TYPEMPLOI	0.2261	1.254	0.0702
revmensc_tranche_2251-3000	-0.1733	0.841	0.1559
revmensc_tranche_1351-1700	-0.0993	0.905	0.3161
revmensc_tranche_1701-2250	-0.0826	0.921	0.4270
AGE	0.0022	1.002	0.5669

```
In [119]: import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt

# ----- VARIABLE CIBLE -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# ----- VARIABLE ÂGE QUADRATIQUE -----
data_cl1["AGE2"] = data_cl1["AGE"] ** 2

# ----- VARIABLES EXPLICATIVES -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg",
    "ACCHEF_reg"
]
num_vars = ["AGE", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "TENSION2_reg"]
cat_vars = ["revmensc_tranche"]

# ----- DUMMIES & INTERACTIONS -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# Interactions
data_cl1["INT_OBJECTIF_INITIAT"] = data_cl1["OBJECTIF_reg"] * data_cl1["INITIAT_reg"]
X_inter = data_cl1[["INT_OBJECTIF_INITIAT"]].astype(float)

# ----- CONSTRUCTION DE X & y -----
X = pd.concat([X_bin, X_num, X_cat, X_inter], axis=1)
y = data_cl1["burnout_bin_q3"]
df_logit = pd.concat([X, y], axis=1).dropna()
X = df_logit.drop(columns="burnout_bin_q3")
y = df_logit["burnout_bin_q3"]

# ----- TRAIN/TEST -----
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, stratify=y, random_state=42)

# ----- ESTIMATION LOGIT -----
X_train_sm = sm.add_constant(X_train)
logit_model = sm.Logit(y_train, X_train_sm)
result = logit_model.fit()

# ----- ÉVALUATION -----
X_test_sm = sm.add_constant(X_test)
y_proba = result.predict(X_test_sm)
y_pred = (y_proba >= 0.20).astype(int)

print("\nMatrice de confusion (seuil = 0.3) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result.aic:.2f}")
```

```
# ----- COURBE ROC -----
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Logit avec âge² et interactions")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
# ----- COEFFICIENTS ET ODDS RATIOS -----
odds_ratios = np.exp(result.params)
summary_df = pd.DataFrame({
    "coeff": result.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df)
```

Optimization terminated successfully.
 Current function value: 0.349111
 Iterations 7

Matrice de confusion (seuil = 0.3) :


[[1569	299]
[127	213]]

AUC : 0.814

Classification report :

	precision	recall	f1-score	support
0	0.925	0.840	0.880	1868
1	0.416	0.626	0.500	340
accuracy			0.807	2208
macro avg	0.671	0.733	0.690	2208
weighted avg	0.847	0.807	0.822	2208

AIC du modèle : 6214.60



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-2.0579	0.128	0.0000
TENSION2_reg	0.6354	1.888	0.0000
INITIAT_reg	0.5147	1.673	0.0000
JOINEXT_reg	0.6261	1.870	0.0000
RPB5E_b	0.7353	2.086	0.0000
RPB1J_b	0.7145	2.043	0.0000
ACCHEF_reg	0.2664	1.305	0.0000
RP4B_reg	0.3789	1.461	0.0000
sexe	0.7895	2.202	0.0000
CVFVP_reg	-0.7183	0.488	0.0000
RPB1E_b	0.8365	2.308	0.0000
INT_OBJECTIF_INITIAT	0.3173	1.373	0.0000
BIENETR1_reg	-0.4316	0.649	0.0000
RP1_reg	-0.6656	0.514	0.0000
niv_diplome_reg	0.1470	1.158	0.0002
IDEE_reg	-0.2678	0.765	0.0004
QUANTI_reg	-0.2746	0.760	0.0006
AIDCOLL_reg	-0.2820	0.754	0.0038
INFOCONF_reg	-0.1179	0.889	0.0044
revmensc_tranche_> 3000	-0.3971	0.672	0.0119
PREVIS	0.1064	1.112	0.0341
revmensc_tranche_2251-3000	-0.1513	0.860	0.2131
revmensc_tranche_1351-1700	-0.0834	0.920	0.3982
AGE	0.0027	1.003	0.4910
revmensc_tranche_1701-2250	-0.0637	0.938	0.5378

```
In [120] from sklearn.metrics import f1_score


thresholds = np.arange(0.1, 0.6, 0.01)
f1_scores = [f1_score(y_test, (y_proba >= t).astype(int)) for t in thresholds]

best_threshold = thresholds[np.argmax(f1_scores)]
best_f1 = max(f1_scores)

print(f"Meilleur seuil : {best_threshold:.2f} | F1-score max : {best_f1:.3f}")
```

Meilleur seuil : 0.25 | F1-score max : 0.511

```
In [121] plt.figure(figsize=(8,5))
plt.plot(thresholds, f1_scores, marker='o')
plt.axvline(best_threshold, color='red', linestyle='--', label=f'Seuil optimal = {best_threshold:.2f}')
plt.title("F1-score en fonction du seuil de classification")
plt.xlabel("Seuil")
plt.ylabel("F1-score")
plt.grid(True)
plt.legend()
plt.tight_layout()
plt.show()
```



```
In [122] from sklearn.linear_model import LogisticRegression
from sklearn.metrics import classification_report, f1_score

# Réentraîner le modèle avec pondération automatique des classes
```

```
logreg_bal = LogisticRegression(class_weight='balanced', solver='liblinear', max_iter=1000)
logreg_bal.fit(X_train, y_train)

# Probabilités et prédictions
y_proba_bal = logreg_bal.predict_proba(X_test)[: , 1]

# Réoptimisation du seuil pour ce modèle
f1_scores_bal = [f1_score(y_test, (y_proba_bal >= t).astype(int)) for t in thresholds]
best_thresh_bal = thresholds[np.argmax(f1_scores_bal)]
best_f1_bal = max(f1_scores_bal)

print(f"Meilleur seuil (class_weight='balanced') : {best_thresh_bal:.2f} | F1-score max : {best_f1_bal:.3f}")
```

Meilleur seuil (class_weight='balanced') : 0.57 | F1-score max : 0.494

Évaluation du modèle logit enrichi (interaction)

Le modèle logit enrichi a été estimé pour prédire la probabilité d'un niveau élevé de burn-out (dernier quartile du score). Il intègre des variables sociodémographiques, relationnelles, professionnelles, et psychologiques, ainsi que des termes d'interaction.

Performances globales

- **Précision (classe 1)** : 0.423
→ Parmi les observations prédites comme burn-out, 42.3 % sont correctes.
- **Rappel (classe 1)** : 0.629
→ Le modèle détecte 62.9 % des vrais cas de burn-out.
- **F1-score (classe 1)** : 0.506
→ Moyenne harmonique entre précision et rappel. Compromis équilibré pour une classe minoritaire.

Autres moyennes :

- **Accuracy** (toutes classes) : **0.811**
- **Macro F1-score** (moyenne non pondérée) : **0.694**
- **Weighted F1-score** (pondérée par effectif) : **0.825**

Ces résultats montrent que le modèle parvient à détecter correctement une bonne partie des individus en situation de burn-out, au prix de quelques faux positifs (précision plus faible).

Matrice de confusion (seuil = 0.20)

	Prédit : 0	Prédit : 1
Observé : 0	1576	292
Observé : 1	126	214

- **Classe minoritaire (burn-out)** bien détectée (rappel = 0.629)
- Mais **292 faux positifs**, expliquant la précision plus faible (0.423)

Interprétation des coefficients et odds ratios

Variable	Coef.	OR	p-value	Interprétation
TENSION2_reg	+0.63	1.88	0.0000	Tensions avec la hiérarchie = risque ×1.88
INITIAT_reg	+0.51	1.67	0.0000	Manque d'initiative autonome = facteur de risque
JOINEXT_reg	+0.63	1.88	0.0000	Difficultés à joindre l'encadrement extérieur
RPB5E_b	+0.73	2.08	0.0000	Fatigue émotionnelle fréquente = facteur majeur
RPB1J_b	+0.72	2.06	0.0000	Se sentir vidé du travail → x2 le risque
ACCHEF_reg	+0.26	1.30	0.0000	Absence de soutien du supérieur immédiat
RP4B_reg	+0.38	1.46	0.0000	Conflits avec collègues ou supérieurs
sexe (Femme)	+0.78	2.19	0.0000	Les femmes ont un risque ×2.19
RPB1E_b	+0.84	2.32	0.0000	Épuisement très fréquent → facteur le plus fort
CVFVP_reg	-0.72	0.49	0.0000	Encadrants = moins de risque
RP1_reg	-0.67	0.51	0.0000	Forte efficacité personnelle = protecteur
BIENETR1_reg	-0.43	0.65	0.0000	Bien-être au travail diminue le risque
INT_OBJECTIF_INITIAT	+0.31	1.37	0.0000	Objectifs flous + faible autonomie = facteur aggravant
niv_diplome_reg	+0.15	1.16	0.0002	Risque légèrement croissant avec le niveau
IDEE_reg	-0.27	0.77	0.0004	Liberté d'expression = facteur protecteur
QUANTI_reg	-0.27	0.76	0.0006	Gestion acceptable de la charge de travail

AIDCOLL_reg	-0.28	0.76	0.0040	Aide des collègues protège du burn-out
INFOCONF_reg	-0.12	0.89	0.0045	Accès à l'information claire réduit le stress
revmensc <tranche>3000< td=""><td>-0.42</td><td>0.66</td><td>0.0081</td><td>Revenu élevé = facteur protecteur</td></tranche>3000<>	-0.42	0.66	0.0081	Revenu élevé = facteur protecteur
PREVIS	+0.11	1.12	0.0265	Manque de prévisibilité = stress latent
TYPEEMPLOI	+0.23	1.25	0.0702	Précarité de l'emploi, effet modéré
revmensc_tranche_2251-3000	-0.17	0.84	0.1559	Pas significatif
revmensc_tranche_1351-1700	-0.10	0.91	0.3161	Pas significatif
revmensc_tranche_1701-2250	-0.08	0.92	0.4270	Pas significatif
AGE	+0.002	1.002	0.5669	Non significatif (effet via AGE² intégré ailleurs)

Conclusion

Le modèle enrichi est robuste et bien calibré. Il met en évidence des facteurs de risque psychologiques (épuisement, conflits), organisationnels (soutien, charge, autonomie), et socio-économiques (sexe, revenus). Il constitue un outil efficace de **détection préventive du burn-out**, tout en restant **interprétable** pour les professionnels du domaine.

```
In [123] import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt
import pickle

# ----- VARIABLE CIBLE -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# ----- VARIABLE ÂGE QUADRATIQUE -----
data_cl1["AGE2"] = data_cl1["AGE"] ** 2

# ----- VARIABLES EXPLICATIVES -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg", "ACCHEF_reg"
]
num_vars = ["AGE", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "TENSION2_reg"]
cat_vars = ["TYPEEMPLOI", "revmensc_tranche"]

# ----- DUMMIES & INTERACTIONS -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# ----- CONSTRUCTION DE X & y -----
X_logit1 = pd.concat([X_bin, X_num, X_cat, X_inter], axis=1)
y_logit1 = data_cl1["burnout_bin_q3"]
df_logit1 = pd.concat([X_logit1, y_logit1], axis=1).dropna()
X_logit1 = df_logit1.drop(columns="burnout_bin_q3")
y_logit1 = df_logit1["burnout_bin_q3"]

# ----- TRAIN/TEST -----
X_train, X_test, y_train, y_test = train_test_split(
    X_logit1, y_logit1, test_size=0.2, stratify=y_logit1, random_state=42
)

# ----- ESTIMATION LOGIT -----
X_train_sm = sm.add_constant(X_train)
logit1 = sm.Logit(y_train, X_train_sm)
result_logit1 = logit1.fit()

# ----- ÉVALUATION -----
X_test_sm = sm.add_constant(X_test)
y_proba = result_logit1.predict(X_test_sm)
y_pred = (y_proba >= 0.20).astype(int)

print("\nMatrice de confusion (seuil = 0.20) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result_logit1.aic:.2f}")

# ----- COURBE ROC -----
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
```

```
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Modèle logit1 (interaction)")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
# ----- COEFFICIENTS ET ODDS RATIOS -----
odds_ratios = np.exp(result_logit1.params)
summary_df_logit1 = pd.DataFrame({
    "coeff": result_logit1.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result_logit1.pvalues.round(4)
}).sort_values("p_value")
```

```
print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df_logit1)
```

```
# ----- SAUVEGARDE DU MODÈLE -----
with open("logit1.pkl", "wb") as f:
    pickle.dump(result_logit1, f)
```

Optimization terminated successfully.
Current function value: 0.348900
Iterations 7

Matrice de confusion (seuil = 0.20) :


```
[[1576 292]
 [ 126 214]]
```

AUC : 0.814

Classification report :

	precision	recall	f1-score	support
0	0.926	0.844	0.883	1868
1	0.423	0.629	0.506	340
accuracy			0.811	2208
macro avg	0.674	0.737	0.694	2208
weighted avg	0.849	0.811	0.825	2208

AIC du modèle : 6212.88



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.3687	0.034	0.0000
TENSION2_reg	0.6319	1.881	0.0000
INITIAT_reg	0.5121	1.669	0.0000
JOINEXT_reg	0.6286	1.875	0.0000
RPB5E_b	0.7328	2.081	0.0000
RPB1J_b	0.7206	2.056	0.0000
ACCHEF_reg	0.2619	1.299	0.0000
RP4B_reg	0.3798	1.462	0.0000
sexe	0.7848	2.192	0.0000
RPB1E_b	0.8432	2.324	0.0000
CVFVP_reg	-0.7198	0.487	0.0000
RP1_reg	-0.6660	0.514	0.0000
BIENETR1_reg	-0.4299	0.651	0.0000
INT_OBJECTIF_INITIAT	0.3146	1.370	0.0000
niv_diplome_reg	0.1484	1.160	0.0002
IDEE_reg	-0.2672	0.766	0.0004
QUANTI_reg	-0.2745	0.760	0.0006
AIDCOLL_reg	-0.2803	0.756	0.0040
INFOCONF_reg	-0.1177	0.889	0.0045
revmensc_tranche_> 3000	-0.4194	0.657	0.0081
PREVIS	0.1115	1.118	0.0265
TYPEMPLOI	0.2261	1.254	0.0702
revmensc_tranche_2251-3000	-0.1733	0.841	0.1559
revmensc_tranche_1351-1700	-0.0993	0.905	0.3161
revmensc_tranche_1701-2250	-0.0826	0.921	0.4270
AGE	0.0022	1.002	0.5669

```
In [124]: import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt
import pickle

# ----- VARIABLE CIBLE -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# ----- ÂGE QUADRATIQUE -----
data_cl1["AGE2"] = data_cl1["AGE"] ** 2

# ----- VARIABLES EXPLICATIVES -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg", "ACCHEF_reg"
]
num_vars = ["AGE", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "revmensc_tranche"]

# ----- CONSTRUCTION DE X_logit2 & y_logit2 -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

X_logit2 = pd.concat([X_bin, X_num, X_cat], axis=1) # pas d'interaction ici
y_logit2 = data_cl1["burnout_bin_q3"]
df_logit2 = pd.concat([X_logit2, y_logit2], axis=1).dropna()
X_logit2 = df_logit2.drop(columns="burnout_bin_q3")
y_logit2 = df_logit2["burnout_bin_q3"]

# ----- TRAIN / TEST SPLIT -----
X_train, X_test, y_train, y_test = train_test_split(
    X_logit2, y_logit2, test_size=0.2, stratify=y_logit2, random_state=42
)

# ----- ESTIMATION LOGIT 2 -----
X_train_sm = sm.add_constant(X_train)
logit2 = sm.Logit(y_train, X_train_sm)
result_logit2 = logit2.fit()

# ----- ÉVALUATION -----
X_test_sm = sm.add_constant(X_test)
y_proba = result_logit2.predict(X_test_sm)
y_pred = (y_proba >= 0.20).astype(int)

print("\nMatrice de confusion (seuil = 0.20) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result_logit2.aic:.2f}")

# ----- COURBE ROC -----
fpr, tpr, _ = roc_curve(y_test, y_proba)
```

```
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Modèle logit2")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()
```

```
# ----- COEFFICIENTS & ODDS RATIOS -----
odds_ratios = np.exp(result_logit2.params)
summary_df_logit2 = pd.DataFrame({
    "coeff": result_logit2.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result_logit2.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df_logit2)

# ----- SAUVEGARDE DU MODÈLE -----
with open("logit2.pkl", "wb") as f:
    pickle.dump(result_logit2, f)
```

Optimization terminated successfully.
Current function value: 0.349836
Iterations 7


Matrice de confusion (seuil = 0.20) :
[[1573 295]
[124 216]]

AUC : 0.813

Classification report :

	precision	recall	f1-score	support
0	0.927	0.842	0.882	1868
1	0.423	0.635	0.508	340
accuracy			0.810	2208
macro avg	0.675	0.739	0.695	2208
weighted avg	0.849	0.810	0.825	2208

AIC du modèle : 6227.40



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.3878	0.034	0.0000
TENSION2_reg	0.6373	1.891	0.0000
INITIAT_reg	0.6063	1.834	0.0000
JOINEXT_reg	0.6481	1.912	0.0000
RPB5E_b	0.7426	2.101	0.0000
RPB1J_b	0.7328	2.081	0.0000
ACCHEF_reg	0.2735	1.315	0.0000
RP4B_reg	0.3799	1.462	0.0000
RP1_reg	-0.6751	0.509	0.0000
BIENETR1_reg	-0.4227	0.655	0.0000
sexe	0.7691	2.158	0.0000
RPB1E_b	0.8347	2.304	0.0000
CVFVP_reg	-0.7259	0.484	0.0000
niv_diplome_reg	0.1455	1.157	0.0002
IDEE_reg	-0.2795	0.756	0.0002
QUANTI_reg	-0.2680	0.765	0.0008
AIDCOLL_reg	-0.2850	0.752	0.0034
INFOCONF_reg	-0.1206	0.886	0.0036
PREVIS	0.1186	1.126	0.0181
revmensc_tranche_> 3000	-0.3478	0.706	0.0267
TYPEMPL0I	0.2344	1.264	0.0613
revmensc_tranche_2251-3000	-0.1415	0.868	0.2448
revmensc_tranche_1351-1700	-0.0983	0.906	0.3207
revmensc_tranche_1701-2250	-0.0658	0.936	0.5263
AGE	0.0016	1.002	0.6893

Tests sur la qualité du modèle :

Test de Hosmer-Lemeshow : évaluation de la qualité de l'ajustement

Le test de Hosmer-Lemeshow permet de vérifier si les probabilités estimées par le modèle logit sont cohérentes avec les proportions observées dans les données. Il s'agit d'un test de qualité d'ajustement pour les modèles de régression logistique.

Hypothèses :

- **H₀** : Le modèle est correctement spécifié (les probabilités prédites sont bien ajustées aux observations).
- **H₁** : Le modèle est mal spécifié (les probabilités prédites s'éloignent significativement des proportions observées).

Méthode :

L'échantillon est divisé en 10 groupes (déciles) selon les quantiles des probabilités prédites. Pour chaque groupe, on compare :

- le nombre d'événements effectivement observés (burn-out),
- au nombre d'événements attendus selon le modèle.

La statistique du test suit une loi du χ^2 avec $g - 2$ degrés de liberté (ici, $10 - 2 = 8$).

Résultats obtenus :

- **Statistique de test** : 6.15
- **p-value** : 0.6310

Interprétation :

Étant donné que la p-value est largement supérieure au seuil usuel de 5 %, on **ne rejette pas l'hypothèse nulle**. Cela signifie que le modèle logit enrichi fournit un **ajustement satisfaisant** aux données : les probabilités estimées de burn-out sont en accord avec les proportions réellement observées dans les différents groupes de risque.

Le test de Hosmer-Lemeshow confirme la **validité globale** du modèle logistique estimé.

```
In [125]: from scipy.stats import chi2

def hosmer_lemeshow_test(y_true, y_pred, g=10):
    df = pd.DataFrame({'y_true': y_true, 'y_prob': y_pred})
    df['bin'] = pd.qcut(df['y_prob'], g, duplicates='drop') # Regroupement en quantiles
    obs = df.groupby('bin')['y_true'].sum()                 # Effectifs observés
    exp = df.groupby('bin')['y_prob'].sum()                 # Effectifs attendus
    n = df.groupby('bin')['y_true'].count()                 # Taille de chaque groupe

    hl_stat = (((obs - exp) ** 2) / (exp * (1 - exp / n))).sum() # Statistique HL
    p_value = 1 - chi2.cdf(hl_stat, g - 2)                  # p-value (ddl = g-2)

    return hl_stat, p_value
```

```
hl_stat, hl_p = hosmer_lemeshow_test(y_test, y_proba)
print(f"Hosmer-Lemeshow : Stat = {hl_stat:.2f}, p-value = {hl_p:.4f}")
```

Hosmer-Lemeshow : Stat = 9.11, p-value = 0.3335

```
/var/folders/ny/hmwn2lfx3sv6m4gglsj8qjk40000gn/T/ipykernel_15418/564376689.py:6: FutureWarning: The default of
observed=False is deprecated and will be changed to True in a future version of pandas. Pass observed=False to
retain current behavior or observed=True to adopt the future default and silence this warning.
    obs = df.groupby('bin')['y_true'].sum() # Effectifs observés
/var/folders/ny/hmwn2lfx3sv6m4gglsj8qjk40000gn/T/ipykernel_15418/564376689.py:7: FutureWarning: The default of
observed=False is deprecated and will be changed to True in a future version of pandas. Pass observed=False to
retain current behavior or observed=True to adopt the future default and silence this warning.
    exp = df.groupby('bin')['y_prob'].sum() # Effectifs attendus
/var/folders/ny/hmwn2lfx3sv6m4gglsj8qjk40000gn/T/ipykernel_15418/564376689.py:8: FutureWarning: The default of
observed=False is deprecated and will be changed to True in a future version of pandas. Pass observed=False to
retain current behavior or observed=True to adopt the future default and silence this warning.
    n = df.groupby('bin')['y_true'].count() # Taille de chaque groupe
```

Test de log-vraisemblance et pseudo R² de McFadden

Le test de log-vraisemblance évalue si le modèle logit enrichi explique significativement mieux la variable dépendante que le modèle nul (modèle avec constante uniquement).

Hypothèses :

- **H₀** : Le modèle enrichi n'apporte pas d'amélioration significative par rapport au modèle nul.
- **H₁** : Le modèle enrichi améliore significativement l'ajustement.

Résultats :

- **Statistique LR** : 1429.28
- **p-value** : < 0.0001
- **Pseudo R² de McFadden** : 0.1883

Interprétation :

- Étant donné que la p-value est inférieure à 1 %, on **rejette H₀**. Le modèle enrichi apporte donc **une amélioration significative** par rapport au modèle sans variables explicatives.
- Le **pseudo R² de McFadden** est une mesure de qualité d'ajustement : bien que ses valeurs soient généralement plus faibles que celles du R² classique, une valeur autour de **0.2** est souvent considérée comme correcte en régression logistique. Ici, **0.1883** indique que le modèle a une **capacité explicative correcte**, surtout compte tenu de la complexité du phénomène (burn-out).

Le modèle enrichi améliore significativement l'ajustement par rapport au modèle nul et explique une part non négligeable de la variabilité du burn-out.

```
In [126]: ll_null = sm.Logit(y_train, np.ones((X_train.shape[0], 1))).fit(dis=0).llf
ll_model = result_logit1.llf
lr_stat = -2 * (ll_null - ll_model)
df_diff = X_train.shape[1]
p_lr = chi2.sf(lr_stat, df_diff)
pseudo_r2 = 1 - (ll_model / ll_null)

print(f"Test de log-vraisemblance : Stat = {lr_stat:.2f}, p-value = {p_lr:.4f}")
print(f"Pseudo R² de McFadden : {pseudo_r2:.4f}")
```

Test de log-vraisemblance : Stat = 1429.28, p-value = 0.0000
Pseudo R² de McFadden : 0.1883

Courbe de calibration – Modèle logit enrichi

La courbe de calibration permet de comparer les **probabilités prédites** par le modèle aux **probabilités observées** dans les données, en les regroupant en classes (ici, 10 bins).

Objectif :

- Vérifier si le modèle est bien **calibré**, c'est-à-dire si les probabilités qu'il prédit sont cohérentes avec les fréquences observées des événements.

Lecture du graphique :

- La ligne **noire en pointillés** représente une calibration parfaite : les prédictions du modèle sont parfaitement alignées avec les observations.
- Les **points bleus** représentent la probabilité moyenne prédite pour chaque bin, comparée à la fréquence réelle de burn-out dans ce groupe.

Interprétation :

- La courbe de calibration du modèle logit enrichi **s'aligne globalement bien** avec la diagonale, ce qui montre que


les probabilités produites sont **raisonnablement fiables**.

- On note toutefois quelques **légers écarts** pour certaines classes (entre 0.6 et 0.9 notamment), ce qui peut indiquer un **sur-ajustement local** ou un petit défaut de calibration dans ces zones.

Le modèle est globalement bien calibré, ce qui renforce la **confiance dans les probabilités prédites** pour guider des décisions (prévention du burn-out par exemple).

```
In [127]: from sklearn.calibration import calibration_curve

prob_true, prob_pred = calibration_curve(y_test, y_proba, n_bins=10)
plt.plot(prob_pred, prob_true, marker='o', label='Calibration')
plt.plot([0, 1], [0, 1], 'k--', label='Parfait')
plt.xlabel('Probabilité prédite')
plt.ylabel('Probabilité observée')
plt.title('Courbe de calibration - Modèle logit enrichi')
plt.legend()
plt.grid()
plt.show()
```



Analyse de la colinéarité — Facteurs d'inflation de la variance (VIF)

Objectif Le VIF (Variance Inflation Factor) mesure dans quelle mesure une variable explicative est corrélée linéairement avec les autres variables du modèle. Une colinéarité élevée peut biaiser les coefficients estimés, les rendant instables et difficilement interprétables.

Seuils d'interprétation du VIF

- **VIF = 1** : Aucune multicolinéarité détectée.
- **$1 < \text{VIF} \leq 5$** : Multicolinéarité modérée, acceptable dans la plupart des cas.
- **$5 < \text{VIF} \leq 10$** : Multicolinéarité élevée, à surveiller.
- **VIF > 10** : Multicolinéarité très forte, souvent problématique.

Résultats du modèle logit enrichi Tous les VIF calculés sont **inférieurs à 2**, ce qui indique une **colinéarité faible** entre les variables explicatives. Voici quelques exemples :

- `revmesc_tranche_2251-3000` : VIF = 1.98
- `niv_diplome_reg` : VIF = 1.48
- `INITIAT_reg` : VIF = 1.41
- `RP1_reg` : VIF = 1.02

La constante (`const`) affiche un VIF anormalement élevé (~322), ce qui est attendu car elle est constante et donc parfaitement colinéaire par construction. Ce n'est **pas un problème** pour l'interprétation du reste du modèle.

Conclusion Aucune variable ne dépasse le seuil de vigilance de 5. Le modèle ne présente **aucune multicolinéarité problématique**, ce qui renforce la fiabilité des estimations des coefficients.

```
In [128]: from statsmodels.stats.outliers_influence import variance_inflation_factor

X_vif = sm.add_constant(X_logit1)
vif_df = pd.DataFrame({
```

```
'Variable': X_vif.columns,
'VIF': [variance_inflation_factor(X_vif.values, i) for i in range(X_vif.shape[1])]
})
print(vif_df.sort_values('VIF', ascending=False))
```

	Variable	VIF
0	const	322.639679
23	revmensc_tranche_2251-3000	1.984741
22	revmensc_tranche_1701-2250	1.972810
24	revmensc_tranche > 3000	1.813640
21	revmensc_tranche_1351-1700	1.792190
14	niv_diplome_reg	1.475369
16	INITIAT_reg	1.408411
17	IDEE_reg	1.367877
19	TENSION2_reg	1.315556
12	ACCHEF_reg	1.312423
11	INFOCONF_reg	1.301193
3	BIENETR1_reg	1.240664
13	AGE	1.203650
1	sexe	1.200024
6	RPB1E_b	1.135209
25	INT_OBJECTIF_INITIAT	1.133100
10	JOINEXT_reg	1.125449
7	RPB1J_b	1.099926
8	RPB5E_b	1.091442
2	CVFVP_reg	1.081921
18	QUANTI_reg	1.063469
15	PREVIS	1.056798
20	TYPEEMPLOI	1.039334
5	RP4B_reg	1.028401
9	AIDCOLL_reg	1.026564
4	RP1_reg	1.022524

Analyse de performance du modèle logit enrichi

Métriques utilisées

- **F1-score** : mesure la moyenne harmonique entre la précision et le rappel. Utile pour évaluer la performance globale sur une classe minoritaire.
- **Précision (Precision)** : parmi les observations prédites comme positives, combien sont réellement positives.
- **Rappel (Recall)** : parmi les observations réellement positives, combien ont été correctement prédites.
- **AUC (Area Under the Curve)** : mesure la capacité du modèle à distinguer entre les classes (valeurs proches de 1 = très bon modèle).

Résultats

- **F1-score** : 0.506
- **Précision** : 0.423
- **Rappel** : 0.629
- **AUC** : 0.814

Interprétation

- Le **F1-score de 0.506** montre un équilibre modéré entre précision et rappel, ce qui est acceptable compte tenu du déséquilibre de classes (burn-out = minoritaire).
- La **précision de 0.423** signifie que parmi toutes les observations prédites comme "burn-out", seulement 42,3 % étaient réellement positives.
- Le **rappel de 0.629** est relativement bon : le modèle détecte environ 63 % des cas réels de burn-out.
- Un **AUC de 0.814** indique une très bonne capacité de discrimination globale du modèle entre les deux classes.

Conclusion Ce modèle présente une **bonne performance globale** avec un **compromis raisonnable entre détection et précision**, ce qui en fait un outil fiable pour estimer le risque de burn-out dans cette population.

```
In [129.] from sklearn.metrics import f1_score, precision_score, recall_score, roc_auc_score

print(f"F1-score : {f1_score(y_test, y_pred):.3f}")
print(f"Précision : {precision_score(y_test, y_pred):.3f}")
print(f"Rappel : {recall_score(y_test, y_pred):.3f}")
print(f"AUC : {roc_auc_score(y_test, y_proba):.3f}")
```

```
F1-score : 0.508
Précision : 0.423
Rappel : 0.635
AUC : 0.813
```

Analyse des résidus de Pearson

Objectif Les résidus de Pearson mesurent la différence entre la valeur observée () et la probabilité estimée par le modèle (), pondérée par la variance attendue sous la loi binomiale :

$$D_i = \frac{|y_i - \hat{y}_i|}{\sqrt{\hat{p}_i(1 - \hat{p}_i)}}$$

Interprétation du graphique

L'histogramme présente une forte concentration des résidus autour de 0, ce qui est un bon signe :

- **Symétrie autour de zéro** : indique que le modèle n'a pas de biais systématique dans ses prédictions.
- **Peu de valeurs extrêmes** : la majorité des résidus se trouvent dans une zone raisonnable, bien que quelques outliers positifs soient visibles (> 4 ou 5).
- **Queue droite plus étendue** : cela peut signaler une certaine difficulté du modèle à bien prédire quelques cas positifs rares (ce qui est cohérent avec un déséquilibre de classes).

Conclusion

Le modèle semble globalement bien ajusté, avec une bonne concentration des résidus près de 0. Quelques cas marginaux peuvent mériter une investigation plus fine (éventuels outliers ou cas atypiques), mais **aucune anomalie majeure n'est détectée** dans la distribution globale des résidus.

```
In [130]: import matplotlib.pyplot as plt
import numpy as np

# Prédiction de probabilité sur le TRAIN (comme le modèle a été estimé là-dessus)
y_pred_train = result_logit2.predict(sm.add_constant(X_train))

# Résidus de Pearson : (y - p) / sqrt(p * (1 - p))
resid_pearson = (y_train - y_pred_train) / np.sqrt(y_pred_train * (1 - y_pred_train))

# Histogramme
plt.figure(figsize=(8, 4))
plt.hist(resid_pearson, bins=30, edgecolor='k')
plt.title("Histogramme des résidus de Pearson")
plt.xlabel("Résidus de Pearson")
plt.grid(True)
plt.tight_layout()
plt.show()
```



Analyse des distances de Cook

Objectif La distance de Cook permet de détecter les **observations influentes**, c'est-à-dire celles qui ont un **impact disproportionné** sur l'ajustement global du modèle. On considère qu'une observation est influente si :

$$D_i > \frac{4}{n}$$

Résultat Dans notre cas, avec ($n \approx 9000$), le seuil est :

$$\frac{4}{n} = 0,00045$$

Résultat

- Le graphique montre que **la très grande majorité des observations ont une distance de Cook proche de zéro**.
- Seulement **903 observations** dépassent le seuil de 0.00045, ce qui représente environ **10 %** de l'échantillon.

Conclusion

Le modèle n'est pas particulièrement dominé par quelques points extrêmes, mais il existe un **nombre non négligeable d'observations influentes**. Cela pourrait refléter :

- soit des cas atypiques (groupes minoritaires),
- soit des valeurs extrêmes de certaines variables explicatives.

À surveiller : il serait pertinent de tester la robustesse du modèle après suppression de ces observations influentes pour voir si les coefficients changent sensiblement.

In [131]

```
import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm


# Récupération de l'influence
influence = result_logit1.get_influence()

# Distance de Cook
cooks_d, _ = influence.cooks_distance

# Affichage d'un histogramme
plt.figure(figsize=(8, 4))
plt.hist(cooks_d, bins=50, edgecolor='k')
plt.title("Histogramme des distances de Cook")
plt.xlabel("Distance de Cook")
plt.ylabel("Fréquence")
plt.grid(True)
plt.tight_layout()
plt.show()

# Seuil de détection des points influents : 4/n
n = X_train.shape[0]
seuil = 4 / n
influents = np.where(cooks_d > seuil)[0]

print(f"\nNombre d'observations influentes (Cook's D > 4/n = {seuil:.5f}) : {len(influents)}")
```



Nombre d'observations influentes (Cook's D > $4/n = 0.00045$) : 903

Analyse des distances de Cook — Détection d'observations influentes

La distance de Cook permet d'évaluer **l'influence d'une observation sur l'ensemble du modèle**. Plus la valeur de Cook's D est élevée, plus une observation est susceptible d'avoir un **impact important** sur l'estimation des coefficients.

Seuil utilisé Le seuil couramment utilisé est $\frac{4}{n}$, avec n le nombre total d'observations. Dans notre cas, $n \approx 9000$, donc le seuil est :

$\frac{4}{9000} \approx 0,00045$

Les observations ayant une distance de Cook **supérieure à ce seuil** sont considérées comme **potentiellement influentes**.

Résultats observés Le graphique ci-dessus montre les distances de Cook pour chaque observation :

- Une majorité d'observations ont une influence négligeable (Cook's D très faible).
- Environ **903 observations** dépassent le seuil critique de 0.00045.
- Quelques pics isolés indiquent des cas très influents à surveiller.

Interprétation

Le modèle semble globalement stable, mais la présence de **plusieurs observations influentes** suggère

qu'il serait pertinent :


- d'inspecter ces cas extrêmes individuellement,
- de tester la robustesse du modèle avec et sans ces observations,
- ou d'appliquer des techniques de pondération robuste si nécessaire.

Conclusion :

La distance de Cook a permis d'identifier des observations dont l'impact sur les coefficients mérite une attention particulière. Cela renforce l'importance de combiner cette analyse avec les résidus et les diagnostics globaux.

In [132]

```
# ——— Graphique de la distance de Cook par observation ———
plt.figure(figsize=(10, 4))
plt.stem(np.arange(len(cooks_d)), cooks_d, markerfmt=" ", basefmt=" ")
plt.axhline(y=seuil, color='r', linestyle='--', label=f'Seuil = 4/n = {seuil:.5f}')
plt.title("Distances de Cook par observation")
plt.xlabel("Index de l'observation")
plt.ylabel("Distance de Cook")
plt.legend()
plt.tight_layout()
plt.show()
```



Autre :

Statistiques descriptives des variables explicatives

Le tableau ci-dessous présente la moyenne et l'écart-type de chaque variable incluse dans le modèle logit enrichi.

Variable	Moyenne	Écart-type	Interprétation rapide
AGE	45.058	9.345	Âge moyen d'environ 45 ans.
sexe	0.570	0.495	57 % des répondants sont des femmes (1 = femme).
niv_diplome_reg	1.641	1.017	Niveau d'études moyen modérément élevé.
TYPEEMPLOI	5.933	0.379	Majorité en emploi standard (modalité de référence exclue).
revmensc	1975.20	875.17	Revenu mensuel moyen ≈ 1975 €, avec forte dispersion.
CVFVP_reg	0.832	0.374	83 % signalent un conflit travail-vie perso.
PREVIS	1.212	0.614	Score moyen de prévisibilité du travail.
INITIAT_reg	0.809	0.393	Bon niveau d'initiative perçue au travail.
IDEE_reg	0.642	0.480	Légère majorité trouvent que leurs idées sont entendues.
QUANTI_reg	0.282	0.450	Faible proportion signalant une surcharge quantitative.
RP1_reg	0.936	0.245	Soutien du supérieur perçu très positivement.
RP4B_reg	0.416	0.493	42 % rapportent des tensions avec le supérieur.
RPB1E_b	0.057	0.232	Symptôme rare d'épuisement émotionnel.
RPB1J_b	0.057	0.232	Sentiment d'inutilité peu fréquent.
RPB5E_b	0.075	0.263	Sensation d'effondrement présente chez 7,5 %.
AIDCOLL_reg	0.891	0.312	Aide perçue des collègues très répandue.
JOINEXT_reg	0.195	0.397	20 % sont joignables en dehors des horaires.
INFOCONF_reg	2.209	0.848	Niveau d'information moyen entre « assez » et « bien ».
ACCHEF_reg	0.928	0.723	Accès au supérieur jugé très bon.

BIENETR1_reg	0.621	0.485	Bien-être global positif mais non majoritaire.
TENSION2_reg	0.309	0.462	31 % signalent des tensions dans leur environnement.

Remarques :

- Les variables binaires sont bien codées entre 0 et 1.
- Les scores moyens permettent de vérifier la cohérence du codage.
- L'analyse de la variabilité (écarts-types) aide à identifier les variables avec une grande dispersion (ex. : revenu, info, tensions).

Ce tableau permet une **vue d'ensemble claire** des caractéristiques des individus inclus dans le modèle, utile pour l'interprétation des coefficients logit.

In [133..

```
import pandas as pd
from tabulate import tabulate

# ——— Sélection des variables à décrire ———
vars_desc = [
    "AGE", "sexe", "niv_diplome_reg", "YPEMPL0I", "revmensc",
    "CVFVP_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg", "ACCHEF_reg",
    "BIENETR1_reg", "TENSION2_reg"
]

# ——— Calcul des stats descriptives ———
desc_df = data_cll[vars_desc].describe().T[["mean", "std"]].reset_index()
desc_df.columns = ["Variable", "Moyenne", "Écart-type"]

# ——— Export LaTeX (ou affichage tabulé) ———
print(tabulate(desc_df, headers="keys", tablefmt="grid", floatfmt=".3f"))
# ——— Option : Export LaTeX pur ———
latex_table = desc_df.to_latex(index=False, float_format="%.3f",
                               caption="Statistiques descriptives des variables explicatives",
                               label="tab:stats_desc")
with open("tableau_stats_desc.tex", "w") as f:
    f.write(latex_table)
```

	Variable	Moyenne	Écart-type
0	AGE	45.058	9.345
1	sexe	0.570	0.495
2	niv_diplome_reg	1.641	1.017
3	YPEMPL0I	5.933	0.379
4	revmensc	1975.195	875.167
5	CVFVP_reg	0.832	0.374
6	PREVIS	1.212	0.614
7	INITIAT_reg	0.809	0.393
8	IDEE_reg	0.642	0.480
9	QUANTI_reg	0.282	0.450
10	RP1_reg	0.936	0.245
11	RP4B_reg	0.416	0.493
12	RPB1E_b	0.057	0.232
13	RPB1J_b	0.057	0.232
14	RPB5E_b	0.075	0.263
15	AIDCOLL_reg	0.891	0.312
16	JOINEXT_reg	0.195	0.397
17	INFOCONF_reg	2.209	0.848
18	ACCHEF_reg	0.928	0.723
19	BIENETR1_reg	0.621	0.485
20	TENSION2_reg	0.309	0.462

Effets marginaux (dy/dx) – Modèle logit enrichi

Les effets marginaux (dy/dx) mesurent l'effet direct d'une variable explicative sur la probabilité d'appartenir à la classe 1 (burn-out dans le dernier quartile). Ils sont calculés en gardant toutes les autres variables constantes.

Chaque ligne indique :

- dy/dx : variation marginale de la probabilité,
- `std_err` : erreur standard,
- `z` : statistique de test z,
- `P>|z|` : p-value (significativité statistique),
- `IC 95 %` : intervalle de confiance.

Variables significatives ($p < 0.05$)

- **sexe** ($dy/dx = 0.0827$, $p < 0.0001$) : Être une femme augmente la probabilité de burn-out de 8,3 points de pourcentage.
- **CVFVP_reg** ($dy/dx = -0.0758$, $p < 0.0001$) : Être soutenu.e par son supérieur diminue la probabilité de burn-out de 7,6 points.
- **BIENETR1_reg** ($dy/dx = -0.0453$, $p < 0.0001$) : Un bon bien-être perçu réduit la probabilité de 4,5 points.
- **RP1_reg** ($dy/dx = -0.0701$, $p < 0.0001$) : Se sentir écouté.e par le supérieur diminue le risque.
- **RP4B_reg** ($dy/dx = 0.0400$, $p < 0.0001$) : Avoir du mal à joindre son supérieur est associé à un risque plus élevé.
- **RPB1E_b, RPB1J_b, RPB5E_b** : Trois symptômes de burn-out (ex. épuisement/déshumanisation) ont des effets positifs forts (+7 à 8 points).
- **AIDCOLL_reg** ($dy/dx = -0.0295$, $p = 0.004$) : Sentiment d'aide des collègues diminue la proba de burn-out.
- **JOINEXT_reg** ($dy/dx = 0.0662$, $p < 0.0001$) : Difficile de joindre quelqu'un en cas d'urgence augmente le risque.
- **INFOCONF_reg** ($dy/dx = -0.0124$, $p = 0.004$) : Recevoir des consignes claires réduit légèrement le risque.
- **ACCHEF_reg** ($dy/dx = 0.0276$, $p < 0.0001$) : Accord avec le chef augmente légèrement la probabilité.
- **niv_diplome_reg** ($dy/dx = 0.0156$, $p < 0.0001$) : Niveau de diplôme élevé corrélé positivement au risque.
- **PREVIS** ($dy/dx = 0.0117$, $p = 0.026$) : Prédicibilité du travail a un effet léger mais significatif.
- **INITIAT_reg** ($dy/dx = 0.0539$, $p < 0.0001$) : Plus d'initiatives = risque accru (peut indiquer surcharge).
- **IDEE_reg** ($dy/dx = -0.0281$, $p < 0.0001$) : Se sentir utile réduit le risque.
- **QUANTI_reg** ($dy/dx = -0.0289$, $p = 0.001$) : Se sentir dépassé.e par la quantité de travail augmente le risque.
- **TENSION2_reg** ($dy/dx = 0.0665$, $p < 0.0001$) : Tensions hiérarchiques augmentent fortement le risque.
- **revmensctranche> 3000** ($dy/dx = -0.0442$, $p = 0.008$) : Revenu mensuel élevé est protecteur.
- **INT_OBJECTIF_INITIAT** ($dy/dx = 0.0331$, $p < 0.0001$) : Interaction objectif × initiative → effet aggravant.

Variables non significatives ($p \geq 0.05$)

- **AGE** ($p = 0.567$) : Pas d'effet significatif.
- **TYPEEMPLOI** ($p = 0.070$) : Limite de significativité.
- **Autres tranches de revenu** (1351-3000 €) : Non significatives dans ce modèle.

Conclusion

Les résultats mettent en lumière :

- des facteurs professionnels aggravants (tensions, surcharge, manque d'écoute),
- des variables de soutien protectrices (aide, confiance, clarté),
- des effets contrastés du revenu et des initiatives.

Les coefficients dy/dx permettent de prioriser les leviers d'action concrets dans la prévention du burn-out.

```
In [134.. marginal_effects = result_logit1.get_margeff()  
print(marginal_effects.summary())
```

Logit Marginal Effects						
=====						
Dep. Variable:	burnout_bin_q3					
Method:	dydx					
At:	overall					
=====						
	dy/dx	std err	z	P> z	[0.025	0.975]

sexe	0.0827	0.008	10.329	0.000	0.067	0.098
CVFVP_reg	-0.0758	0.008	-9.560	0.000	-0.091	-0.060
BIENETR1_reg	-0.0453	0.008	-6.000	0.000	-0.060	-0.030
RP1_reg	-0.0701	0.012	-5.890	0.000	-0.093	-0.047
RP4B_reg	0.0400	0.007	5.756	0.000	0.026	0.054
RPB1E_b	0.0888	0.012	7.588	0.000	0.066	0.112
RPB1J_b	0.0759	0.012	6.387	0.000	0.053	0.099
RPB5E_b	0.0772	0.011	7.106	0.000	0.056	0.098
AIDCOLL_reg	-0.0295	0.010	-2.882	0.004	-0.050	-0.009
JOINEXT_reg	0.0662	0.009	7.774	0.000	0.050	0.083
INFOCONF_reg	-0.0124	0.004	-2.844	0.004	-0.021	-0.004
ACCHEF_reg	0.0276	0.005	5.301	0.000	0.017	0.038
AGE	0.0002	0.000	0.573	0.567	-0.001	0.001
niv_diplome_reg	0.0156	0.004	3.777	0.000	0.008	0.024
PREVIS	0.0117	0.005	2.220	0.026	0.001	0.022
INITIAT_reg	0.0539	0.011	4.844	0.000	0.032	0.076
IDEE_reg	-0.0281	0.008	-3.524	0.000	-0.044	-0.012
QUANTI_reg	-0.0289	0.008	-3.429	0.001	-0.045	-0.012
TENSION2_reg	0.0665	0.008	8.668	0.000	0.052	0.082
TYPEMPLOI	0.0238	0.013	1.811	0.070	-0.002	0.050
revmensc_tranche_1351-1700	-0.0105	0.010	-1.003	0.316	-0.031	0.010
revmensc_tranche_1701-2250	-0.0087	0.011	-0.794	0.427	-0.030	0.013
revmensc_tranche_2251-3000	-0.0183	0.013	-1.419	0.156	-0.043	0.007
revmensc_tranche_> 3000	-0.0442	0.017	-2.650	0.008	-0.077	-0.012
INT_OBJECTIF_INITIAT	0.0331	0.008	4.103	0.000	0.017	0.049
=====						

Burn-out au travail : évaluez votre risque !

Application d'évaluation du risque de burn-out au travail

Cette application a pour objectif de **fournir une estimation personnalisée du risque de burn-out professionnel** à partir de vos réponses à un ensemble de questions standardisées issues de la littérature scientifique (notamment le **Maslach Burnout Inventory**) et de l'enquête nationale **Conditions de travail et Risques psychosociaux 2016 (CT-RPS)**.

Elle repose sur un **modèle de régression logistique enrichi**, construit à partir d'un échantillon représentatif de plus de 9000 actifs en France. Ce modèle intègre :

- les **scores aux 3 dimensions du burn-out** (épuisement émotionnel, déshumanisation, accomplissement),
- des **variables sociodémographiques** (âge, sexe, diplôme),
- des **conditions et relations de travail** (type d'emploi, soutien perçu, tensions),
- et des **facteurs psychologiques et organisationnels** (pression, autonomie, bien-être).

Ce que vous obtiendrez :

- Un **score de burn-out** basé sur vos réponses ;
- Une **probabilité estimée** d'être en situation de burn-out (dernier quartile) ;
- Des **conseils personnalisés** pour mieux comprendre les facteurs de risque identifiés et agir en prévention.

Attention : cette application est une **aide à la prise de conscience**, mais ne remplace en aucun cas un avis médical ou un accompagnement psychologique. En cas de mal-être, parlez-en à un professionnel de santé ou à un service de prévention.

```
In [135]... import os
os.getcwd()
```

```
Out[135]: '/Users/jadelaurent/Documents/M1/Mémoire/Data.csv/Csv'
```

```
In [136]... %%writefile app.py

import numpy as np
import streamlit as st
import joblib
import pandas as pd
import statsmodels.api as sm
```



```

# --- CONFIGURATION DE LA PAGE ---
st.set_page_config(page_title="Burn-out au travail", page_icon="", layout="centered")

# --- TITRE ---
st.title("Application d'évaluation du risque de burn-out au travail ")

# --- INTRODUCTION ---
st.markdown("""
Bienvenue dans cette application interactive conçue pour évaluer votre risque de burn-out professionnel à p

L'évaluation repose sur un modèle statistique rigoureux construit à partir des réponses de plus de 9000 act
- Les dimensions du burn-out selon le Maslach Burnout Inventory (MBI),
- Des facteurs personnels et professionnels (âge, sexe, diplôme, emploi, etc.),
- Des variables liées au travail (tensions, soutien, autonomie, etc.).

---
### Que fait cette application ?
- Calcule un score de burn-out basé sur vos réponses ;
- Estime la probabilité d'être en situation de burn-out sévère ;
- Fournit des conseils personnalisés en fonction de votre profil.

---
### À lire avant de commencer

Cette application a une visée informative et préventive.
Elle ne remplace pas un diagnostic médical. En cas de mal-être ou de souffrance au travail, consultez un pr
""")

# --- DÉMARRAGE DU QUESTIONNAIRE ---
st.markdown("""
---
### Comment ça marche ?

Nous allons vous poser une série de questions simples sur :

- Votre ressenti au travail (épuisement, motivation, pression...)
- Vos relations professionnelles (soutien, conflits, reconnaissance...)
- Vos conditions de travail (horaires, autonomie, clarté des attentes...)
- Votre situation personnelle (âge, sexe, diplôme, type d'emploi...)

Il vous suffit de répondre le plus honnêtement possible en cochant les réponses qui correspondent à votre v

---
""")

# --- DÉBUT DU FORMULAIRE ---
st.subheader(" Questionnaire")

st.markdown("----")
st.subheader(" Informations personnelles et emploi")
# puis les questions : âge, sexe, diplôme, type d'emploi, revenu

## AGE ##
age = st.slider("Quel est votre âge ?", min_value=18, max_value=64, value=30)

if age < 24:
    st.warning("⚠ Attention : notre modèle a été entraîné uniquement sur des individus âgés de 24 à 64 ans. La

## IDENTITÉ DE GENRE ##
st.markdown("### Identité de genre")

col1, col2, col3 = st.columns(3)
genre_selectionne = None

with col1:
    if st.button("Femme", use_container_width=True):
        genre_selectionne = "Femme"
with col2:
    if st.button("Homme", use_container_width=True):
        genre_selectionne = "Homme"
with col3:
    if st.button("Autre / Ne souhaite pas répondre", use_container_width=True):
        genre_selectionne = "Autre"

# Variable de contrôle
genre_autre = False

if genre_selectionne == "Femme":
    sexe = 1
    show_prediction = True
    st.success(" Réponse enregistrée : Femme")
elif genre_selectionne == "Homme":
    sexe = 0
    show_prediction = True
    st.success(" Réponse enregistrée : Homme")
elif genre_selectionne == "Autre":
    sexe = np.nan
    show_prediction = False

```

```

genre_autre = True # → on active ce drapeau
st.warning("i Votre profil ne peut pas être évalué par le modèle actuel. Vous trouverez néanmoins ci-dessous des conseils personnalisés (sans estimation)")
st.subheader(" Conseils personnalisés (sans estimation)")
st.markdown("""
Bien que nous ne puissions pas vous donner de score personnalisé dans ce cas, voici des conseils utiles si vous êtes en situation de burn-out :

- Écoutez vos signaux d'alerte : troubles du sommeil, fatigue, irritabilité, perte d'envie ou de concentration.
- Parlez-en à un·e professionnel·le de santé si vous avez un doute ou ressentez un mal-être.
- N'attendez pas que la situation s'aggrave : il est possible de prévenir le burn-out par des ajustements.
- Entourez-vous de personnes de confiance, au travail ou en dehors, et ne restez pas seul·e.
- Consultez votre médecin du travail si besoin : il peut vous aider à adapter vos conditions de travail.
""")

st.markdown("----")

##DIPLÔME##
# Question sur le diplôme
diplome = st.selectbox(
    "Quel est votre niveau de diplôme le plus élevé obtenu ?",
    options=[
        "Aucun diplôme ou primaire",
        "CAP / BEP / Bac",
        "Bac +2 (BTS, DUT, etc.)",
        "Bac +3 ou plus (Licence, Master...)"
    ]
)
diplome_dict = {
    "Aucun diplôme ou primaire": 0,
    "CAP / BEP / Bac": 1,
    "Bac +2 (BTS, DUT, etc.)": 2,
    "Bac +3 ou plus (Licence, Master...)": 3
}
niv_diplome_reg = diplome_dict[diplome]

##TYPEEMPLOI##
type_emploi = st.selectbox(
    "Quel est votre type d'emploi actuel ?",
    [
        "1 - Fonctionnaire titulaire",
        "2 - Fonctionnaire non titulaire",
        "3 - Salarié permanent CDI",
        "4 - Salarié temporaire ou CDD",
        "5 - Intérimaire",
        "6 - Indépendant / à son compte",
        "7 - Aide familiale"
    ]
)
TYPEEMPLOI = int(type_emploi.split(" - ")[0])

##revmensc_tranche##
# Question sur le revenu mensuel
revenu = st.selectbox(
    "Quel est votre revenu mensuel net moyen (en €) ?",
    options=[
        "Je préfère ne pas répondre",
        "≤ 1350",
        "1351-1700",
        "1701-2250",
        "2251-3000",
        "> 3000"
    ]
)
revmensc_dummies = {
    "revmensc_tranche_1351-1700": 0,
    "revmensc_tranche_1701-2250": 0,
    "revmensc_tranche_2251-3000": 0,
    "revmensc_tranche_> 3000": 0
}

if revenu == "Je préfère ne pas répondre":
    st.warning("Vous avez choisi de ne pas répondre à cette question. La prédiction pourrait être légèrement moins précise.")
elif revenu != "≤ 1350":
    revmensc_dummies[f"revmensc_tranche_{revenu}"] = 1

st.markdown("----")

st.subheader(" Conditions de travail")
# horaires, prévisibilité, initiatives, autonomie...

##ÉQUILIBRE VIE PROFESSIONNELLE / PERSONNELLE##
cvfvp = st.radio(
    "Comment jugez-vous votre équilibre entre vie professionnelle et vie personnelle ?",
    options=[
        "Très bien",
        "Bien",
        "Pas très bien",
    ]
)

```

```

        "Pas bien du tout",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

if cvfvp in ["Très bien", "Bien"]:
    CVFVP_reg = 1
elif cvfvp in ["Pas très bien", "Pas bien du tout"]:
    CVFVP_reg = 0
else:
    CVFVP_reg = np.nan

##PRÉVISIBILITÉ DES HORAIRES##
previs = st.radio(
    "À quel moment êtes-vous informé·e de vos horaires de travail ?",
    options=[
        "Au moins un mois à l'avance",
        "Au moins une semaine à l'avance",
        "La veille",
        "Le jour même ou pas du tout",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

previs_dict = {
    "Au moins un mois à l'avance": 1,
    "Au moins une semaine à l'avance": 2,
    "La veille": 3,
    "Le jour même ou pas du tout": 4
}

PREVIS = previs_dict.get(previs, np.nan)

##INITIATIVES AU TRAVAIL##
initiat = st.radio(
    "Votre travail nécessite-t-il que vous preniez des initiatives ?",
    options=[
        "Toujours",
        "Souvent",
        "Parfois",
        "Jamais",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

# Recodage INITIAT_reg (1 à 4 conservés, 8/9 → np.nan)
initiat_dict = {
    "Toujours": 1,
    "Souvent": 2,
    "Parfois": 3,
    "Jamais": 4,
    "Je ne sais pas / Je préfère ne pas répondre": np.nan
}

INITIAT_reg = initiat_dict[initiat]

##POSSIBILITÉ DE METTRE EN PRATIQUE SES PROPRES IDÉES##
idee = st.radio(
    "Avez-vous la possibilité de mettre vos propres idées en pratique dans votre travail ?",
    options=[
        "Toujours",
        "Souvent",
        "Parfois",
        "Jamais",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

# Recodage IDEE_reg
if idee in ["Toujours", "Souvent"]:
    IDEE_reg = 1
elif idee in ["Parfois", "Jamais"]:
    IDEE_reg = 0
else:
    IDEE_reg = np.nan

##INTERVENTION SUR LA QUANTITÉ DE TRAVAIL##
quanti = st.radio(
    "Pouvez-vous intervenir sur la quantité de travail qui vous est attribuée ?",
    options=[
        "Toujours",
        "Souvent",
        "Parfois",
        "Jamais",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

if quanti in ["Toujours", "Souvent"]:

```

```

        QUANTI_reg = 1
    elif quanti in ["Parfois", "Jamais"]:
        QUANTI_reg = 0
    else:
        QUANTI_reg = np.nan

##BIENETR1##
bienetr1 = st.radio(
    "Comment évaluez-vous votre bien-être global ces dernières semaines ?",
    ["Plutôt bien", "Plutôt mal", "Je ne sais pas / Je préfère ne pas répondre"]
)
if bienetr1 == "Plutôt bien":
    BIENETR1_reg = 1
elif bienetr1 == "Plutôt mal":
    BIENETR1_reg = 0
else:
    BIENETR1_reg = np.nan

st.markdown("---")

st.subheader(" Relations professionnelles")
# soutien, tensions, aide, conflits...

# --- TENSIONS AVEC LA HIÉRARCHIE ---
tension2 = st.radio(
    "Vivez-vous des situations de tension dans vos rapports avec vos supérieurs hiérarchiques (suffisamment fré
    options=[
        "Oui",
        "Non",
        "Sans objet (pas de supérieur hiérarchique)",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

if tension2 == "Oui":
    TENSION2_reg = 1
elif tension2 == "Non":
    TENSION2_reg = 0
else:
    TENSION2_reg = np.nan

##SOUTIEN SOCIAL RP1##
rp1 = st.radio(
    "Y a-t-il quelqu'un sur qui vous pouvez compter pour discuter de choses personnelles ou pour prendre une dé
    options=[
        "Oui",
        "Non",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

if rp1 == "Oui":
    RP1_reg = 1
elif rp1 == "Non":
    RP1_reg = 0
else:
    RP1_reg = np.nan

##ÉVÉNEMENT MARQUANT - SANTÉ / DÉCÈS D'UN PROCHE##
rp4b = st.radio(
    "Au cours des trois dernières années, un événement vous a-t-il marqué, comme de graves problèmes de santé d
    options=[
        "Oui",
        "Non",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

if rp4b == "Oui":
    RP4B_reg = 1
elif rp4b == "Non":
    RP4B_reg = 0
else:
    RP4B_reg = np.nan

##DÉSACCORD AVEC LE SUPÉRIEUR SUR LA FAÇON DE TRAVAILLER##
acchef = st.radio(
    "Vous arrive-t-il d'être en désaccord avec vos supérieurs sur la façon de bien faire votre travail ?",
    options=[
        "Toujours",
        "Souvent",
        "Parfois",
        "Jamais",
        "Je ne sais pas / Je préfère ne pas répondre"
    ]
)

acchef_dict = {
    "Toujours": 3,
    "Souvent": 2,

```

```

        "Parfois": 1,
        "Jamais": 0,
        "Je ne sais pas / Je préfère ne pas répondre": np.nan
    }

    ACCHEF_reg = accchef_dict[acchef]

    ##AIDE DES COLLÈGUES EN CAS DE DIFFICULTÉ##
    aidcoll = st.radio(
        "Si vous avez du mal à faire un travail délicat ou compliqué, êtes-vous aidé·e par les personnes avec qui v
        options=[
            "Oui",
            "Non",
            "Sans objet / Je ne sais pas / Je préfère ne pas répondre"
        ]
    )
    if aidcoll == "Oui":
        AIDCOLL_reg = 1
    elif aidcoll == "Non":
        AIDCOLL_reg = 0
    else:
        AIDCOLL_reg = np.nan

    ##CONTACT EN DEHORS DU TEMPS DE TRAVAIL PAR DES PERSONNES EXTÉRIEURES##
    joinext = st.radio(
        "Au cours des douze derniers mois, avez-vous été contacté·e en dehors de vos horaires de travail par des pe
        options=[
            "Oui",
            "Non",
            "Sans objet / Je travaille seul·e / Je ne sais pas / Je préfère ne pas répondre"
        ]
    )
    if joinext == "Oui":
        JOINEXT_reg = 1
    elif joinext == "Non":
        JOINEXT_reg = 0
    else:
        JOINEXT_reg = np.nan

    ##CONFIANCE DANS LES INFORMATIONS DU SUPÉRIEUR##
    infoconf = st.radio(
        "Pouvez-vous faire confiance aux informations qui viennent de vos supérieurs ou responsables ?",
        options=[
            "Toujours",
            "Souvent",
            "Parfois",
            "Jamais",
            "Sans objet / Je ne sais pas / Je préfère ne pas répondre"
        ]
    )
    infoconf_dict = {
        "Toujours": 3,
        "Souvent": 2,
        "Parfois": 1,
        "Jamais": 0,
        "Sans objet / Je ne sais pas / Je préfère ne pas répondre": np.nan
    }

    INFOCONF_reg = infoconf_dict[infoconf]

    st.markdown("---")

    st.subheader(" Ressenti au travail")
    # ennui, tâches inutiles, moqueries...

    ##COMPORTEMENT HOSTILE : TÂCHES INUTILES##
    rpble = st.radio(
        "Au travail, vous arrive-t-il d'être chargé·e de tâches inutiles ou dégradantes ?",
        options=["Oui", "Non", "Je ne sais pas / Je préfère ne pas répondre"]
    )
    RPB1E_b = 1 if rpble == "Oui" else 0 if rpble == "Non" else np.nan

    ##COMPORTEMENT HOSTILE : EMPÊCHÉ DE S'EXPRIMER##
    rpblh = st.radio(
        "Vous est-il déjà arrivé d'être empêché·e de vous exprimer dans votre travail ?",
        options=["Oui", "Non", "Je ne sais pas / Je préfère ne pas répondre"]
    )
    RPB1H_b = 1 if rpblh == "Oui" else 0 if rpblh == "Non" else np.nan

    ##COMPORTEMENT HOSTILE : MOQUERIES OU BLAGUES BLESSANTES##
    rpblj = st.radio(
        "Avez-vous subi des moqueries ou blagues blessantes dans votre environnement de travail ?",
        options=["Oui", "Non", "Je ne sais pas / Je préfère ne pas répondre"]
    )
    RPB1J_b = 1 if rpblj == "Oui" else 0 if rpblj == "Non" else np.nan

    ##RESSENTI : ENNUI DANS LE TRAVAIL##
    rpb5e = st.radio(
        "Dans votre travail, ressentez-vous souvent de l'ennui ?",

```

```

options=["Toujours", "Souvent", "Parfois", "Jamais", "Je ne sais pas / Je préfère ne pas répondre"]
)
if rpb5e in ["Toujours", "Souvent"]:
    RPB5E_b = 1
elif rpb5e in ["Parfois", "Jamais"]:
    RPB5E_b = 0
else:
    RPB5E_b = np.nan

# Coefficients estimés du modèle logit1
coefficients = {
    "const": -3.3687,
    "TENSION2_reg": 0.6319,
    "INITIAT_reg": 0.5121,
    "JOINEXT_reg": 0.6286,
    "RPB5E_b": 0.7328,
    "RPB1J_b": 0.7206,
    "ACCHEF_reg": 0.2619,
    "RP4B_reg": 0.3798,
    "sexe": 0.7848,
    "RPB1E_b": 0.8432,
    "CVFVP_reg": -0.7198,
    "RP1_reg": -0.6660,
    "BIENETR1_reg": -0.4299,
    "niv_diplome_reg": 0.1484,
    "IDEE_reg": -0.2672,
    "QUANTI_reg": -0.2745,
    "AIDCOLL_reg": -0.2803,
    "INFOCONF_reg": -0.1177,
    "revmensc_tranche_> 3000": -0.4194,
    "PREVIS": 0.1115,
    "TYPEMPLOI": 0.2261,
    "revmensc_tranche_2251-3000": -0.1733,
    "revmensc_tranche_1351-1700": -0.0993,
    "revmensc_tranche_1701-2250": -0.0826,
    "AGE": 0.0022
}

# Construction du DataFrame utilisateur pour la prédiction
X_input = pd.DataFrame([
    "sexe": sexe,
    "AGE": age,
    "CVFVP_reg": CVFVP_reg,
    "BIENETR1_reg": BIENETR1_reg,
    "RP1_reg": RP1_reg,
    "RP4B_reg": RP4B_reg,
    "RPB1E_b": RPB1E_b,
    "RPB1J_b": RPB1J_b,
    "RPB5E_b": RPB5E_b,
    "AIDCOLL_reg": AIDCOLL_reg,
    "JOINEXT_reg": JOINEXT_reg,
    "INFOCONF_reg": INFOCONF_reg,
    "ACCHEF_reg": ACCHEF_reg,
    "niv_diplome_reg": niv_diplome_reg,
    "PREVIS": PREVIS,
    "INITIAT_reg": INITIAT_reg,
    "IDEE_reg": IDEE_reg,
    "QUANTI_reg": QUANTI_reg,
    "TENSION2_reg": TENSION2_reg,
    "TYPEMPLOI": TYPEMPLOI,
    "revmensc_tranche_1351-1700": revmensc_dummies["revmensc_tranche_1351-1700"],
    "revmensc_tranche_1701-2250": revmensc_dummies["revmensc_tranche_1701-2250"],
    "revmensc_tranche_2251-3000": revmensc_dummies["revmensc_tranche_2251-3000"],
    "revmensc_tranche_> 3000": revmensc_dummies["revmensc_tranche_> 3000"]
])

if not show_prediction or X_input.isnull().any(axis=1).values[0]:
    st.info(" Merci de compléter toutes les questions pour obtenir votre score.")
else:
    # --- Calcul de la probabilité ---
    X_input["const"] = 1 # Ajoute constante
    X_input = X_input[list(coefficients.keys())] # Garde seulement les variables du modèle
    X_array = X_input.values[0]
    coef_array = np.array(list(coefficients.values()))
    log_odds = np.dot(X_array, coef_array)
    proba = 1 / (1 + np.exp(-log_odds))
    prediction = int(proba >= 0.2)

    # --- Résultat ---
    st.subheader(" Résultat")
    st.metric("Probabilité estimée de burn-out sévère", f"{round(proba * 100, 1)} %")
    st.info(f"Selon vos réponses, votre risque estimé de burn-out sévère est de **{round(proba*100, 1)} %**.")
    st.progress(proba)

    # --- Conseils en fonction du niveau de risque ---
    if proba >= 0.4:
        st.warning("⚠ Le risque de burn-out sévère détecté est très élevé.")

```

```

st.markdown("""
**Voici quelques conseils adaptés à votre situation :**
- **Consultez rapidement un professionnel de santé** (médecin traitant, psychologue, psychiatre) pour faire le
- **Envisagez un arrêt de travail temporaire** si vous êtes en situation d'épuisement avancé. Cela peut vous pe
- **Prenez soin de vous** : veillez à votre sommeil, réduisez les surstimulations (notifications, écrans...), e
- **Ne restez pas isolé·e** : parlez à vos proches, à un collègue de confiance ou à votre médecin du travail. V
- **Pensez à consulter votre médecin du travail** pour un éventuel aménagement de poste (réduction des horaires
""")

elif 0.2 <= proba < 0.4:
    st.info("⚠ Un risque modéré de burn-out est détecté.")
    st.markdown("""
**Quelques recommandations pour agir à temps :**
- **Soyez attentif·ve aux signaux de fatigue** : troubles du sommeil, irritabilité, perte de motivation, etc.
- **Essayez d'identifier les facteurs de stress** dans votre environnement de travail : surcharge, manque de re
- **Organisez vos priorités**, apprenez à dire non si besoin, et aménagez-vous des temps de déconnexion.
- **Échangez avec votre supérieur·e ou RH** si certaines tâches vous semblent insoutenables ou mal comprises.
- **Envisagez un accompagnement psychologique préventif** (psychologue, thérapeute, groupe de parole).
""")

else:
    st.success("✅ Aucun risque préoccupant de burn-out n'est détecté.")
    st.markdown("""
**Vous semblez actuellement dans une situation stable. Bravo !**
Voici quelques conseils pour **préserver votre équilibre** :
- Maintenez des **temps de récupération réguliers** : pauses, congés, moments de détente.
- **Entretenez vos relations sociales** au travail et en dehors : soutien et reconnaissance sont protecteurs.
- Soyez à l'écoute de vous-même : en cas de changement d'humeur, fatigue persistante ou perte de sens, n'hésitez pas à demander de l'aide.
- Continuez à **vous questionner sur le sens de votre travail**, et à ajuster vos objectifs personnels et professionnels.
""")


```

Overwriting app.py

```

In [137]: sns.barplot(x="revmensc_tranche", y="burnout_bin_q3", data=data_cl1, order=["≤ 1350", "1351-1700", "1701-2250", "2251-3000", "> 3000"],
plt.title("Prévalence du burn-out selon le revenu mensuel net")
plt.xlabel("Tranche de revenu (€)")
plt.ylabel("% de burn-out sévère")
plt.xticks(rotation=45)
plt.ylim(0, 1)
plt.show()

```



```

In [138]: import numpy as np
import matplotlib.pyplot as plt
import statsmodels.api as sm

# Récupération de l'influence
influence = result_logit1.get_influence()

# Distance de Cook
cooks_d, _ = influence.cooks_distance


# Affichage d'un histogramme
plt.figure(figsize=(8, 4))
plt.hist(cooks_d, bins=50, edgecolor='k')
plt.title("Histogramme des distances de Cook")
plt.xlabel("Distance de Cook")

```

```
plt.ylabel("Fréquence")
plt.grid(True)
plt.tight_layout()
plt.show()

# Seuil de détection des points influents : 4/n
n = X_train.shape[0]
seuil = 4 / n
influents = np.where(cooks_d > seuil)[0]

print(f"\nNombre d'observations influentes (Cook's D > 4/n = {seuil:.5f}) : {len(influents)}")
```



Nombre d'observations influentes (Cook's D > 4/n = 0.00045) : 903

```
In [139]: import pandas as pd
import numpy as np
import statsmodels.api as sm
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, classification_report, roc_auc_score, roc_curve
import matplotlib.pyplot as plt
import pickle

# ----- VARIABLE CIBLE -----
q3 = data_cl1["score_burnout"].quantile(0.75)
data_cl1["burnout_bin_q3"] = (data_cl1["score_burnout"] > q3).astype(int)

# ----- VARIABLE ÂGE QUADRATIQUE -----
data_cl1["AGE2"] = data_cl1["AGE"] ** 2

# ----- VARIABLES EXPLICATIVES -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg", "ACCHEF_reg"
]
num_vars = ["AGE", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "revmensc_tranche"]

# ----- DUMMIES & INTERACTIONS -----
X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

# ----- CONSTRUCTION DE X & y -----
X_logit1 = pd.concat([X_bin, X_num, X_cat, X_inter], axis=1)
y_logit1 = data_cl1["burnout_bin_q3"]
df_logit1 = pd.concat([X_logit1, y_logit1], axis=1).dropna()
X_logit1 = df_logit1.drop(columns="burnout_bin_q3")
y_logit1 = df_logit1["burnout_bin_q3"]

# ----- TRAIN/TEST -----
X_train, X_test, y_train, y_test = train_test_split(
    X_logit1, y_logit1, test_size=0.2, stratify=y_logit1, random_state=42
)

# ----- ESTIMATION LOGIT -----
X_train_sm = sm.add_constant(X_train)
logit1 = sm.Logit(y_train, X_train_sm)
result_logit1 = logit1.fit()

# ----- ÉVALUATION -----
X_test_sm = sm.add_constant(X_test)
y_proba = result_logit1.predict(X_test_sm)
```



```

y_pred = (y_proba >= 0.20).astype(int)

print("\nMatrice de confusion (seuil = 0.20) :")
print(confusion_matrix(y_test, y_pred))
print(f"\nAUC : {roc_auc_score(y_test, y_proba):.3f}")
print("\nClassification report :")
print(classification_report(y_test, y_pred, digits=3))
print(f"\nAIC du modèle : {result_logit1.aic:.2f}")

# ----- COURBE ROC -----
fpr, tpr, _ = roc_curve(y_test, y_proba)
plt.figure(figsize=(8,6))
plt.plot(fpr, tpr, label=f"AUC = {roc_auc_score(y_test, y_proba):.2f}")
plt.plot([0,1], [0,1], 'k--')
plt.xlabel("1 - Spécificité")
plt.ylabel("Sensibilité")
plt.title("Courbe ROC - Modèle logit1 (interaction)")
plt.legend()
plt.grid(True)
plt.tight_layout()
plt.show()

# ----- COEFFICIENTS ET ODDS RATIOS -----
odds_ratios = np.exp(result_logit1.params)
summary_df_logit1 = pd.DataFrame({
    "coeff": result_logit1.params.round(4),
    "odds_ratio": odds_ratios.round(3),
    "p_value": result_logit1.pvalues.round(4)
}).sort_values("p_value")

print("\nCoefficients, Odds Ratios et P-values :")
print(summary_df_logit2)

# ----- SAUVEGARDE DU MODÈLE -----
with open("logit1.pkl", "wb") as f:
    pickle.dump(result_logit1, f)

```

Optimization terminated successfully.
 Current function value: 0.348900
 Iterations 7

Matrice de confusion (seuil = 0.20) :
 [[1576 292]
 [126 214]]


AUC : 0.814

Classification report :

	precision	recall	f1-score	support
0	0.926	0.844	0.883	1868
1	0.423	0.629	0.506	340
accuracy			0.811	2208
macro avg	0.674	0.737	0.694	2208
weighted avg	0.849	0.811	0.825	2208

AIC du modèle : 6212.88

Courbe ROC - Modèle logit1 (interaction)



Coefficients, Odds Ratios et P-values :

	coeff	odds_ratio	p_value
const	-3.3878	0.034	0.0000
TENSION2_reg	0.6373	1.891	0.0000
INITIAT_reg	0.6063	1.834	0.0000
JOINEXT_reg	0.6481	1.912	0.0000
RPB5E_b	0.7426	2.101	0.0000
RPB1J_b	0.7328	2.081	0.0000
ACCHEF_reg	0.2735	1.315	0.0000
RP4B_reg	0.3799	1.462	0.0000
RP1_reg	-0.6751	0.509	0.0000
BIENETR1_reg	-0.4227	0.655	0.0000
sexe	0.7691	2.158	0.0000
RPB1E_b	0.8347	2.304	0.0000
CVFVP_reg	-0.7259	0.484	0.0000
niv_diplome_reg	0.1455	1.157	0.0002
IDEE_reg	-0.2795	0.756	0.0002
QUANTI_reg	-0.2680	0.765	0.0008
AIDCOLL_reg	-0.2850	0.752	0.0034
INFOCONF_reg	-0.1206	0.886	0.0036
PREVIS	0.1186	1.126	0.0181
revmensc_tranche_> 3000	-0.3478	0.706	0.0267
TYPEMPLOI	0.2344	1.264	0.0613
revmensc_tranche_2251-3000	-0.1415	0.868	0.2448
revmensc_tranche_1351-1700	-0.0983	0.906	0.3207
revmensc_tranche_1701-2250	-0.0658	0.936	0.5263
AGE	0.0016	1.002	0.6893

In [140..

```
import pandas as pd
import numpy as np
import statsmodels.api as sm

# ----- RECONSTRUCTION DE X ET y -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg", "ACCHEF_reg"
]
num_vars = ["AGE", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "revmensc_tranche"]

X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

X_full = pd.concat([X_bin, X_num, X_cat], axis=1)
y_full = data_cl1["burnout_bin_q3"]

df_logit = pd.concat([X_full, y_full], axis=1).dropna()
X_logit1 = df_logit.drop(columns="burnout_bin_q3")
y_logit1 = df_logit["burnout_bin_q3"]

# ----- RÉGRESSION MULTIVARIÉE -----
X_sm = sm.add_constant(X_logit1)
model = sm.Logit(y_logit1, X_sm).fit(dis=0)
summary_multi = model.summary2().tables[1]
summary_multi["OR_adjusted"] = np.exp(summary_multi["Coef."])
summary_multi["Signif"] = summary_multi["P>|z|"].apply(lambda p: "**** if p < 0.001 else *** if p < 0.01 else ** if p < 0.05 else ")
summary_multi = summary_multi.reset_index().rename(columns={"index": "Variable"})

# ----- RÉGRESSIONS UNIVARIÉES -----
univ_results = []
for col in X_logit1.columns:
    X_uni = sm.add_constant(X_logit1[[col]])
    result_uni = sm.Logit(y_logit1, X_uni).fit(dis=0)
    coef = result_uni.params[col]
    pval = result_uni.pvalues[col]
    or_uni = np.exp(coef)
    stars = "**** if pval < 0.001 else *** if pval < 0.01 else ** if pval < 0.05 else "
    univ_results.append((col, or_uni, stars))
summary_univ = pd.DataFrame(univ_results, columns=["Variable", "OR_unadjusted", "Signif_uni"])

# ----- PROPORTIONS DESCRIPTIVES -----
prop_dict = {}
for col in X_logit1.columns:
    if X_logit1[col].nunique() == 2:
        freq = X_logit1[col].mean()
        prop_dict[col] = f"{freq * 100:.1f}%"
    else:
        prop_dict[col] = "-"
summary_prop = pd.DataFrame(list(prop_dict.items()), columns=["Variable", "Proportion"])

# ----- FUSION FINALE -----
merged = pd.merge(summary_prop, summary_univ, on="Variable", how="outer")
merged = pd.merge(merged, summary_multi[["Variable", "OR_adjusted", "Signif"]], on="Variable", how="outer")

# ----- AFFICHAGE OU EXPORT -----
print(merged.to_string(index=False)) # Affichage propre dans la console
```

```
# Optionnel : export Excel
# merged.to_excel("tableau_logit_fusionne.xlsx", index=False)
```

Variable	Proportion	OR_unadjusted	Signif_uni	OR_adjusted	Signif
ACCHEF_reg	—	2.010811	***	1.287932	***
AGE	—	0.994271	*	1.001690	
AIDCOLL_reg	89.1%	0.566309	***	0.701087	***
BIENETR1_reg	62.1%	0.323180	***	0.637529	***
CVFVP_reg	83.2%	0.329309	***	0.480576	***
IDEE_reg	64.1%	0.702937	***	0.768568	***
INFOCONF_reg	—	0.577218	***	0.861079	***
INITIAT_reg	80.9%	1.467524	***	1.736779	***
JOINEXT_reg	19.4%	1.741136	***	1.886195	***
PREVIS	—	1.298159	***	1.143384	**
QUANTI_reg	28.0%	0.645646	***	0.787855	***
RP1_reg	93.6%	0.425246	***	0.497822	***
RP4B_reg	41.6%	1.819683	***	1.525918	***
RPB1E_b	5.8%	5.130497	***	2.157024	***
RPB1J_b	5.8%	4.244806	***	2.120687	***
RPB5E_b	7.5%	3.458413	***	2.139984	***
TENSION2_reg	31.0%	3.727477	***	1.879577	***
TYPEMPLOI	—	1.394594	***	1.258269	*
const	NaN	NaN	NaN	0.037770	***
niv_diplome_reg	—	1.181976	***	1.180958	***
revmensc_tranche_1351-1700	27.0%	1.014862		0.994573	
revmensc_tranche_1701-2250	26.8%	1.044356		0.996571	
revmensc_tranche_2251-3000	17.2%	1.000492		0.883433	
revmensc_tranche_> 3000	9.2%	0.751754	**	0.696970	*
sexe	56.9%	2.004488	***	2.197717	***

```
In [141]: import pandas as pd
import numpy as np
import statsmodels.api as sm

# ----- RECONSTRUCTION DE X ET y -----
bin_vars = [
    "sexe", "CVFVP_reg", "BIENETR1_reg",
    "RP1_reg", "RP4B_reg", "RPB1E_b", "RPB1J_b", "RPB5E_b",
    "AIDCOLL_reg", "JOINEXT_reg", "INFOCONF_reg", "ACCHEF_reg"
]
num_vars = ["AGE", "niv_diplome_reg", "PREVIS", "INITIAT_reg", "IDEE_reg", "QUANTI_reg", "TENSION2_reg"]
cat_vars = ["TYPEMPLOI", "revmensc_tranche"]

X_bin = data_cl1[bin_vars].astype(float)
X_num = data_cl1[num_vars].astype(float)
X_cat = pd.get_dummies(data_cl1[cat_vars], drop_first=True).astype(float)

X_full = pd.concat([X_bin, X_num, X_cat], axis=1)
y_full = data_cl1["burnout_bin_q3"]

df_logit = pd.concat([X_full, y_full], axis=1).dropna()
X_logit1 = df_logit.drop(columns="burnout_bin_q3")
y_logit1 = df_logit["burnout_bin_q3"]

# ----- RÉGRESSION MULTIVARIÉE -----
X_sm = sm.add_constant(X_logit1)
model = sm.Logit(y_logit1, X_sm).fit(dis=0)
summary_multi = model.summary2().tables[1]
summary_multi["OR_adjusted"] = np.exp(summary_multi["Coef."])
summary_multi["Signif"] = summary_multi["P>|z|"].apply(lambda p: "****" if p < 0.001 else "***" if p < 0.01 else
summary_multi = summary_multi.reset_index().rename(columns={"index": "Variable"})

# ----- RÉGRESSIONS UNIVARIÉES -----
univ_results = []
for col in X_logit1.columns:
    X_uni = sm.add_constant(X_logit1[[col]])
    result_uni = sm.Logit(y_logit1, X_uni).fit(dis=0)
    coef = result_uni.params[col]
    pval = result_uni.pvalues[col]
    or_uni = np.exp(coef)
    stars = "****" if pval < 0.001 else "***" if pval < 0.01 else "" if pval < 0.05 else ""
    univ_results.append((col, or_uni, stars))
summary_univ = pd.DataFrame(univ_results, columns=["Variable", "OR_unadjusted", "Signif_uni"])

# ----- PROPORTIONS DESCRIPTIVES -----
prop_dict = {}
for col in X_logit1.columns:
    if X_logit1[col].nunique() == 2:
        freq = X_logit1[col].mean()
        prop_dict[col] = f"{freq * 100:.1f}%"
    else:
        prop_dict[col] = "-"
summary_prop = pd.DataFrame(list(prop_dict.items()), columns=["Variable", "Proportion"])

# ----- FUSION FINALE -----
merged = pd.merge(summary_prop, summary_univ, on="Variable", how="outer")
merged = pd.merge(merged, summary_multi[["Variable", "OR_adjusted", "Signif"]], on="Variable", how="outer")
```

```
# ----- AFFICHAGE OU EXPORT -----
print(merged.to_string(index=False)) # Affichage propre dans la console

# Optionnel : export Excel
# merged.to_excel("tableau_logit_fusionne.xlsx", index=False)
```

	Variable	Proportion	OR_unadjusted	Signif_uni	OR_adjusted	Signif
	ACCHEF_reg	—	2.010811	***	1.287932	***
	AGE	—	0.994271	*	1.001690	
	AIDCOLL_reg	89.1%	0.566309	***	0.701087	***
	BIENETR1_reg	62.1%	0.323180	***	0.637529	***
	CVFVP_reg	83.2%	0.329309	***	0.480576	***
	IDEE_reg	64.1%	0.702937	***	0.768568	***
	INFOCONF_reg	—	0.577218	***	0.861079	***
	INITIAT_reg	80.9%	1.467524	***	1.736779	***
	JOINEXT_reg	19.4%	1.741136	***	1.886195	***
	PREVIS	—	1.298159	***	1.143384	**
	QUANTI_reg	28.0%	0.645646	***	0.787855	***
	RP1_reg	93.6%	0.425246	***	0.497822	***
	RP4B_reg	41.6%	1.819683	***	1.525918	***
	RPB1E_b	5.8%	5.130497	***	2.157024	***
	RPB1J_b	5.8%	4.244806	***	2.120687	***
	RPB5E_b	7.5%	3.458413	***	2.139984	***
	TENSION2_reg	31.0%	3.727477	***	1.879577	***
	TYPEMLOI	—	1.394594	***	1.258269	*
	const	NaN	NaN	NaN	0.037770	***
	niv_diplome_reg	—	1.181976	***	1.180958	***
	revmensc_tranche_1351-1700	27.0%	1.014862		0.994573	
	revmensc_tranche_1701-2250	26.8%	1.044356		0.996571	
	revmensc_tranche_2251-3000	17.2%	1.000492		0.883433	
	revmensc_tranche_> 3000	9.2%	0.751754	**	0.696970	*
	sexe	56.9%	2.004488	***	2.197717	***

```
In [142]: import pandas as pd

# Exemple de chargement de données
# data_cl1 = pd.read_csv('votre_fichier.csv')

# Créer la variable burnout_bin_q3 en fonction du 75e percentile
data_cl1['burnout_bin_q3'] = (data_cl1['score_burnout'] > data_cl1['score_burnout'].quantile(0.75)).astype(int)

# Séparer les groupes en fonction de la variable cible 'burnout_bin_q3'
epuisement = data_cl1[data_cl1['burnout_bin_q3'] == 1] # Individus avec épuisement professionnel
non_epuisement = data_cl1[data_cl1['burnout_bin_q3'] == 0] # Autres individus

# Convertir les variables catégorielles en variables numériques si nécessaire
# Exemple : Si 'sexe' est une variable catégorielle, on la convertit
data_cl1['sexe'] = data_cl1['sexe'].map({'Homme': 1, 'Femme': 0})

# Calcul des statistiques descriptives pour les deux groupes
desc_epuisement = epuisement.describe(include='all') # Inclure toutes les variables
desc_non_epuisement = non_epuisement.describe(include='all') # Inclure toutes les variables

# Comparaison entre les deux groupes : Moyenne, Médiane, Écarts-types, etc.
moyenne_comparaison = pd.DataFrame({
    'Moyenne (épuisement)': epuisement.select_dtypes(include='number').mean(),
    'Moyenne (non épuisement)': non_epuisement.select_dtypes(include='number').mean()
})

ecart_type_comparaison = pd.DataFrame({
    'Ecart-type (épuisement)': epuisement.select_dtypes(include='number').std(),
    'Ecart-type (non épuisement)': non_epuisement.select_dtypes(include='number').std()
})

# Pour les variables catégorielles comme 'sexe', vous pouvez faire une comparaison de fréquences
frequences_epuisement = epuisement['sexe'].value_counts(normalize=True)
frequences_non_epuisement = non_epuisement['sexe'].value_counts(normalize=True)

# Résumé de tout
print("Statistiques descriptives pour les individus en épuisement professionnel :")
print(desc_epuisement)

print("\nStatistiques descriptives pour les individus non épuisement :")
print(desc_non_epuisement)

print("\nComparaison des moyennes :")
print(moyenne_comparaison)

print("\nComparaison des écarts-types :")
print(ecart_type_comparaison)

print("\nComparaison des fréquences de 'sexe' :")
print("Epuisement professionnel :\n", frequences_epuisement)
print("Non épuisement professionnel :\n", frequences_non_epuisement)
```

```
Statistiques descriptives pour les individus en épuisement professionnel :
      DETRESSE      FATIGUE      CWLOURD      revmensc      RP3B \
count  1728.000000  1728.000000  1728.000000  1728.000000  1728.000000
unique         NaN         NaN         NaN         NaN         NaN
```

top	NaN	NaN	NaN	NaN	NaN
freq	NaN	NaN	NaN	NaN	NaN
mean	1.211806	3.146412	1.527199	1936.532986	1.529514
std	0.481553	0.817427	0.499404	826.217739	0.581760
min	1.000000	1.000000	1.000000	206.000000	1.000000
25%	1.000000	3.000000	1.000000	1400.000000	1.000000
50%	1.000000	3.000000	2.000000	1770.000000	2.000000
75%	1.000000	4.000000	2.000000	2250.000000	2.000000
max	9.000000	9.000000	2.000000	6400.000000	9.000000

	MAISON	RP22J	CWDEBOU	RP22I	EMOTION	...	\
count	1728.000000	1728.000000	1728.000000	1728.000000	1728.000000	...	
unique	NaN	NaN	NaN	NaN	NaN	...	
top	NaN	NaN	NaN	NaN	NaN	...	
freq	NaN	NaN	NaN	NaN	NaN	...	
mean	3.421296	3.439236	1.501736	2.608218	2.769097	...	
std	1.216395	0.774380	0.553974	0.841788	0.739673	...	
min	1.000000	1.000000	1.000000	1.000000	1.000000	...	
25%	3.000000	3.000000	1.000000	2.000000	2.000000	...	
50%	4.000000	4.000000	1.000000	3.000000	3.000000	...	
75%	4.000000	4.000000	2.000000	3.000000	3.000000	...	
max	5.000000	9.000000	9.000000	9.000000	9.000000	...	

	AIDCOLL_reg	JOINEXT_reg	HORVAR_reg	INFOCONF_reg	ACCHEF_reg		\
count	1728.000000	1728.000000	1728.000000	1728.000000	1728.000000		
unique	NaN	NaN	NaN	NaN	NaN		
top	NaN	NaN	NaN	NaN	NaN		
freq	NaN	NaN	NaN	NaN	NaN		
mean	0.837384	0.276620	0.414352	1.851273	1.245949		
std	0.369122	0.447457	0.492752	0.949439	0.801154		
min	0.000000	0.000000	0.000000	0.000000	0.000000		
25%	1.000000	0.000000	0.000000	1.000000	1.000000		
50%	1.000000	0.000000	0.000000	2.000000	1.000000		
75%	1.000000	1.000000	1.000000	3.000000	2.000000		
max	1.000000	1.000000	1.000000	3.000000	3.000000		

	OBJECTIF_reg	AGE2	INT_TENSION2_AIDCOLL	INT_OBJECTIF_INITIAT		\
count	1728.000000	1728.000000	1715.000000	1727.000000		
unique	NaN	NaN	NaN	NaN		
top	NaN	NaN	NaN	NaN		
freq	NaN	NaN	NaN	NaN		
mean	0.350694	2080.576389	0.473469	0.306312		
std	0.477326	823.992881	0.499441	0.461094		
min	0.000000	576.000000	0.000000	0.000000		
25%	0.000000	1425.250000	0.000000	0.000000		
50%	0.000000	2025.000000	0.000000	0.000000		
75%	1.000000	2704.000000	1.000000	1.000000		
max	1.000000	4096.000000	1.000000	1.000000		

	INT_RPB5E_TENSION2
count	1715.000000
unique	NaN
top	NaN
freq	NaN
mean	0.114286
std	0.318251
min	0.000000
25%	0.000000
50%	0.000000
75%	0.000000
max	1.000000

[11 rows x 258 columns]

Statistiques descriptives pour les individus non épuisement :

	DETRESSE	FATIGUE	CWLOURD	revmensc	RP3B	\
count	9485.000000	9485.000000	9485.000000	9485.000000	9485.000000	
unique	NaN	NaN	NaN	NaN	NaN	
top	NaN	NaN	NaN	NaN	NaN	
freq	NaN	NaN	NaN	NaN	NaN	
mean	1.461149	3.565314	1.609383	1982.239114	1.625936	
std	0.559882	0.627534	0.505741	883.652117	0.538757	
min	1.000000	1.000000	1.000000	184.000000	1.000000	
25%	1.000000	3.000000	1.000000	1424.000000	1.000000	
50%	1.000000	4.000000	2.000000	1800.000000	2.000000	
75%	2.000000	4.000000	2.000000	2300.000000	2.000000	
max	9.000000	9.000000	9.000000	6700.000000	9.000000	

	MAISON	RP22J	CWDEBOU	RP22I	EMOTION	...	\
count	9485.000000	9485.000000	9485.000000	9485.000000	9485.000000	...	
unique	NaN	NaN	NaN	NaN	NaN	...	
top	NaN	NaN	NaN	NaN	NaN	...	
freq	NaN	NaN	NaN	NaN	NaN	...	
mean	3.699842	3.785029	1.523774	3.276858	3.265577	...	
std	1.062098	0.506669	0.516890	0.745645	0.679892	...	
min	1.000000	1.000000	1.000000	1.000000	1.000000	...	
25%	3.000000	4.000000	1.000000	3.000000	3.000000	...	
50%	4.000000	4.000000	2.000000	3.000000	3.000000	...	
75%	4.000000	4.000000	2.000000	4.000000	4.000000	...	

max	5.000000	9.000000	9.000000	9.000000	4.000000	...
-----	----------	----------	----------	----------	----------	-----

	AIDCOLL_reg	JOINEXT_reg	HORVAR_reg	INFOCONF_reg	ACCHEF_reg	\
count	9485.000000	9485.000000	9485.000000	9485.000000	9485.000000	
unique	NaN	NaN	NaN	NaN	NaN	
top	NaN	NaN	NaN	NaN	NaN	
freq	NaN	NaN	NaN	NaN	NaN	
mean	0.900264	0.180706	0.318187	2.274222	0.870111	
std	0.299664	0.384795	0.465797	0.811255	0.692642	
min	0.000000	0.000000	0.000000	0.000000	0.000000	
25%	1.000000	0.000000	0.000000	2.000000	0.000000	
50%	1.000000	0.000000	0.000000	2.000000	1.000000	
75%	1.000000	0.000000	1.000000	3.000000	1.000000	
max	1.000000	1.000000	1.000000	3.000000	3.000000	

	OBJECTIF_reg	AGE2	INT_TENSION2_AIDCOLL	INT_OBJECTIF_INITIAT	\
count	9485.000000	9485.000000	9409.000000	9484.000000	
unique	NaN	NaN	NaN	NaN	
top	NaN	NaN	NaN	NaN	
freq	NaN	NaN	NaN	NaN	
mean	0.270005	2124.315656	0.233925	0.220266	
std	0.443986	831.761070	0.423348	0.414448	
min	0.000000	576.000000	0.000000	0.000000	
25%	0.000000	1444.000000	0.000000	0.000000	
50%	0.000000	2116.000000	0.000000	0.000000	
75%	1.000000	2809.000000	0.000000	0.000000	
max	1.000000	4096.000000	1.000000	1.000000	

	INT_RPB5E_TENSION2
count	9409.000000
unique	NaN
top	NaN
freq	NaN
mean	0.024020
std	0.153118
min	0.000000
25%	0.000000
50%	0.000000
75%	0.000000
max	1.000000

[11 rows x 258 columns]

Comparaison des moyennes :

	Moyenne (épuiement)	Moyenne (non épuiement)
DETRESSE	1.211806	1.461149
FATIGUE	3.146412	3.565314
CWLOURD	1.527199	1.609383
revmensc	1936.532986	1982.239114
RP3B	1.529514	1.625936
...	...	...
OBJECTIF_reg	0.350694	0.270005
AGE2	2080.576389	2124.315656
INT_TENSION2_AIDCOLL	0.473469	0.233925
INT_OBJECTIF_INITIAT	0.306312	0.220266
INT_RPB5E_TENSION2	0.114286	0.02402

[229 rows x 2 columns]

Comparaison des écarts-types :

	Ecart-type (épuiement)	Ecart-type (non épuiement)
DETRESSE	0.481553	0.559882
FATIGUE	0.817427	0.627534
CWLOURD	0.499404	0.505741
revmensc	826.217739	883.652117
RP3B	0.58176	0.538757
...	...	...
OBJECTIF_reg	0.477326	0.443986
AGE2	823.992881	831.76107
INT_TENSION2_AIDCOLL	0.499441	0.423348
INT_OBJECTIF_INITIAT	0.461094	0.414448
INT_RPB5E_TENSION2	0.318251	0.153118

[229 rows x 2 columns]

Comparaison des fréquences de 'sexe' :

Epuiement professionnel :

```
sexe
1.0    0.706019
0.0    0.293981
Name: proportion, dtype: float64
```

Non épuiement professionnel :

```
sexe
1.0    0.544966
0.0    0.455034
Name: proportion, dtype: float64
```

```
In [143]: # Statistiques descriptives des variables numériques
print("Statistiques descriptives des variables numériques:")
```

```
print(data_cl1[num_vars].describe())

# Statistiques descriptives des variables catégorielles (fréquences)
print("\nStatistiques descriptives des variables catégorielles:")
for var in cat_vars:
    print(f'\nFréquences de {var}:')
    print(data_cl1[var].value_counts())
```

Statistiques descriptives des variables numériques:

	AGE	niv_diplome_reg	PREVIS	INITIAT_reg \
count	11213.000000	11213.000000	11213.000000	11211.000000
mean	45.058414	1.641309	1.211719	0.808848
std	9.344636	1.016513	0.613891	0.393226
min	24.000000	0.000000	1.000000	0.000000
25%	38.000000	1.000000	1.000000	1.000000
50%	45.000000	1.000000	1.000000	1.000000
75%	53.000000	3.000000	1.000000	1.000000
max	64.000000	3.000000	4.000000	1.000000

	IDEE_reg	QUANTI_reg	TENSION2_reg
count	11203.000000	11137.000000	11124.000000
mean	0.641703	0.282123	0.309421
std	0.479521	0.450053	0.462276
min	0.000000	0.000000	0.000000
25%	0.000000	0.000000	0.000000
50%	1.000000	0.000000	0.000000
75%	1.000000	1.000000	1.000000
max	1.000000	1.000000	1.000000

Statistiques descriptives des variables catégorielles:

Fréquences de TYPEMPL0I:

TYPEMPL0I	count
6.0	10691
5.0	415
2.0	60
4.0	32
3.0	6
7.0	5
1.0	4

Name: count, dtype: int64

Fréquences de revmensc_tranche:

revmensc_tranche	count
1351-1700	3013
1701-2250	3006
≤ 1350	2232
2251-3000	1922
> 3000	1040

Name: count, dtype: int64

In []: